Část III

Matematika v praxi

Úvod ke třetí části

Neexistuje odvětví matematiky, jakkoli abstraktní, které by se jednou nedalo použít na jevy reálného světa.

Nikolaj Lobačevskij

Často se ptáme ‘a k čemu mi to bude?’ Tato poslední část knihy je pokusem o odpověď. Každá kapitola vezme jednu oblast, kde se matematika z předchozích částí opravdu používá: počítačové hry, šifrování, umělou inteligenci a přírodu kolem nás.

Kapitoly jsou psané tak, aby se daly číst samostatně a v libovolném pořadí. Používají pojmy z obou předchozích částí a vždy odkazují, kde je najdete. Pokud vám některá kapitola z druhé části připadala příliš abstraktní, tady uvidíte, proč se ji někdo vůbec obtěžoval vymyslet.

Kapitola 35

Matematika ve hrách

Člověk je zcela člověkem jen tam, kde si hraje.
Friedrich Schiller, Listy o estetické výchově člověka, 1795

Hry jsou matematika, která se tváří jako zábava. Když se rozhodujete, jestli v kámen, nůžky, papír hodit kámen, řešíte úlohu teorie her. Když v deskovce počítáte, jak často padne na dvou kostkách sedmička, používáte kombinatoriku z kapitoly 19 a pravděpodobnost z kapitoly 20. A když ve videohře postavička otočí hlavu za nepřítelem, odrazí se od zdi nebo najde cestu bludištěm, běží pod kapotou vektory z kapitol 16 a 14, matice z kapitoly 27 a numerické řešení diferenciálních rovnic z kapitoly 31.

Kapitola má tři patra. Nejdřív teorie her: jak se rozhodovat, když o výsledku rozhoduje i soupeř. Pak pravděpodobnost ve hrách, od kostek po loot boxy. A nakonec největší část, matematika pro vývojáře her, tedy to, co skutečně najdete v každém herním enginu.

35.1 Teorie her: když hraje i soupeř

Hra v normálním tvaru je dána hráči, jejich možnými **strategiemi** a **výplatami**: pro každou kombinaci strategií dostane každý hráč nějaké číslo (zisk). Dvojice strategií je **Nashova rovnováha**, pokud ani jeden hráč nemůže zvýšit svou výplatu tím, že *sám* změní strategii.

Nashova rovnováha není ‘nejlepší výsledek’. Je to stav, ze kterého nikomu nevyplatí jednostranně utéct. Nejslavnější příklad ukazuje, jak velký rozdíl mezi těmi dvěma věcmi může být.

Příklad 35.1.1 Vězňovo dilema. Dva podezřelí sedí v oddělených celách. Každý může mlčet, nebo práskat. Pokud oba mlčí, dostanou po roce. Pokud jeden práská a druhý mlčí, práskač jde domů a mlčící dostane tři roky. Pokud práskají oba, dostanou po dvou letech. Výplaty (záporné roky vězení, první číslo patří hráči A):

	B mlčí	B práská
A mlčí	$(-1,-1)$	$(-3,0)$
A práská	$(0,-3)$	$(-2,-2)$

Ať udělá B cokoli, A si práskáním polepší: $0 > -1$ a $-2 > -3$. Práskání je tzv. **dominantní strategie**, a totéž platí pro B. Jediná Nashova rovnováha je (práská, práská) s výsledkem $(-2,-2)$, přestože (mlčí, mlčí) by bylo lepší pro *oba*. Rozumné individuální chování vede ke špatnému společnému výsledku.

Hru vymysleli v roce 1950 Merrill Flood a Melvin Dresher v RAND Corporation, příběh o vězních k ní přidal Albert Tucker. Stejnou strukturu má závod ve zbrojení, přetěžování společné pastviny nebo dva obchody, které si navzájem podbízejí ceny. Když se ale vězňovo dilema hraje *opakovaně*, situace se mění. V počítačových turnajích Roberta Axelroda kolem roku 1980 zvítězila jednoduchá strategie ‘oko za oko’: začni spoluprací a pak opakuj soupeřův minulý tah.

35.1.1 Kámen, nůžky, papír a smíšené strategie

	kámen	nůžky	papír
kámen	0	+1	−1
nůžky	−1	0	+1
papír	+1	−1	0

Tabulka udává výplatu řádkového hráče, soupeř dostane přesně opačné číslo. Takové hře se říká **hra s nulovým součtem**: co jeden získá, druhý ztratí. Žádná *čistá* strategie tu rovnováhou není. Kdo hraje stále kámen, toho soupeř porazí papírem. Řešením je **smíšená strategie**: hráč volí tahy náhodně s pevnými pravděpodobnostmi.

Příklad 35.1.2 Proč právě $\frac{1}{3}$, $\frac{1}{3}$, $\frac{1}{3}$? Nechť soupeř hraje kámen, nůžky, papír s pravděpodobnostmi k, n, p. Moje očekávaná výplata za jednotlivé tahy je

$$E[\text{kámen}] = n - p, \qquad E[\text{nůžky}] = p - k, \qquad E[\text{papír}] = k - n.$$

Pokud by jedna z hodnot byla kladná, hrál bych jen ten tah a vydělával. Soupeř mi to nesmí dovolit, takže v rovnováze musí být všechny tři hodnoty stejné. Jejich součet je ale 0, takže jsou všechny nulové: $n = p$, $p = k$, $k = n$. Spolu s $k + n + p = 1$ dostaneme $k = n = p = \frac{1}{3}$.

Princip ‘udělej soupeře lhostejným’ platí obecně. V rovnováze musí být každý tah, který hrajete s kladnou pravděpodobností, stejně dobrý. Jinak byste hráli jen ten lepší. Proto má smysl ve fotbale kopat penaltu občas doprostřed a v pokeru občas blafovat.

Nashova věta (1950): Každá konečná hra (konečně mnoho hráčů i strategií) má alespoň jednu Nashovu rovnováhu ve smíšených strategiích.
Věta o minimaxu (von Neumann, 1928): Ve hře dvou hráčů s nulovým součtem existuje číslo v (**cena hry**) a smíšené strategie, kterými si první hráč zaručí průměrně aspoň v a druhý hráč zaručí, že první nezíská víc než v.

Nashův důkaz je krátký a stojí na *větě o pevném bodě*: spojité zobrazení koule do sebe má bod, který se nehýbe. Pro kámen, nůžky, papír je cena hry $v = 0$, jak čekáme u férové hry.

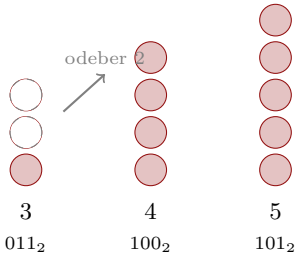
35.2 Kombinatorické hry: Nim a krádež strategie

Kombinatorické hry jsou hry bez náhody a bez skrytých informací, jako šachy, dáma nebo piškvorky. Dva hráči se střídají a kdo nemůže táhnout, prohrává (nebo se vyhrává jiným jasným pravidlem). V teorii jsou to nejjednodušší hry. Každou pozici lze v principu označit jako **vyhranou** (hráč na tahu má vyhrávající strategii) nebo **prohranou**.

Nim: na stole je několik hromádek žetonů. Hráč na tahu si vybere jednu hromádku a odebere z ní libovolný kladný počet žetonů. Kdo nemůže táhnout (stůl je prázdný), prohrál.
Boutonova věta (1901): Pozice s hromádkami $a_1, a_2, \ldots, a_k$ je prohraná pro hráče na tahu, právě když

$$a_1 \oplus a_2 \oplus \cdots \oplus a_k = 0,$$

kde $\oplus$ je **XOR**, tedy sčítání ve dvojkové soustavě bez přenosu (v každém řádu: $0 \oplus 0 = 1 \oplus 1 = 0$, $0 \oplus 1 = 1 \oplus 0 = 1$).



$011 \oplus 100 \oplus 101 = 010 = 2 \neq 0$

nejvyšší jednička součtu: řád 2

$3 \oplus 2 = 1$: z hromádky 3 nech 1

$001 \oplus 100 \oplus 101 = 000$

Důkaz. (Boutonovy věty) Označme pozice s nulovým XORem jako *nulové*. Stačí ukázat tři věci.

1. Koncová pozice (všechny hromádky prázdné) je nulová.

2. Z nulové pozice vede každý tah do nenulové. Tah mění jen jednu hromádku z a na $a' \neq a$. Celkový XOR se tím změní na $s \oplus a \oplus a'$, a protože $a \oplus a' \neq 0$, nový součet je $0 \oplus (a \oplus a') \neq 0$.

3. Z nenulové pozice existuje tah do nulové. Nechť $s \neq 0$ je XOR všech hromádek a nechť jeho nejvyšší jednička je v řádu 2^m. Aspoň jedna hromádka a má v řádu 2^m také jedničku (jinak by tam součet měl nulu). Číslo $a \oplus s$ má v řádu 2^m nulu a ve vyšších řádech se s a shoduje, takže $a \oplus s < a$. Zmenšíme tedy hromádku a na $a \oplus s$. Nový XOR je $s \oplus a \oplus (a \oplus s) = 0$.

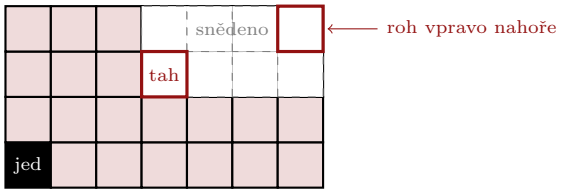
Hráč, který vždy táhne do nulové pozice, tedy nikdy nedostane do ruky koncovou pozici. Hra je konečná, takže soupeř jednou nebude mít tah. ■

Poznámka 35.2.1 Nim je víc než kuriozita. **Sprague–Grundyho věta** (1935–1939) říká, že *každá* nestranná kombinatorická hra (oba hráči mají stejné tahy) je ekvivalentní jedné hromádce Nimu nějaké velikosti. Součet her se pak počítá XORem.

35.2.1 Krádež strategie

Někdy umíme dokázat, že první hráč vyhrává, aniž bychom věděli *jak*.

Příklad 35.2.2 Chomp: čokoláda o rozměrech $m \times n$ s otráveným dílkem v levém dolním rohu. Hráč na tahu ukáže na dílek a sní ho spolu se všemi dílky napravo a nahoru od něj. Kdo musí sníst otrávený dílek, prohrál.



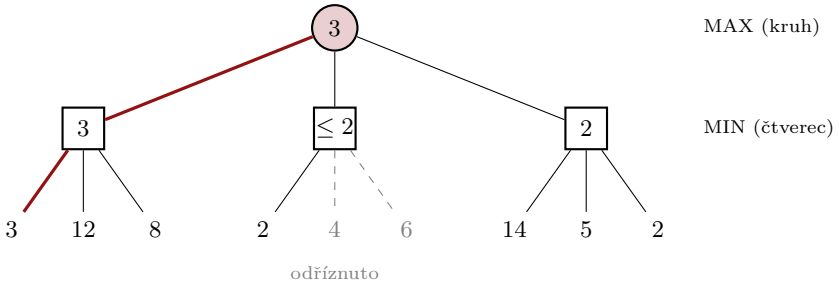
Důkaz. (první hráč vyhrává) Předpokládejme, že vyhrávající strategii má druhý hráč. První hráč sní jen roh vpravo nahoře. Druhý odpoví podle své vyhrávající strategie nějakým tahem X. Tah X ale sní i ten roh (roh leží napravo a nahoru od každého dílku), takže pozice po tahu X je stejná, jako kdyby první hráč zahrál X hned na začátku. První hráč tedy mohl 'ukrást' vyhrávající tah a hrát za druhého. To je spor, protože oba nemohou mít vyhrávající strategii. Hra skončí vždy vítězstvím jednoho z hráčů (je konečná a remízy nejsou), takže vyhrává první hráč. ■

Stejný argument funguje pro deskovou hru Hex (John Nash ji v roce 1948 vymyslel nezávisle na Pietu Heinovi). Pro velké čokolády ani velké desky Hexu přitom vyhrávající strategii nikdo nezná.

35.2.2 Strom hry a minimax

Každou konečnou hru lze nakreslit jako **strom**: kořen je výchozí pozice, hrany jsou tahy. U piškvorek 3×3 je nejvýš $9! = 362\,880$ posloupností tahů. Mnoho partií ale skončí dřív, takže dohraných partií je přesně 255 168. To počítač projde za zlomek sekundy a zjistí, že při dokonalé hře je výsledkem remíza. Claude Shannon v roce 1950 odhadl počet partií šachů zhruba na 10^{120}, víc, než je atomů v pozorovatelném vesmíru (asi 10^{80}).

Minimax: hodnota listu je výsledek hry (z pohledu hráče MAX). Hodnota uzlu, kde táhne MAX, je *maximum* hodnot potomků, uzlu, kde táhne MIN, je *minimum*. Hodnota kořene je výsledek při dokonalé hře obou stran.

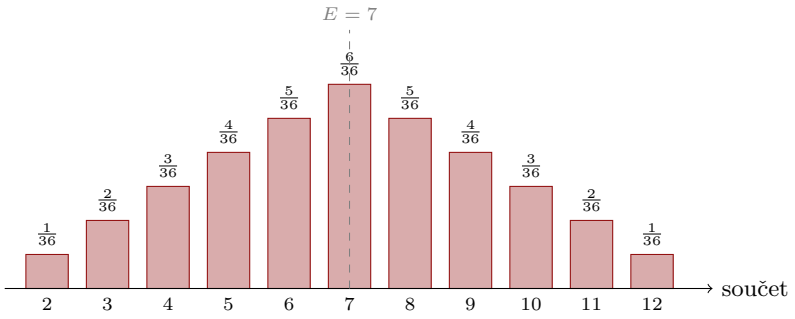


Strom na obrázku ukazuje i trik, kterým šachové programy ušetří obrovské množství práce: **alfa-beta prořezávání**. Levá větev zaručuje MAXovi hodnotu 3. V prostřední větvi MIN hned první odpovědí nabídne 2, takže hodnota celé větve bude nejvýš $2 < 3$. Zbylé listy 4 a 6 už nemá smysl zkoumat, MAX tuto větev stejně nezvolí. Při dobrém pořadí tahů zmenší alfa-beta počet prohledaných pozic zhruba na odmocninu.

35.3 Pravděpodobnost ve hrách

35.3.1 Kostky

Při hodu dvěma kostkami je 36 stejně pravděpodobných dvojic. Součet s lze dostat $6-|s-7|$ způsoby, takže součty nejsou stejně pravděpodobné. Sedmička padá šestkrát častěji než dvojka nebo dvanáctka.



Rozdělení má tvar trojúhelníku. Hází-li se třemi kostkami, je to už ‘zvon’ složený ze tří parabol, a s více kostkami se podle centrální limitní věty blíží normálnímu rozdělení. Herní designéři to znají: útok ‘3k6’ má stejný průměr 10,5 jako ‘1k20’, ale je mnohem předvídatelnější. V deskové hře Osadníci z Katanu jsou na číslech políček tečky, jejichž počet je přesně počet způsobů, jak daný součet padne.

35.3.2 Loot boxy, gacha a geometrické rozdělení

Příklad 35.3.1 Truhla za 50 mincí obsahuje běžný předmět v hodnotě 10 (pravděpodobnost 0,70), vzácný v hodnotě 60 (0,25) a legendární v hodnotě 400 (0,05). Střední hodnota obsahu je

$$E = 0{,}70 \cdot 10 + 0{,}25 \cdot 60 + 0{,}05 \cdot 400 = 7 + 15 + 20 = 42 < 50.$$

Průměrně tedy každou truhlou prodělá hráč 8 mincí. Polovinu hodnoty přitom tvoří legendárka, kterou devatenáct hráčů z dvaceti nedostane.

Opakujeme nezávislé pokusy, každý uspěje s pravděpodobností p. Počet pokusů T do prvního úspěchu má **geometrické rozdělení**:

$$P(T = k) = (1-p)^{k-1}p, \qquad P(T > k) = (1-p)^k, \qquad E[T] = \frac{1}{p}.$$

Důkaz. Po prvním pokusu buď máme úspěch (pravděpodobnost p, spotřebovali jsme 1 pokus), nebo jsme na začátku znovu a jeden pokus jsme ‘ztratili’. Tedy $E = p \cdot 1 + (1-p)(1+E)$, odkud $pE = 1$. ■

Pozor na intuici: se šancí 5 % potřebujete průměrně 20 pokusů, ale po 20 pokusech máte úspěch jen s pravděpodobností $1 - 0{,}95^{20} \approx 64\,\%$. A 10 % hráčů nemá úspěch ani po 45 pokusech. Rozdělení má dlouhý 'ocas' nešťastníků, kteří pak píšou rozzlobené recenze.

Příklad 35.3.2 Pity systém. Ve hrách typu gacha bývá šance na nejvzácnější postavu malá, třeba $p = 0{,}6\,\%$, ale hra slibuje, že nejpozději 90. pokus uspěje vždy (tzv. tvrdá pity). Jaký je průměrný počet pokusů? Pro kladné celočíselné T platí užitečný vzorec $E[T] = \sum_{k\geq 0} P(T > k)$. Zde $P(T > k) = (1-p)^k$ pro $k < 90$ a $P(T > k) = 0$ pro $k \geq 90$:

$$E[T] = \sum_{k=0}^{89} (1-p)^k = \frac{1-(1-p)^{90}}{p} = \frac{1-0{,}994^{90}}{0{,}006} \approx \frac{1-0{,}582}{0{,}006} \approx 69{,}7.$$

Bez pity by průměr byl $\frac{1}{p} \approx 167$. Navíc $P(T > 89) = 0{,}994^{89} \approx 0{,}585$, takže víc než polovina hráčů 'dojde až na pity'. Pity tedy není drobná pojistka, je to hlavní mechanika.

35.3.3 Krach hráče

Příklad 35.3.3 Hráč má k žetonů a v každém kole vyhraje žeton s pravděpodobností p, nebo prohraje žeton s pravděpodobností $q = 1 - p$. Hraje, dokud nezbankrotuje, nebo nemá N žetonů. Nechť P_k je pravděpodobnost, že dosáhne N. Podmíněním podle prvního kola

$$P_k = pP_{k+1} + qP_{k-1}, \qquad P_0 = 0, \quad P_N = 1.$$

Je to lineární rekurence. Charakteristická rovnice $p\lambda^2 - \lambda + q = 0$ má kořeny 1 a $\frac{q}{p}$, takže pro $p \neq q$

$$P_k = \frac{(q/p)^k - 1}{(q/p)^N - 1},$$

a pro férovou hru $p = q$ vyjde $P_k = \frac{k}{N}$. Ruleta s jednou nulou má pro sázku na barvu $p = \frac{18}{37}$. Kdo má 50 žetonů a chce je zdvojnásobit sázkami po jednom žetonu, uspěje s pravděpodobností jen asi 6,3 %. Kdo vsadí všech 50 najednou, uspěje s pravděpodobností $\frac{18}{37} \approx 48{,}6\,\%$. V nevýhodné hře je nejlepší hrát co nejkratší dobu.

35.3.4 Proč náhoda nepůsobí náhodně

Hráči si často stěžují, že náhoda ve hře je 'rozbitá'. Většinou není, jen lidská intuice čeká víc pravidelnosti, než náhoda dává. Ve 100 hodech mincí je s pravděpodobností asi 80 % někde aspoň šest stejných výsledků za sebou. Zamícháte-li playlist 20 písní od 5 interpretů (po čtyřech), dvě sousední pozice mají stejného interpreta s pravděpodobností $\frac{3}{19}$ (druhá píseň je jedna z 19 zbývajících a 3 z nich jsou od stejného interpreta). Sousedních dvojic je 19, takže v průměru budou v playlistu *tři* dvojice písní téhož interpreta za sebou. Spotify proto svůj shuffle záměrně upravil, aby byl *méně* náhodný a působil náhodněji. Hry dělají totéž: v některých se šance na kritický zásah po každém neúspěchu zvyšuje, aby se omezily dlouhé série smůly.

Lineární kongruenční generátor (LCG) vytváří pseudonáhodná čísla předpisem

$$x_{n+1} = (ax_n + c) \bmod m.$$

Podle **Hullovy–Dobellovy věty** má (pro $c \neq 0$) plnou periodu m, právě když c je nesoudělné s m, $a - 1$ je dělitelné každým prvočíslem dělícím m a $a - 1$ je dělitelné 4, pokud $4 \mid m$.

Příklad 35.3.4 Pro $m = 16$, $a = 5$, $c = 3$ a $x_0 = 7$ dostaneme

$$7,\ 6,\ 1,\ 8,\ 11,\ 10,\ 5,\ 12,\ 15,\ 14,\ 9,\ 0,\ 3,\ 2,\ 13,\ 4,\ 7,\ \ldots$$

Perioda je plná, 16. Ale podívejte se na paritu: lichá, sudá, lichá, sudá… Nejnižší bit má periodu 2. Proto se u LCG nikdy nepoužívají nejnižší bity, třeba přes `rand() % 2`.

Slavný odstrašující případ je generátor RANDU z 60. let s $a = 65\,539 = 2^{16} + 3$ a $m = 2^{31}$. Protože $a^2 = 2^{32} + 6 \cdot 2^{16} + 9 \equiv 6a - 9 \pmod{2^{31}}$, platí $x_{n+2} = 6x_{n+1} - 9x_n \pmod{2^{31}}$. Každá trojice po sobě jdoucích čísel tak leží v jedné z pouhých 15 rovin v krychli. Moderní hry používají lepší generátory (např. PCG nebo xorshift), ale princip 'deterministický vzorec, který jen vypadá náhodně' zůstává. Stejné semínko dá stejný svět, na čemž stojí procedurálně generované hry a přehrávání záznamů.

Poznámka 35.3.5 Míchání balíčku: **Fisherův–Yatesův algoritmus** prochází pozice $i = n-1, \dots, 1$ a prohodí prvek na pozici i s náhodnou pozicí $j \in \{0, \dots, i\}$. Má $n \cdot (n-1) \cdots 2 = n!$ stejně pravděpodobných průběhů, každý vede k jiné permutaci, takže všechny permutace jsou stejně pravděpodobné. Častá chyba je volit j vždy z celého rozsahu $\{0, \dots, n-1\}$. Pak je průběhů n^n, a protože n^n obecně není dělitelné $n!$ (pro $n = 3$: 27 není dělitelné 6), některé permutace musí padat častěji. Pro $n = 3$ padnou tři permutace s pravděpodobností $\frac{5}{27}$ a tři s pravděpodobností $\frac{4}{27}$.

35.4 Matematika pro vývojáře her: vektory

35.4.1 Skalární součin: vidí mě?

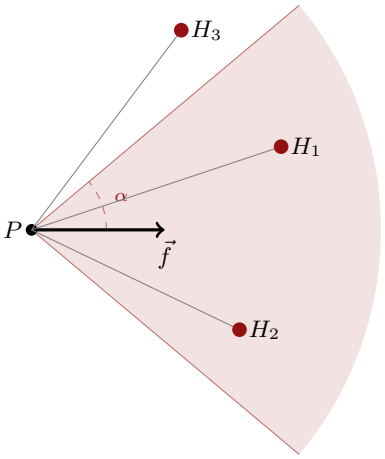
Skalární součin z kapitoly 16 je nejpoužívanější operace v herní grafice:

$$\vec{u} \cdot \vec{v} = u_x v_x + u_y v_y + u_z v_z = |\vec{u}||\vec{v}| \cos \varphi.$$

Levá strana je levná (tři násobení), pravá strana obsahuje úhel. Nepřítel stojící v bodě P s pohledem ve směru jednotkového vektoru $\vec{f}$ vidí hráče v bodě H, pokud je hráč v jeho **zorném kuželu** s poloviční úhlem α:

$$\vec{f} \cdot \frac{H - P}{|H - P|} \geq \cos \alpha.$$

Žádný arkus kosinus, $\cos \alpha$ se spočítá jednou dopředu.



H_1: vidí, vlevo ($\vec{f} \times \vec{d} > 0$)

H_2: vidí, vpravo ($\vec{f} \times \vec{d} < 0$)

H_3: nevidí, $\cos \varphi = 0{,}6 < \cos 40°$

35.4.2 Vektorový součin: vlevo, nebo vpravo?

Ve 2D se z vektorového součinu stane jediné číslo, třetí složka

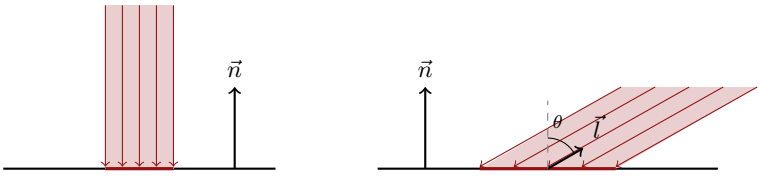
$$\vec{f} \times \vec{d} = f_x d_y - f_y d_x = |\vec{f}||\vec{d}| \sin \varphi.$$

Je kladné, pokud je $\vec{d}$ *nalevo* od $\vec{f}$ (proti směru hodinových ručiček), a záporné, pokud napravo. Podle znaménka se věžička rozhodne, kterým směrem se otočit. Na obrázku je $\vec{f} = (1, 0)$, takže $\vec{f} \times \vec{d} = d_y$: hráč $H_1 = [3, 1]$ je vlevo, $H_2 = [2{,}5; -1{,}2]$ vpravo a $H_3 = [1{,}8; 2{,}4]$ s $\cos \varphi = \frac{1{,}8}{3} = 0{,}6 < \cos 40° \approx 0{,}77$ je mimo zorné pole.

Ve 3D vektorový součin dvou hran trojúhelníku $\vec{n} = (B - A) \times (C - A)$ dává **normálu**, vektor kolmý na trojúhelník. Její směr závisí na pořadí vrcholů. Enginy proto ukládají vrcholy v pevném pořadí (třeba proti směru ručiček při pohledu zvenku) a trojúhelníky, jejichž normála míří od kamery, vůbec nekreslí (*back-face culling*). Tím se ušetří zhruba polovina práce.

35.4.3 Osvětlení: Lambertův kosinový zákon

Proč je povrch natočený ke světlu jasnější? Svazek paprsků o šířce w dopadá na plochu pod úhlem θ od normály a rozprostře se na šířku $\frac{w}{\cos\theta}$. Stejné množství světla připadá na větší plochu, takže osvětlení klesá s faktorem $\cos\theta$.



šířka w, plný jas — $\theta = 60°$: šířka $\frac{w}{\cos\theta} = 2w$, poloviční jas

Lambertovo (difúzní) osvětlení: s jednotkovou normálou $\vec{n}$ a jednotkovým směrem ke světlu $\vec{l}$ je jas povrchu

$$I = I_{\text{světla}} \cdot \rho \cdot \max(0, \vec{n} \cdot \vec{l}),$$

kde ρ je barva (odrazivost) materiálu. Maximum s nulou zajistí, že plochy odvrácené od světla nejsou ‘záporně osvětlené’.

Tento řádek kódu běží v pixel shaderu pro každý pixel na obrazovce, dnes miliardkrát za sekundu.

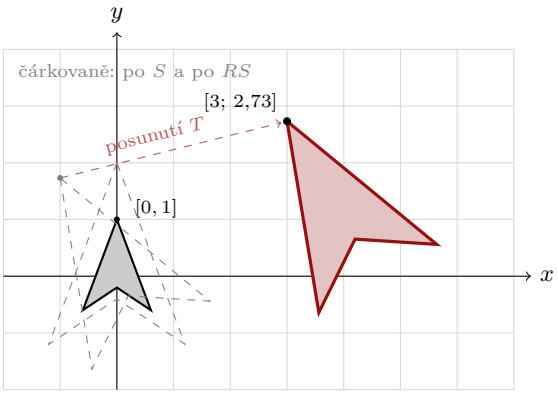
35.5 Matematika pro vývojáře her: transformace

35.5.1 Homogenní souřadnice

Otočení a změna měřítka jsou lineární zobrazení z kapitoly 27, takže je zapíšeme maticí. Posunutí ale lineární není (počátek se nezobrazí na počátek). Trik: k bodu $[x, y]$ přidáme třetí souřadnici 1. Pak i posunutí je násobení maticí:

$$T = \begin{pmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{pmatrix}, \quad R = \begin{pmatrix} \cos\varphi & -\sin\varphi & 0 \\ \sin\varphi & \cos\varphi & 0 \\ 0 & 0 & 1 \end{pmatrix}, \quad S = \begin{pmatrix} s & 0 & 0 \\ 0 & s & 0 \\ 0 & 0 & 1 \end{pmatrix}, \quad T \begin{pmatrix} x \\ y \\ 1 \end{pmatrix} = \begin{pmatrix} x + t_x \\ y + t_y \\ 1 \end{pmatrix}.$$

Celou transformaci sprajtu (obrázku postavičky) lze spojit do jediné **modelové matice** $M = TRS$. Bod se nejdřív zvětší, pak otočí kolem počátku a nakonec posune. Pořadí je důležité, protože násobení matic není komutativní: $RT \neq TR$. Kdybychom nejdřív posunuli a pak otočili, sprajt by obíhal kolem počátku jako planeta.



Příklad 35.5.1 Špička sprajtu $[0, 1]$, měřítko $s = 2$, otočení o 30°, posunutí o $(4, 1)$. Po S: $[0, 2]$. Po R: $[-2\sin 30°, 2\cos 30°] = [-1;\ 1{,}732]$. Po T: $[3;\ 2{,}732]$. Přesně tam leží špička tmavého sprajtu na obrázku. V praxi se ale matice $M = TRS$ spočítá jen jednou a pak se jí násobí všechny vrcholy.

Ve 3D se používají matice 4×4 a čtvrtá souřadnice má ještě jednu roli. Perspektivní projekce vydělí body jejich vzdáleností od kamery, a právě to dělení ‘schované’ ve čtvrté souřadnici dělá ze vzdálených věcí malé věci.

35.5.2 Otočení ve 3D: Eulerovy úhly a kvaterniony

Nejpřirozenější popis orientace ve 3D jsou tři **Eulerovy úhly**: otočení kolem svislé osy (yaw), náklon nahoru a dolů (pitch) a náklon do strany (roll). Mají ale vadu, které se říká **gimbal lock**. Pokud je pitch přesně 90° (letadlo míří kolmo nahoru), osa yaw a osa roll splynou. Oba úhly pak dělají totéž a jeden stupeň volnosti se ztratí. Animace, která prochází blízko takové polohy, se začne nečekaně točit. Astronauti Apolla se gimbal locku inerciální plošiny báli a Michael Collins během letu Apolla 11 prý žertem požádal, ať mu k Vánocům pošlou čtvrtý kardanový závěs.

Řešením jsou **kvaterniony**, rozšíření komplexních čísel z kapitoly 22 o tři imaginární jednotky i, j, k s pravidly $i^2 = j^2 = k^2 = ijk = -1$. Otočení o úhel θ kolem jednotkové osy $\vec{n}$ je kvaternion

$$q = \cos\frac{\theta}{2} + \sin\frac{\theta}{2}\,(n_x i + n_y j + n_z k),$$

a vektor $\vec{v}$ (zapsaný jako $v_x i + v_y j + v_z k$) se otočí na $q\vec{v}q^{-1}$. Kvaternion má jen čtyři čísla místo devíti v matici, skládání otočení je násobení kvaternionů, gimbal lock neexistuje a mezi dvěma orientacemi lze plynule interpolovat po ‘nejkratší cestě’ (tzv. slerp). Proč vzorec otáčí a proč obsahuje poloviční úhel, uvidíme v odbočce.

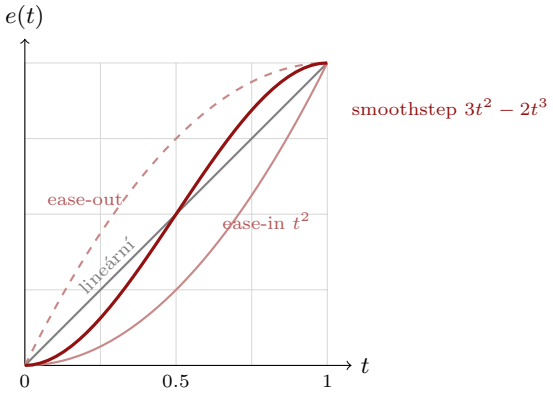
35.6 Matematika pro vývojáře her: křivky a pohyb

35.6.1 Lerp a easing

Lineární interpolace (lerp) mezi hodnotami a a b s parametrem $t \in [0,1]$:

$$\operatorname{lerp}(a,b,t) = a + t(b-a) = (1-t)a + tb.$$

Easing funkce je funkce $e\colon [0,1] \to [0,1]$ s $e(0) = 0$, $e(1) = 1$, kterou vložíme mezi čas a interpolaci: $\operatorname{lerp}(a,b,e(t))$.



Lineární pohyb působí roboticky: objekt se rozjede a zastaví okamžitě. Funkce **smoothstep** $3t^2 - 2t^3$ má v obou koncích nulovou derivaci ($6t - 6t^2 = 0$ pro $t = 0, 1$), takže objekt plynule zrychlí a plynule zabrzdí. Ease-in t^2 startuje pomalu, ease-out $1 - (1-t)^2$ pomalu končí.

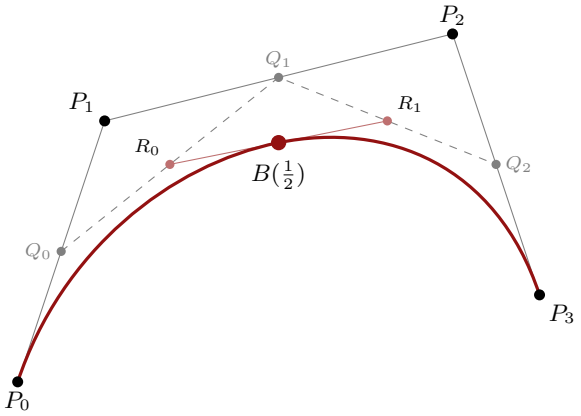
Poznámka 35.6.1 Oblíbený řádek `x = lerp(x, cíl, 0.1)` volaný každý snímek způsobí, že vzdálenost od cíle se každý snímek zmenší na 0,9násobek. Je to geometrická posloupnost, tedy exponenciální přibližování. Háček: při 120 snímcích za sekundu se kamera přiblíží dvakrát rychleji než při 60. Správná, na snímkové frekvenci nezávislá verze je `x = lerp(x, cíl, 1 - exp(-k*dt))`, kde `dt` je délka snímku. Po čase t pak zbývá vzdálenost e^{-kt}-násobná, ať je snímků kolik chce.

35.6.2 Bézierovy křivky

Kubická Bézierova křivka s řídicími body P_0, P_1, P_2, P_3:

$$B(t) = (1-t)^3 P_0 + 3(1-t)^2 t\, P_1 + 3(1-t)t^2\, P_2 + t^3 P_3, \qquad t \in [0,1].$$

Algoritmus de Casteljau: bod $B(t)$ dostaneme opakovaným lerpem. Z $P_0P_1P_2P_3$ uděláme $Q_i = \mathrm{lerp}(P_i, P_{i+1}, t)$, z nich $R_i = \mathrm{lerp}(Q_i, Q_{i+1}, t)$ a nakonec $B(t) = \mathrm{lerp}(R_0, R_1, t)$.



Příklad 35.6.2 Pro $P_0 = [0,0]$, $P_1 = [1,3]$, $P_2 = [5,4]$, $P_3 = [6,1]$ a $t = \frac{1}{2}$ jsou lerpy prostě středy úseček:

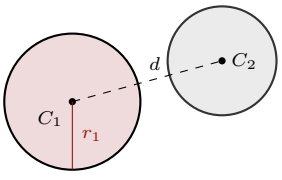
$$\begin{aligned} Q_0 &= [0{,}5;\ 1{,}5], & Q_1 &= [3;\ 3{,}5], & Q_2 &= [5{,}5;\ 2{,}5], \\ R_0 &= [1{,}75;\ 2{,}5], & R_1 &= [4{,}25;\ 3], & B(\tfrac{1}{2}) &= [3;\ 2{,}75]. \end{aligned}$$

Kontrola vzorcem: $B(\frac{1}{2}) = \frac{1}{8}(P_0 + 3P_1 + 3P_2 + P_3) = \frac{1}{8}[0+3+15+6,\ 0+9+12+1] = [3;\ 2{,}75]$.

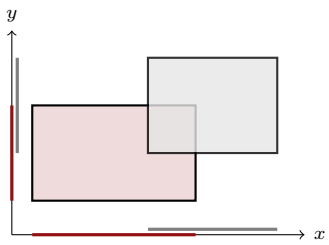
Koeficienty $(1-t)^3$, $3(1-t)^2 t$, … jsou členy binomického rozvoje $\big((1-t)+t\big)^3 = 1$, takže jejich součet je vždy 1 a křivka leží v konvexním obalu řídicích bodů. Křivka začíná v P_0 ve směru P_1 a končí v P_3 ve směru od P_2. Proto se s ní v editorech tak dobře pracuje. Bézierovy křivky kreslí písmo, cesty kamer, dráhy projektilů i tento obrázek: TikZ příkaz `.. controls ..` je přesně kubický Bézier.

35.7 Matematika pro vývojáře her: kolize

Kolize se testují tisíckrát za snímek, takže se používají co nejjednodušší tvary.



kolize $\iff$ $d^2 \le (r_1 + r_2)^2$

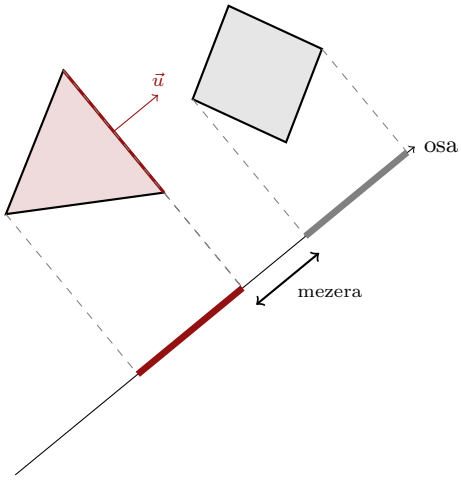


překryv v x i v y $\Rightarrow$ kolize

Dva kruhy se srážejí, právě když je vzdálenost středů nejvýš součet poloměrů. Porovnáváme druhé mocniny, $(x_1-x_2)^2 + (y_1-y_2)^2 \le (r_1+r_2)^2$, abychom nemuseli počítat odmocninu. **Obdélníky rovnoběžné s osami** (AABB, *axis-aligned bounding box*) se srážejí, právě když se překrývají jejich průměty na osu x *i* na osu y. To jsou čtyři porovnání: $a_{\min} \le b_{\max}$ a $b_{\min} \le a_{\max}$ pro obě osy.

Pro otočené tvary tento trik zobecňuje věta o oddělující ose.

Věta o oddělující ose (SAT): Dva konvexní mnohoúhelníky jsou disjunktní, právě když existuje přímka (osa), na kterou se promítnou do dvou disjunktních intervalů. Stačí přitom vyzkoušet normály všech hran obou mnohoúhelníků.



Důkaz. (náznak) Jsou-li průměty disjunktní, tvary jsou zjevně disjunktní. Opačně: dva disjunktní konvexní mnohoúhelníky mají dvojici nejbližších bodů X, Y. Kolmice na XY procházející středem XY je odděluje, protože kdyby některý tvar zasahoval přes ni, z konvexity by v něm byl bod bližší druhému tvaru. Průměty na osu ve směru XY jsou pak disjunktní. U mnohoúhelníků navíc oddělující přímku můžeme posouvat a natáčet, dokud se neopře o celou hranu jednoho z tvarů. Ta přímka je pak rovnoběžná s hranou a osa na ni kolmá je normálou hrany. Proto stačí zkoušet normály hran. ■

Na obrázku je oddělující osa kolmá na tmavou hranu trojúhelníku. Průměty obou tvarů jsou disjunktní intervaly, takže kolize nenastala. Pro trojúhelník a čtyřúhelník je hran sedm, a tedy nejvýš sedm testů. Kdyby se intervaly překrývaly na všech sedmi osách, tvary by se srážely, a nejmenší překryv navíc říká, jakým směrem a o kolik je od sebe odstrčit.

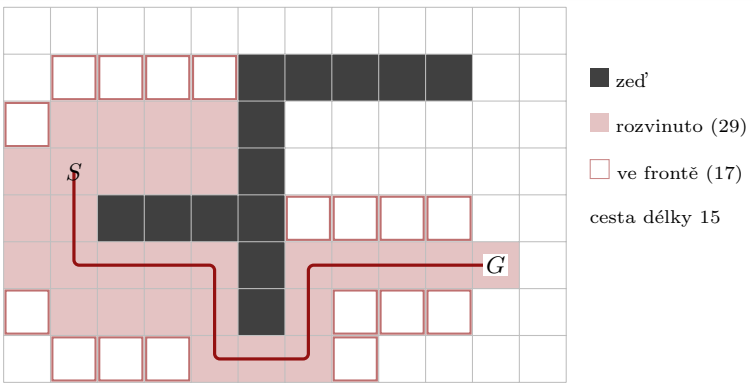
35.8 Matematika pro vývojáře her: hledání cesty

Postavička má dojít z bodu S do bodu G na mřížce s překážkami. Mřížka je graf: políčka jsou vrcholy, sousední volná políčka jsou spojena hranou délky 1.

Algoritmus A* udržuje pro každé políčko n délku $g(n)$ nejkratší dosud nalezené cesty ze startu a **heuristický odhad** $h(n)$ zbývající vzdálenosti do cíle. Vždy rozvine (prozkoumá) políčko s nejmenší hodnotou

$$f(n) = g(n) + h(n).$$

Pokud heuristika nikdy nepřecení skutečnou vzdálenost (je **přípustná**), najde A* nejkratší cestu. Pro pohyb ve čtyřech směrech je přípustná **manhattanská vzdálenost** $h(n) = |x_n - x_G| + |y_n - y_G|$.



Obrázek je skutečný výsledek A* s manhattanskou heuristikou (při shodě f dává přednost políčkům blíž k cíli). Algoritmus nejdřív zkusí jít přímo doprava, narazí na zeď a obejde ji spodní mezerou. Rozvine 29 políček. **Dijkstrův algoritmus**, tedy A* s $h = 0$, se na stejné mapě rozlévá všemi směry stejně a před nalezením cíle rozvine 70 políček. Obě metody najdou cestu stejné délky 15.

Důkaz. (optimality A* pro konzistentní heuristiku) Heuristika je **konzistentní**, pokud $h(n) \le 1 + h(m)$ pro sousední políčka n, m a $h(G) = 0$ (manhattanská vzdálenost to splňuje, krok změní h nejvýš o 1). Podél libovolné cesty pak $f = g + h$ neklesá: krok zvýší g o 1 a sníží h nejvýš o 1. A* proto rozvíjí políčka v neklesajícím pořadí f, a když poprvé rozvine políčko, zná k němu už nejkratší cestu. Speciálně v okamžiku, kdy rozvine G, je $g(G) = f(G)$ délka nejkratší cesty. ■

35.9 Matematika pro vývojáře her: šum a fyzika

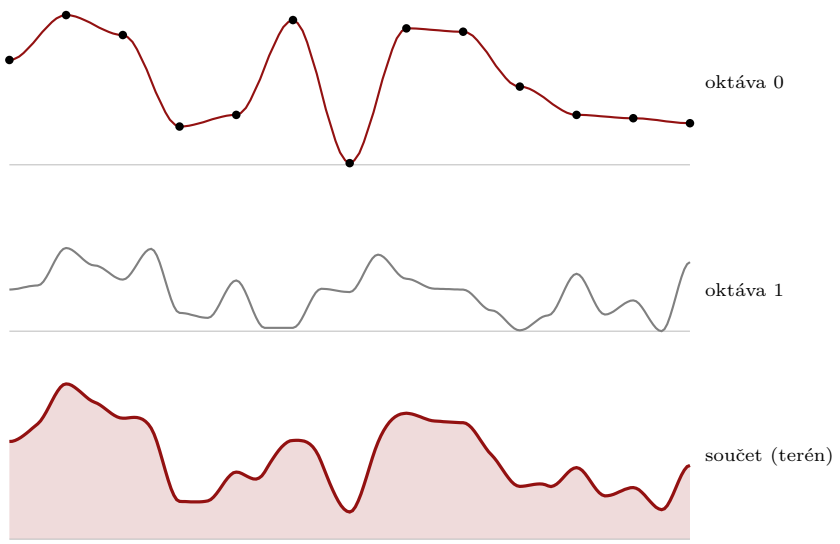
35.9.1 Procedurální generování: šum

Krajiny v Minecraftu, mraky, oheň nebo třesení kamery potřebují ‘náhodu’, která je *hladká*. Obyčejná náhodná čísla vedle sebe skáčou. Řešením je **šum**. Nejjednodušší je **hodnotový šum**: v celých číslech zvolíme náhodné hodnoty a mezi nimi interpolujeme hladce, s parametrem prohnaným přes smoothstep:

$$n(x) = \operatorname{lerp}\big(v_{\lfloor x \rfloor},\ v_{\lfloor x \rfloor + 1},\ \operatorname{smoothstep}(x - \lfloor x \rfloor)\big).$$

Jedna vrstva vypadá jako mírné kopce. Skutečné terény jsou ale ‘zubaté na všech měřítkách’. Proto sečteme několik **oktáv**: k-tá oktáva má dvojnásobnou frekvenci a poloviční amplitudu než předchozí,

$$N(x) = \sum_{k=0}^{K} \frac{1}{2^k}\, n_k(2^k x).$$



Ken Perlin vymyslel vylepšenou verzi, **gradientní šum**, po práci na filmu Tron (1982). V mřížových bodech nevolí náhodné hodnoty, ale náhodné *sklony*, takže šum nemá tendenci vytvářet hrboly přesně v celých číslech. V roce 1997 za něj dostal technického Oscara. Všimněte si, že ‘náhodné’ hodnoty v_i pocházejí z generátoru se semínkem, takže stejné semínko dá vždy stejnou krajinu, a svět nemusí být uložen na disku.

35.9.2 Fyzika: Eulerova metoda a únik energie

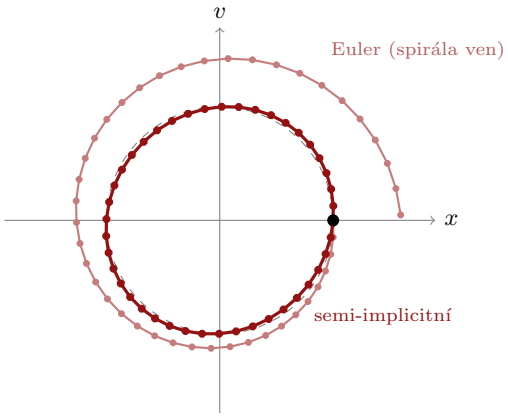
Herní fyzika řeší Newtonovu rovnici $\ddot{x} = F/m$ z kapitoly 31 po krocích délky h (typicky $h = \frac{1}{60}$ s). Nejjednodušší je **Eulerova metoda**: novou polohu spočítáme se starou rychlostí. Skoro stejně jednoduchá je **semi-implicitní Eulerova metoda**: nejdřív aktualizujeme rychlost a polohu posuneme už s *novou* rychlostí.

$$\text{Euler: } \begin{cases} x_{n+1} = x_n + h v_n, \\ v_{n+1} = v_n + h a(x_n), \end{cases} \qquad \text{semi-implicitní: } \begin{cases} v_{n+1} = v_n + h a(x_n), \\ x_{n+1} = x_n + h v_{n+1}. \end{cases}$$

Příklad 35.9.1 Pružina $a(x) = -x$, tedy přesné řešení $x = \cos t$, $v = -\sin t$, s energií $E = \frac{1}{2}(x^2 + v^2)$. Pro obyčejného Eulera

$$x_{n+1}^2 + v_{n+1}^2 = (x_n + hv_n)^2 + (v_n - hx_n)^2 = (1 + h^2)(x_n^2 + v_n^2).$$

Energie roste každý krok $(1 + h^2)$-krát, exponenciálně! Pro $h = 0{,}15$ se po jedné periodě (42 kroků) zvětší $1{,}0225^{42} \approx 2{,}5$krát. Semi-implicitní metoda má matici kroku $\begin{pmatrix} 1 - h^2 & h \\ -h & 1 \end{pmatrix}$ s determinantem 1, zachovává tedy plochu ve fázové rovině, a přesně zachovává ‘skoro energii’ $x^2 + v^2 - hxv$. Skutečná energie jen nepatrně kmitá a nikam neutíká.



čárkovaně přesné řešení, $h = 0{,}15$, 42 kroků

Ve hře to znamená, že s obyčejným Eulerem se kyvadlo rozhoupe samo od sebe a planety odletí ze soustavy. Semi-implicitní Euler (v knihovnách často nazývaný *symplektický*) stojí stejně mnoho výpočtů, a proto ho používá většina herních fyzikálních enginů. Druhé pravidlo praxe: fyzika běží s **pevným krokem** h, nezávisle na snímkové frekvenci. Jinak by výsledek simulace závisel na tom, jak rychlý má hráč počítač.

35.10 Odbočka — Proč kvaterniony otáčejí

Kvaternion $a + bi + cj + dk$ zapíšeme jako dvojici: reálnou část a a vektor $\vec{u} = (b, c, d)$. Z pravidel $i^2 = j^2 = k^2 = ijk = -1$ plyne $ij = k = -ji$, $jk = i = -kj$, $ki = j = -ik$ a po roznásobení dostaneme kompaktní vzorec pro součin

$$(a, \vec{u})(b, \vec{w}) = \big(ab - \vec{u} \cdot \vec{w},\ a\vec{w} + b\vec{u} + \vec{u} \times \vec{w}\big).$$

Uvnitř násobení kvaternionů se tedy skrývá skalární i vektorový součin zároveň. (Historicky je to dokonce naopak, skalární a vektorový součin se z kvaternionů ‘oddělily’ až později.) Speciálně pro dva čistě imaginární kvaterniony $(0, \vec{u})(0, \vec{w}) = (-\vec{u} \cdot \vec{w},\ \vec{u} \times \vec{w})$.

Nechť $q = (c, s\vec{n})$, kde $c = \cos\frac{\theta}{2}$, $s = \sin\frac{\theta}{2}$ a $|\vec{n}| = 1$. Pak $|q| = 1$ a $q^{-1} = \bar{q} = (c, -s\vec{n})$. Vektor $\vec{v}$ rozložíme na složku rovnoběžnou s osou a kolmou k ose, $\vec{v} = \vec{v}_\parallel + \vec{v}_\perp$.

- **Rovnoběžná složka** $\vec{v}_\parallel = \lambda\vec{n}$: vektorový součin $\vec{n} \times \vec{n} = 0$, takže q a $\vec{v}_\parallel$ komutují a $q\vec{v}_\parallel\bar{q} = \vec{v}_\parallel q\bar{q} = \vec{v}_\parallel$. Osa se nehýbe.
- **Kolmá složka**: protože $\vec{n} \cdot \vec{v}_\perp = 0$, ze vzorce plyne $\vec{n}\vec{v}_\perp = \vec{n} \times \vec{v}_\perp = -\vec{v}_\perp\vec{n}$. Kolmý vektor tedy s $\vec{n}$ *antikomutuje*, a proto

  $$\vec{v}_\perp\bar{q} = \vec{v}_\perp(c - s\vec{n}) = (c + s\vec{n})\vec{v}_\perp = q\vec{v}_\perp, \qquad \text{tedy} \qquad q\vec{v}_\perp\bar{q} = q^2\vec{v}_\perp.$$

  A $q^2 = (c^2 - s^2,\ 2cs\,\vec{n}) = (\cos\theta,\ \sin\theta\,\vec{n})$, takže

  $$q\vec{v}_\perp\bar{q} = \cos\theta\,\vec{v}_\perp + \sin\theta\,(\vec{n} \times \vec{v}_\perp).$$

To je přesně otočení vektoru $\vec{v}_\perp$ o úhel θ v rovině kolmé na $\vec{n}$: vektory $\vec{v}_\perp$ a $\vec{n} \times \vec{v}_\perp$ jsou kolmé, stejně dlouhé a tvoří v té rovině ‘osy x a y’. Odtud i poloviční úhel: kvaternion q působí na vektor dvakrát, zleva a zprava, a v kolmé rovině se obě poloviny sečtou na celé θ. Vedlejší důsledek: q a $-q$ dávají stejné otočení. Kvaterniony popisují každou orientaci dvakrát, což je důvod, proč slerp musí občas q otočit na $-q$, aby šel kratší cestou.

35.11 Příběh — Krásná mysl

John Forbes Nash přišel v roce 1948 na Princeton s doporučujícím dopisem, který měl prý jedinou větu: ‘Tento muž je génius.’ Za dva roky obhájil disertaci o nekooperativních hrách. Měla jen pár desítek stran a obsahovala pojem, kterému dnes říkáme Nashova rovnováha. Během následujících let dokázal zásadní a velmi těžké věty o vnořování variet a o parciálních diferenciálních rovnicích, a vypadal jako jeden z nejslibnějších matematiků své generace.

Na konci 50. let u něj propukla paranoidní schizofrenie. Věřil, že mu mimozemšťané posílají zakódované zprávy v novinách, a strávil řadu pobytů v psychiatrických léčebnách, kde podstoupil i léčbu inzulinovými šoky. Kolega se ho později zeptal, jak mohl on, muž rozumu, uvěřit mimozemšťanům. Nash odpověděl, že nápady o nadpřirozených bytostech k němu přicházely stejně jako ty matematické, a tak je bral vážně. Celá desetiletí bloudil po princetonském kampusu jako ‘fantom z Fine Hall’ a psal na tabule podivné číselné vzkazy. Jeho žena Alicia se s ním v roce 1963 rozvedla, ale v roce 1970 si ho vzala zpátky k sobě do domu a starala se o něj.

V 80. letech nemoc postupně ustoupila. V roce 1994 dostal Nash Nobelovu cenu za ekonomii (spolu s Johnem Harsanyim a Reinhardem Seltenem), a to právě za práci z disertace. Kniha Sylvie Nasar a film *Čistá duše* (v originále *A Beautiful Mind*) z roku 2001 z něj udělaly celebritu. S Aliciou se v roce 2001 znovu vzali.

V květnu 2015 převzal Nash v Norsku Abelovu cenu, nejvyšší ocenění v matematice, spolu s Louisem Nirenbergem za práci o parciálních diferenciálních rovnicích. Po návratu jeli s Aliciou z letiště taxíkem domů. Na dálnici v New Jersey taxík narazil do svodidel a oba manželé, kteří nebyli připoutaní, z auta vypadli a na místě zemřeli. Johnovi bylo osmdesát šest, Alicii osmdesát dva.

35.12 Shrnutí a otázky

Cvičení 35.12.1 Vypočítejte:

(a) Kdo vyhraje Nim s hromádkami 1, 5, 7, 9 a jakým tahem?

(b) Nepřítel v bodě $[0,0]$ se dívá ve směru $\vec{f} = (0{,}6;\ 0{,}8)$, poloviční zorný úhel je $60°$. Vidí hráče v bodě $[4,-1]$? Je hráč vlevo, nebo vpravo?

(c) Jaký je průměrný počet pokusů do úspěchu se šancí 2 % a s tvrdou pity na 50. pokusu? (Stačí vzorec.)

Řešení 35.12.1

(a) $0001 \oplus 0101 \oplus 0111 \oplus 1001 = 1010 = 10 \neq 0$, vyhrává hráč na tahu. Nejvyšší jednička součtu je v řádu 8, má ji jen hromádka 9, a $9 \oplus 10 = 3$. Z hromádky 9 tedy nechá 3: $1 \oplus 5 \oplus 7 \oplus 3 = 0$.

(b) $\vec{d} = (4,-1)$, $|\vec{d}| = \sqrt{17}$, $\vec{f} \cdot \vec{d} = 2{,}4 - 0{,}8 = 1{,}6$, $\cos\varphi = \frac{1{,}6}{\sqrt{17}} \approx 0{,}39 < \cos 60° = 0{,}5$. Nevidí. $\vec{f} \times \vec{d} = 0{,}6 \cdot (-1) - 0{,}8 \cdot 4 = -3{,}8 < 0$, hráč je vpravo.

(c) $E = \sum_{k=0}^{49} 0{,}98^k = \frac{1-0{,}98^{50}}{0{,}02} \approx \frac{1-0{,}364}{0{,}02} \approx 31{,}8$.

Cvičení 35.12.2 Odpovězte vlastními slovy:

1. Co je Nashova rovnováha a proč ve vězňově dilematu nevede k nejlepšímu výsledku?
2. Proč je jedinou rovnováhou kamene, nůžek a papíru strategie $\frac{1}{3}$, $\frac{1}{3}$, $\frac{1}{3}$?
3. Jak se hraje Nim a proč funguje strategie ‘táhni na nulový XOR’?
4. Vysvětlete argument krádeže strategie na hře Chomp. Proč nám neřekne, jak vyhrát?
5. Proč je průměrný počet pokusů do úspěchu $\frac{1}{p}$ a jak ho změní pity systém?
6. Jak skalární součin rozhodne, jestli nepřítel vidí hráče, a jak vektorový součin, jestli je vlevo?
7. K čemu jsou homogenní souřadnice a proč záleží na pořadí TRS?

8. Popište algoritmus de Casteljau. Proč Bézierova křivka leží v konvexním obalu řídicích bodů?
9. Proč A* s přípustnou heuristikou najde nejkratší cestu a proč bývá rychlejší než Dijkstrův algoritmus?
10. Proč obyčejná Eulerova metoda přidává energii a čím je lepší semi-implicitní varianta?

Kapitola 36

Kryptografie

Nikdo dosud neobjevil žádný válečný účel, kterému by mohla sloužit teorie čísel nebo relativita, a zdá se velmi nepravděpodobné, že by se to v příštích mnoha letech podařilo.

G. H. Hardy, *Obrana matematikova*, 1940

Hardy byl hrdý na to, že jeho obor je zcela neužitečný. Mýlil se dvakrát. Pět let po vydání jeho knihy dopadly na Japonsko atomové bomby, a o další tři desetiletí později se teorie čísel stala páteří vojenské i civilní komunikace. Pokaždé, když zaplatíte kartou na internetu, odemknete telefon nebo pošlete zprávu, běží na pozadí malá Fermatova věta z kapitoly 28.

Kryptografie je umění poslat zprávu tak, aby jí rozuměl jen adresát. V této kapitole projdeme cestu od římských šifer, které rozluští každý desetiletý, přes Enigmu až k šifrování s veřejným klíčem, které funguje, i když se odesílatel s adresátem nikdy neviděli. Ukážeme také, proč to funguje, tedy dokážeme to.

36.1 Klasické šifry

Terminologie: zprávě, kterou chceme utajit, říkáme **otevřený text**, zašifrované podobě **šifrový text**. Postup závisí na **klíči**, tajemství, které znají jen odesílatel a příjemce.

36.1.1 Caesarova šifra

Podle Suetonia psal Julius Caesar důvěrné dopisy tak, že každé písmeno nahradil písmenem o tři místa dál v abecedě. Ztotožníme-li písmena s čísly $A = 0$, $B = 1$, …, $Z = 25$, je to obyčejné sčítání modulo 26:

$$E(x) = x + k \bmod 26, \qquad D(y) = y - k \bmod 26.$$

Fyzicky se šifra realizuje dvěma kotouči s abecedou, vnitřní pootočený o k míst.



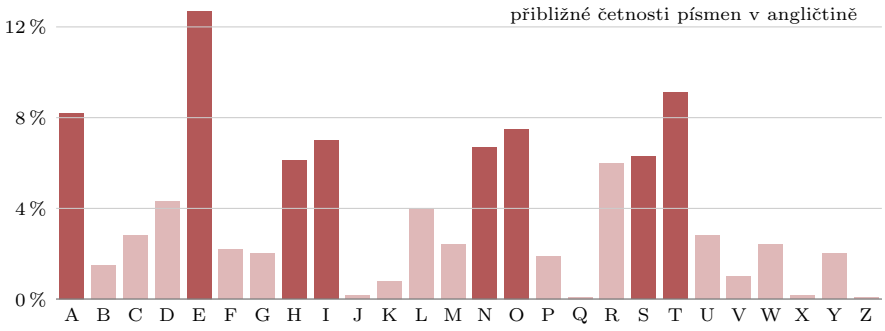

```
VENI VIDI VICI
↓ +3
YHQL YLGL YLFL
```

Klíčů je jen 25. Útočník je prostě všechny vyzkouší.

36.1.2 Substituční šifra a frekvenční analýza

Místo posunu můžeme abecedu libovolně *zamíchat*: $A \to Q$, $B \to W$, ... Klíčem je permutace 26 písmen, a těch je podle kapitoly 19 $26! \approx 4 \cdot 10^{26}$. Kdyby útočník zkoušel miliardu klíčů za sekundu, trvalo by mu to přes deset miliard let. A přesto tuto šifru luští luštitelé křížovek v novinách.

Trik popsal arabský učenec al-Kindí už v 9. století. V přirozeném jazyce nejsou písmena stejně častá. Substituce sice písmena přejmenuje, ale jejich četnosti zachová. Nejčastější písmeno šifrového textu je tedy nejspíš obraz nejčastějšího písmene jazyka.



V angličtině vede E (asi 12,7 %), pak T, A, O, I, N. V češtině je nejčastější O, pak E, A, N (a háčky situaci komplikují jen trochu). Kromě jednotlivých písmen pomáhají i dvojice: v angličtině je nejčastější TH, a za Q skoro vždy následuje U. Delší zprávu tak lze rozluštit tužkou a papírem za pár hodin.

36.1.3 Vigenèrova šifra

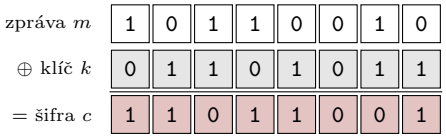
Obranou proti frekvenční analýze je použít *více* Caesarových šifer střídavě. Klíčem je slovo, třeba `KLIC`, a jeho písmena udávají posuny $10, 11, 8, 2$, které se opakují dokola.



Písmeno Z se jednou zašifrovalo na J, podruhé na K, a A na L i na C. Četnosti se rozmazaly. Šifra se tři sta let považovala za nerozluštitelnou, ‘le chiffre indéchiffrable’. (Mimochodem ji poprvé popsal Giovan Battista Bellaso v roce 1553, Vigenère dostal jméno omylem.) Její slabinou je ale opakování klíče. Zjistíme-li jeho délku L, rozpadne se šifrový text na L obyčejných Caesarových šifer, každou z nich rozluštíme frekvenční analýzou. Délku klíče prozradí opakující se úseky šifry. Tuto metodu našel Charles Babbage kolem roku 1854 (nepublikoval ji) a nezávisle Friedrich Kasiski, který ji v roce 1863 vydal.

36.2 Dokonalá šifra: jednorázová tabulka

Co kdyby byl klíč stejně dlouhý jako zpráva, zcela náhodný a použitý jen jednou? V počítači pracujeme s bity a místo sčítání modulo 26 použijeme sčítání modulo 2, operaci **XOR** ($\oplus$): $0 \oplus 0 = 1 \oplus 1 = 0$, $0 \oplus 1 = 1 \oplus 0 = 1$.



dešifrování:
$c \oplus k = m \oplus k \oplus k = m$,
protože $k \oplus k = 0$

Věta (Shannon, 1949): Je-li klíč $k \in \{0,1\}^n$ zvolen rovnoměrně náhodně a nezávisle na zprávě, pak šifrový text $c = m \oplus k$ neprozradí o zprávě m vůbec nic: pro každou zprávu m a každý šifrový text c je

$$P(C = c \mid M = m) = 2^{-n}.$$

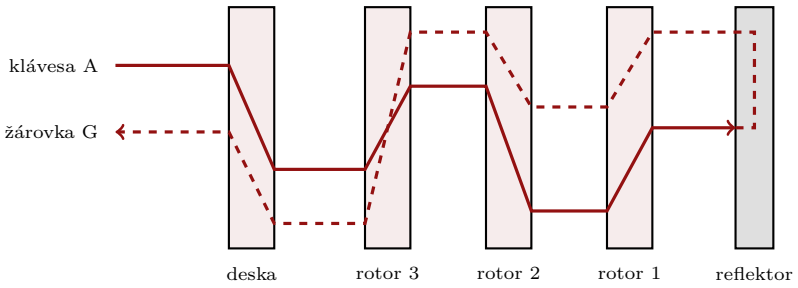
Rozložení šifrového textu je tedy stejné, ať byla poslána jakákoli zpráva.

Důkaz. Pro dané m a c existuje právě jeden klíč, který m převede na c, totiž $k = m \oplus c$. Ten byl zvolen s pravděpodobností 2^{-n}. ■

Intuitivně: daný šifrový text mohl stejně dobře vzniknout ze zprávy `ANO` jako ze zprávy `NE!`, jen s jiným klíčem. Útočník s neomezeným výpočetním výkonem je na tom stejně jako bez něj. Háček je praktický. Klíč musí být stejně dlouhý jako všechny zprávy dohromady a doručený předem, třeba diplomatickou poštou. A nikdy se nesmí použít dvakrát: z $c_1 = m_1 \oplus k$ a $c_2 = m_2 \oplus k$ dostane útočník $c_1 \oplus c_2 = m_1 \oplus m_2$, a z toho se oba texty dají vyluštit. Přesně to se stalo Sovětskému svazu ve 40. letech. Kvůli nedostatku materiálu se část tabulek vytiskla dvakrát a americký projekt Venona díky tomu přečetl tisíce zpráv sovětských zpravodajců.

36.3 Enigma a Kerckhoffsův princip

Ve 20. letech 20. století začala německá armáda používat **Enigmu**, elektromechanický stroj se třemi otočnými **rotory**. Stisk klávesy pustil proud přes propojovací desku (která prohodila několik dvojic písmen), přes tři rotory, odrazil se v **reflektoru** a vrátil se jinou cestou zpět, až rozsvítil žárovku se šifrovým písmenem. Po každém stisku se rychlý rotor pootočil o jedno místo, takže se šifrování měnilo s každým písmenem. Je to Vigenère s neuvěřitelně dlouhým klíčem.



Reflektor měl elegantní vedlejší účinek: stejné nastavení šifruje i dešifruje, protože cesta proudu je vratná. A měl i fatální slabinu: **žádné písmeno se nikdy nezašifruje samo na sebe** (proud se nemůže vrátit stejným drátem, kterým přišel). Počet všech nastavení armádní Enigmy s deseti kabely na desce je přibližně $1{,}59 \cdot 10^{20}$. Hrubou silou to v roce 1940 nešlo. Šlo to chytrostí a matematikou, jak uvidíme v příběhu na konci kapitoly.

Kerckhoffsův princip (1883): Šifrovací systém musí zůstat bezpečný, i když nepřítel zná vše kromě klíče.

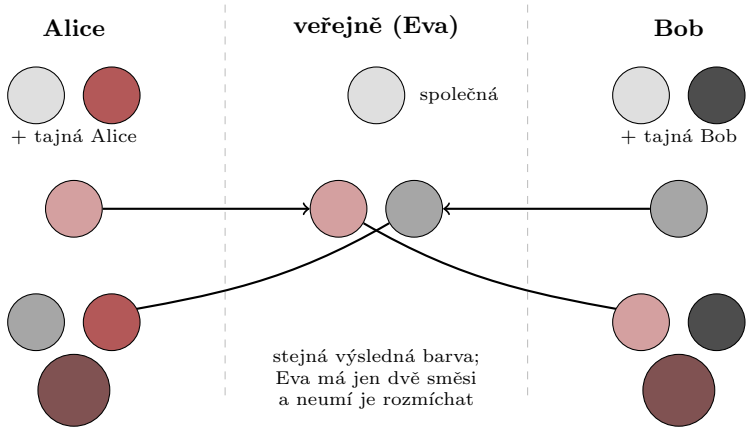
Spojenci znali konstrukci Enigmy (polští matematici ji zrekonstruovali už v roce 1932), a na tajemství stroje tedy nebylo možné spoléhat. Moderní šifry jako AES jsou proto veřejné, roky je zkoumají tisíce odborníků a tajný je jen klíč. Firma, která tvrdí, že má ‘vlastní tajný šifrovací algoritmus’, vám tím obvykle říká, že ho nikdo neprověřil.

36.4 Šifrování s veřejným klíčem

Všechny dosavadní šifry jsou **symetrické**: kdo umí šifrovat, umí i dešifrovat. Odesílatel a příjemce se proto musí předem dohodnout na klíči. Jak to ale udělat s e-shopem na druhém konci světa, když jediný kanál, který máte, je odposlouchávaný internet? Dlouho se zdálo, že to nejde. V roce 1976 Whitfield Diffie a Martin Hellman ukázali, že ano.

36.4.1 Diffie–Hellman: míchání barev

Představte si, že Alice a Bob chtějí získat společnou barvu, kterou Eva, která vidí všechno, co si pošlou, nezná. Barvy se snadno míchají, ale směs se nedá rozdělit zpět na složky.

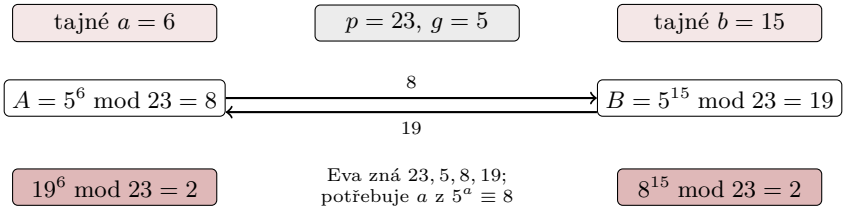


Obě strany do výsledné barvy přimíchaly společnou barvu, tajnou barvu Alice i tajnou barvu Boba, jen v jiném pořadí. Matematicky potřebujeme operaci, která se snadno provede, ale těžko vrací, a ve které nezáleží na pořadí. Tou je umocňování modulo prvočíslo.

Protokol Diffie–Hellman: Veřejně se zvolí velké prvočíslo p a číslo g.

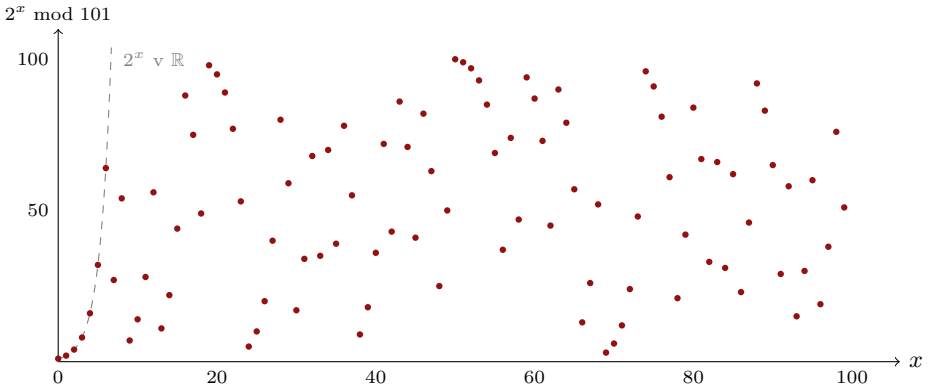
1. Alice si tajně zvolí a a pošle $A = g^a \bmod p$. Bob si tajně zvolí b a pošle $B = g^b \bmod p$.
2. Alice spočítá B^a, Bob spočítá A^b. Oba dostanou stejný **sdílený klíč**

$$s = B^a = (g^b)^a = g^{ab} = (g^a)^b = A^b \pmod p.$$



36.4.2 Diskrétní logaritmus

Eva by potřebovala vyřešit rovnici $g^a \equiv A \pmod p$, tedy spočítat **diskrétní logaritmus** a. Pro reálná čísla je logaritmus snadný, protože 2^x je rostoucí funkce a stačí ‘půlit interval’. Modulo prvočíslo ale mocniny skáčou chaoticky. Na grafu je $2^x \bmod 101$ pro $x = 0, 1, \ldots, 99$. Z hodnoty se o exponentu nedá nic vyčíst.



Umocňovat je přitom rychlé i pro tisícimístné exponenty: **opakovaným umocňováním na druhou** spočítáme $g^2, g^4, g^8, \ldots$ a vynásobíme ty, které odpovídají jedničkám ve dvojkovém zápisu exponentu. Na g^{1000} stačí asi patnáct násobení. Pro opačný směr nikdo nezná algoritmus, který by byl pro p s 600 ciframi rychlejší než miliardy let. Takovým funkcím říkáme **jednosměrné**.

36.5 RSA

Diffie–Hellman umožní dohodnout klíč. V roce 1977 přišli Ron Rivest, Adi Shamir a Leonard Adleman s něčím ještě silnějším: **veřejným klíčem**. Představte si visací zámky. Bob jich rozdá tisíce, zaklapnout je umí každý, ale klíček k nim má jen on. Kdokoli mu tak může poslat zamčenou zprávu, aniž by se předtím domlouvali.

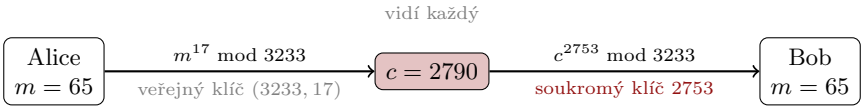
RSA:

1. Bob zvolí dvě velká prvočísla p, q a spočítá $n = pq$ a $\varphi(n) = (p-1)(q-1)$.
2. Zvolí e nesoudělné s $\varphi(n)$ a Eukleidovým algoritmem najde d s $ed \equiv 1 \pmod{\varphi(n)}$.
3. **Veřejný klíč** je (n, e), **soukromý klíč** je d. Čísla p, q, $\varphi(n)$ zahodí.

Šifrování zprávy $0 \le m < n$: $c = m^e \bmod n$. Dešifrování: $m = c^d \bmod n$.

Příklad 36.5.1 $p = 61$, $q = 53$, tedy $n = 3233$ a $\varphi(n) = 60 \cdot 52 = 3120$. Zvolíme $e = 17$. Rozšířený Eukleidův algoritmus dá $d = 2753$; zkouška: $17 \cdot 2753 = 46\,801 = 15 \cdot 3120 + 1$. Alice chce poslat $m = 65$:

$$c = 65^{17} \bmod 3233 = 2790, \qquad 2790^{2753} \bmod 3233 = 65.$$



Důkaz. (správnosti RSA) Máme ukázat $m^{ed} \equiv m \pmod{n}$. Protože $ed = 1 + k(p-1)(q-1)$, platí modulo p: je-li $p \mid m$, jsou obě strany nula. Jinak podle malé Fermatovy věty

$$m^{ed} = m \cdot \left(m^{p-1}\right)^{k(q-1)} \equiv m \cdot 1 = m \pmod{p}.$$

Stejně $m^{ed} \equiv m \pmod{q}$. Číslo $m^{ed} - m$ je tedy dělitelné p i q, a tím i $n = pq$ (čínská věta o zbytcích z kapitoly 28). ■

Proč je to bezpečné? Útočník zná n a e. Kdyby znal $\varphi(n)$, spočítal by d stejně jako Bob. Jenže zjistit $\varphi(n)$ je stejně těžké jako rozložit n na $p \cdot q$. Násobit umíme okamžitě, rozkládat ne. Největší rozložené číslo typu RSA, RSA-250 s 250 ciframi (829 bitů), padlo v únoru 2020 po výpočtu, který by na jednom procesorovém jádru trval asi 2700 let. Dnes se běžně používá n s 2048 bity, tedy 617 ciframi.

Zajímavost: stejný systém objevil už v roce 1973 Clifford Cocks z britské zpravodajské služby GCHQ. Byl ale přísně tajný a svět se o něm dozvěděl až v roce 1997.

36.5.1 Digitální podpis

RSA funguje i obráceně. Bob ‘zašifruje’ zprávu svým *soukromým* klíčem, $s = m^d \bmod n$, a pošle m i s. Kdokoli ověří veřejným klíčem, že $s^e \equiv m$. Podpis s mohl vyrobit jen ten, kdo zná d. V našem příkladu je podpis zprávy 65 číslo $s = 65^{2753} \bmod 3233 = 588$ a skutečně $588^{17} \bmod 3233 = 65$. V praxi se nepodepisuje celá zpráva, ale její otisk, hash.

36.6 Hashovací funkce

Kryptografická hashovací funkce h přiřadí libovolně dlouhým datům krátký otisk pevné délky (například 256 bitů u SHA-256) tak, že

- z otisku $h(x)$ nelze prakticky najít x (jednosměrnost),
- nelze prakticky najít dvě různá $x \neq y$ s $h(x) = h(y)$ (odolnost vůči kolizím),

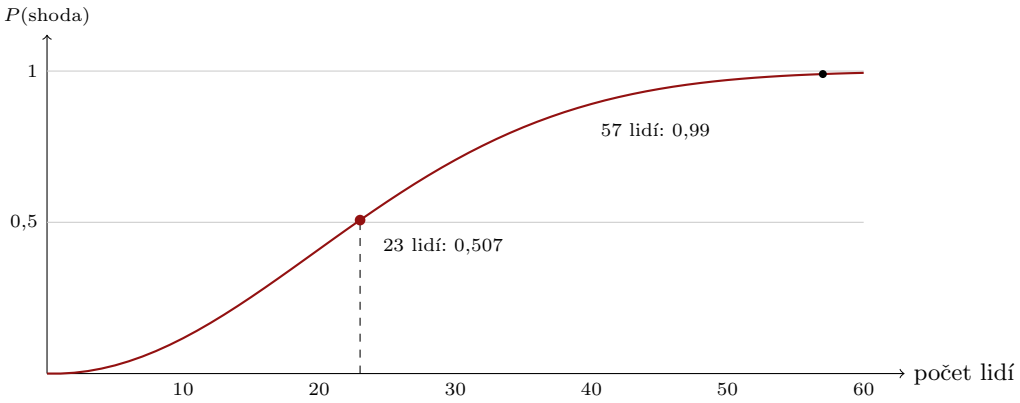
- malá změna vstupu změní otisk k nepoznání (**lavinový efekt**).

Příklad 36.6.1 `SHA-256("matematika") = 2bbdbedf819c7eab...1941dc08`
`SHA-256("Matematika") = fa67515751f6297f...3d547de2`
Jediné velké písmeno a z 256 bitů se jich změnilo 131, tedy zhruba polovina, jak by se čekalo u náhodných čísel.

36.6.1 Narozeninový paradox

Kolizí musí existovat nekonečně mnoho, protože dat je víc než otisků. Kolik pokusů útočník potřebuje, než nějakou najde? V kapitole 20 jsme spočítali, že mezi 23 lidmi mají dva narozeniny ve stejný den s pravděpodobností přes polovinu:

$$1 - \frac{365}{365} \cdot \frac{364}{365} \cdots \frac{343}{365} \approx 0{,}507.$$



Párů lidí je totiž $\binom{23}{2} = 253$, a každý pár má šanci $\frac{1}{365}$. Obecně: mezi N možnostmi čekáme první shodu po zhruba $\sqrt{N}$ pokusech. Pro 256bitový hash je to $2^{128} \approx 3 \cdot 10^{38}$ pokusů, což je bezpečné. Pro starou funkci SHA-1 se 160 bity a matematickými slabinami to bylo málo: v roce 2017 předvedli výzkumníci z Googlu a CWI Amsterdam dva různé PDF soubory se stejným otiskem.

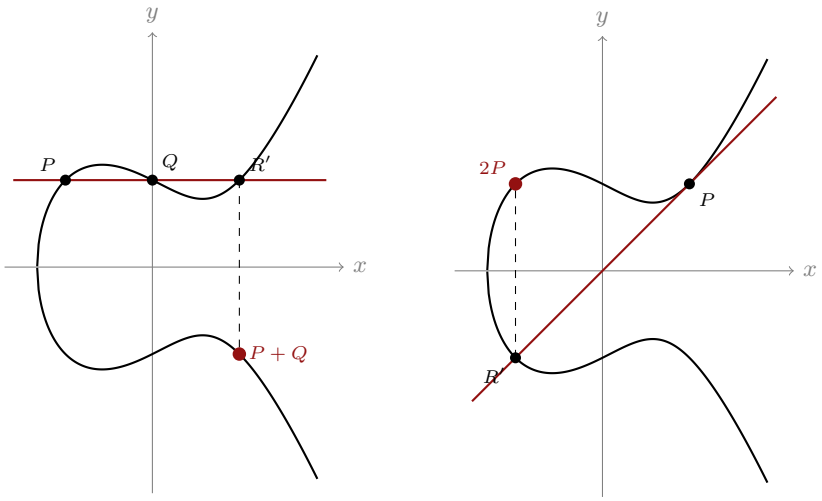
36.6.2 Hesla a sůl

Slušný server nikdy neukládá vaše heslo, jen jeho hash. Při přihlášení zahashuje, co jste napsali, a porovná. Když databázi někdo ukradne, hesla přímo nevidí. Může ale předem zahashovat milion nejčastějších hesel a hledat shody, a stejná hesla mají stejný otisk. Proto se ke každému heslu přidá náhodná **sůl**, uložená vedle: ukládá se $(r,\ h(r \,\|\, \text{heslo}))$. Předpočítané tabulky jsou pak k ničemu a útočník musí lámat každé heslo zvlášť. Navíc se používají záměrně pomalé funkce (bcrypt, Argon2), aby jeden pokus trval zlomek sekundy místo nanosekundy. Když v roce 2012 unikla z LinkedInu hesla uložená jako nesolené otisky SHA-1, velkou část z nich útočníci rozluštili během několika dní.

36.7 Eliptické křivky

Diffie–Hellman funguje v libovolné struktuře, kde se dá ‘násobit’ a kde je diskrétní logaritmus těžký. Nejlepší dnes známá taková struktura pochází z geometrie.

Eliptická křivka je množina bodů $[x, y]$ s $y^2 = x^3 + ax + b$ (kde $4a^3 + 27b^2 \neq 0$) spolu se zvláštním ‘bodem v nekonečnu’ O. Body se **sčítají** takto: přímka bodů P, Q protne křivku ve třetím bodě R'; jeho obraz v souměrnosti podle osy x je $P + Q$. Pro $P = Q$ použijeme tečnu.



$y^2 = x^3 - x + 1$ tečna v P

Ověřme obrázek. Vlevo: body $P = [-1, 1]$ a $Q = [0, 1]$ leží na přímce $y = 1$. Dosazením do rovnice křivky $1 = x^3 - x + 1$, tedy $x(x-1)(x+1) = 0$, a třetí průsečík je $R' = [1, 1]$. Proto $P + Q = [1, -1]$. Vpravo: v bodě $P = [1, 1]$ má křivka (implicitní derivací $2yy' = 3x^2 - 1$) směrnici $y' = 1$, tečna je $y = x$. Dosazením $x^2 = x^3 - x + 1$, tedy $(x-1)^2(x+1) = 0$. Dvojnásobný kořen $x = 1$ je bod dotyku, třetí průsečík je $R' = [-1, -1]$, a tedy $2P = [-1, 1]$.

Obecně pro $P = [x_1, y_1]$, $Q = [x_2, y_2]$ se směrnicí $\lambda = \frac{y_2 - y_1}{x_2 - x_1}$ (u tečny $\lambda = \frac{3x_1^2 + a}{2y_1}$) vyjde

$$x_3 = \lambda^2 - x_1 - x_2, \qquad y_3 = \lambda(x_1 - x_3) - y_1.$$

Tyto vzorce dávají smysl i modulo prvočíslo p, kde už žádný obrázek není, jen konečná množina bodů. Sčítání je komutativní a (což je překvapivě pracné ověřit) asociativní. Místo g^a počítáme $aP = P + P + \cdots + P$ a diskrétní logaritmus je úloha: ze známých P a aP najít a. Pro eliptické křivky neznáme ani triky, které pomáhají modulo p, a tak stačí mnohem kratší klíče. Klíč s 256 bity na eliptické křivce odpovídá zhruba 3072bitovému RSA. Proto dnes eliptické křivky šifrují většinu webu i zpráv v telefonech.

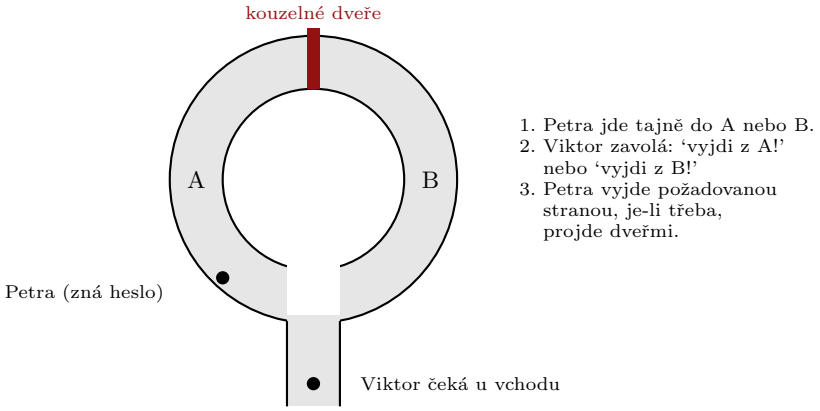
36.8 Kvantová hrozba

V roce 1994 Peter Shor ukázal, že **kvantový počítač** by uměl rozkládat čísla i počítat diskrétní logaritmy rychle, v čase, který roste jen jako polynom v počtu cifer. Klíčová myšlenka: rozklad n se dá převést na hledání periody funkce $x \mapsto a^x \bmod n$, tedy čísla r s $a^r \equiv 1$. A periody kvantový počítač najde pomocí kvantové Fourierovy transformace, příbuzné Fourierových řad z kapitoly 29. Najdeme-li sudé r, je $(a^{r/2} - 1)(a^{r/2} + 1) \equiv 0 \pmod n$ a $\mathrm{NSD}(a^{r/2} - 1, n)$ je často netriviální dělitel n.

Dosud postavené kvantové počítače jsou na to příliš malé a nepřesné. Data zašifrovaná dnes se ale dají uložit a rozluštit za dvacet let. Proto americký úřad NIST v roce 2024 standardizoval první **postkvantové** algoritmy, většinou založené na těžkých úlohách s mřížemi, na které Shorův algoritmus nestačí.

36.9 Odbočka — Důkaz s nulovou znalostí

Jde dokázat, že něco vím, a přitom o tom nic neprozradit? Třeba že znám heslo, aniž bych ho řekl? Zní to jako paradox. Klasické vysvětlení (Quisquater a kol., 1989) používá jeskyni Ali Baby.



Jeskyně má tvar okruhu a v jeho nejzazším místě jsou dveře, které otevře jen heslo. Kdo heslo zná, vyjde vždy tou stranou, kterou Viktor chce. Kdo ho nezná, musel na začátku hádat a uspěje s pravděpodobností $\frac{1}{2}$. Po 20 kolech je šance podvodníka $2^{-20} < 10^{-6}$. Viktor je přesvědčen.

A přitom se nedozvěděl nic, co by nevěděl sám. Celý záznam ('zavolal jsem A, vyšla z A, zavolal jsem B, vyšla z B, ...') by si mohl vyrobit i bez Petry, třeba domluvou s hercem, který se vždy předem dozví, co Viktor zavolá. Záznam tedy nikoho třetího nepřesvědčí. Přesvědčivá je jen *interakce*, ve které Viktor volí náhodně až *po* Petřině kroku. Tohle je přesná definice nulové znalosti: vše, co ověřovatel vidí, by si dokázal nasimulovat sám.

Matematická verze. Petra zná x s $y = g^x \bmod p$ (číslo y je veřejné). V každém kole:

1. Petra zvolí náhodné r a pošle $t = g^r \bmod p$ ('vejde do jeskyně').
2. Viktor zvolí náhodně bit $c \in \{0, 1\}$ ('zavolá stranu').
3. Petra pošle $z = r + cx$ a Viktor ověří $g^z \equiv t \cdot y^c \pmod p$.

Pro $c = 0$ Petra jen ukáže r, což o x nic neříká. Pro $c = 1$ ukáže $r + x$, což je kvůli náhodnému r také jen náhodné číslo. Kdo x nezná, umí připravit odpověď jen na jednu z otázek, přesně jako v jeskyni. Takové protokoly dnes umožňují třeba prokázat, že je vám přes 18 let, bez ukázání data narození.

Cvičení 36.9.1

(a) Rozluštěte Caesarovu šifru `PDWHPDWLND` (posun neznáte).

(b) RSA s $p = 5$, $q = 11$, $e = 3$: spočítejte n, $\varphi(n)$, d a zašifrujte $m = 7$.

(c) Diffie–Hellman s $p = 11$, $g = 2$, $a = 3$, $b = 4$: jaký je sdílený klíč?

(d) Kolik pokusů zhruba potřebuje útočník na nalezení kolize 64bitového hashe?

(e) Proč u jednorázové tabulky nesmíme použít klíč dvakrát?

Řešení 36.9.1

(a) Posun 3: `MATEMATIKA`. Stačí vyzkoušet všech 25 posunů. Rychleji: nejčastější písmeno `D` je nejspíš `A` nebo `E`, a posun 3 dává smysl.

(b) $n = 55$, $\varphi(n) = 40$, $d = 27$ ($3 \cdot 27 = 81 = 2 \cdot 40 + 1$). $c = 7^3 = 343 = 6 \cdot 55 + 13$, tedy $c = 13$. Zkouška: $13^{27} \bmod 55 = 7$.

(c) $A = 2^3 = 8$, $B = 2^4 = 16 \equiv 5$. Klíč $B^a = 5^3 = 125 \equiv 4$, a také $A^b = 8^4 = 4096 \equiv 4 \pmod{11}$.

(d) Asi $\sqrt{2^{64}} = 2^{32} \approx 4 \cdot 10^9$, to zvládne notebook.

(e) Protože $c_1 \oplus c_2 = m_1 \oplus m_2$: klíč zmizí a zbude 'součet' dvou zpráv, který se dá luštit statisticky.

36.10 Příběh — Jablko u postele

Alan Turing se narodil v roce 1912 v Londýně. Ve čtyřiadvaceti letech napsal článek o ‘vyčíslitelných číslech’, v němž popsal abstraktní stroj, který čte a píše symboly na nekonečnou pásku. Dnes mu říkáme Turingův stroj a je to matematický model každého počítače, včetně toho, na kterém byla vysázena tato kniha.

Den poté, co Británie v září 1939 vyhlásila Německu válku, nastoupil do Bletchley Park, tajného britského luštitelského centra. Navázal na práci polských matematiků Mariana Rejewského, Jerzyho Różyckého a Henryka Zygalského, kteří Enigmu luštili už od roku 1932 a v červenci 1939, pár týdnů před německým útokem na Polsko, předali své poznatky Britům a Francouzům. Turing navrhl elektromechanický stroj zvaný *bomba*, který rychle procházel nastavení rotorů a vyřazoval ta, která byla ve sporu s uhodnutým kouskem textu. Využíval přitom i slabinu reflektoru: písmeno se nikdy nezašifruje samo na sebe, takže uhodnuté slovo nemůže ležet na místě, kde by se s šifrou v nějakém písmeni shodovalo. Turing pak vedl tým Hut 8, který luštil šifry německého námořnictva, a s nimi zprávy ponorek, jež potápěly konvoje v Atlantiku. Historik Harry Hinsley, který sám v Bletchley Park pracoval, odhadoval, že luštění zkrátilo válku o dva až čtyři roky.

Po válce navrhl jeden z prvních elektronických počítačů s uloženým programem a v roce 1950 se v článku zeptal, zda stroje mohou myslet. Jeho test, při kterém člověk konverzuje se strojem a má poznat, že to není člověk, se dodnes jmenuje po něm. Vše, co dělal za války, ale zůstalo přísně tajné.

V lednu 1952 se mu vloupali do domu v Manchesteru. Turing krádež nahlásil a při vyšetřování přiznal, že má vztah s mužem. Homosexualita byla tehdy v Británii trestná. Byl obviněn z ‘hrubé neslušnosti’ a odsouzen. Místo vězení zvolil hormonální ‘léčbu’ syntetickým estrogenem, tedy chemickou kastraci, která trvala rok. Přišel o bezpečnostní prověrku a nesměl dál pracovat pro tajné služby.

Sedmého června 1954 zemřel na otravu kyanidem, bylo mu jednačtyřicet. Úřední vyšetřování konstatovalo sebevraždu. U postele leželo napůl snědené jablko. Předpokládá se, že kyanid byl v něm, ale jablko nikdy nikdo neotestoval. Jeho matka věřila, že šlo o nehodu při chemických pokusech, které doma prováděl.

V roce 2009 se za ‘otřesné zacházení’ s Turingem veřejně omluvil britský premiér Gordon Brown. V roce 2013 mu královna Alžběta II. udělila posmrtnou milost. Od roku 2021 je jeho portrét na britské padesátilibrové bankovce. Hardy, který si myslel, že teorie čísel nikdy nebude sloužit válce, zemřel v roce 1947 a o Bletchley Park se nikdy nedozvěděl. Celý příběh zůstal utajený až do 70. let.

36.11 Shrnutí a otázky

Cvičení 36.11.1 Odpovězte vlastními slovy:

1. Proč je substituční šifra s 26! klíči slabá? Jak funguje frekvenční analýza?
2. V čem je Vigenèrova šifra lepší než Caesarova a jak se luští?
3. Proč je jednorázová tabulka dokonale bezpečná a proč se přesto běžně nepoužívá?
4. Co říká Kerckhoffsův princip? Jakou slabinu měl reflektor Enigmy?
5. Vysvětlete Diffie–Hellmanův protokol pomocí barev a pomocí mocnin modulo p.
6. Co je diskrétní logaritmus a proč je jeho výpočet těžký?
7. Popište generování klíčů v RSA a dokažte, že dešifrování vrátí původní zprávu.
8. Jak funguje digitální podpis?
9. Co je lavinový efekt a jak souvisí narozeninový paradox s kolizemi hashů? K čemu je sůl?
10. Jak se sčítají body na eliptické křivce a proč je kvantový počítač hrozbou pro RSA?

Kapitola 37

Strojové učení a umělá inteligence

Všechny modely jsou špatně, ale některé jsou užitečné.

George E. P. Box

Když vám telefon navrhne další slovo zprávy, když banka zablokuje podezřelou platbu nebo když chatbot napíše báseň o integrálech, nestojí za tím žádná magie, ale matematika, kterou už skoro celou znáte. Derivace z kapitoly 24, gradient z kapitoly 30, matice a vlastní vektory z kapitoly 27, pravděpodobnost z kapitoly 20 a skalární součin z kapitoly 14. V této kapitole uvidíme, jak se z těchto kousků skládá **strojové učení**: obor, ve kterém počítač nedostane přesný postup, ale příklady, a postup si z nich 'vypočítá' sám. Budeme se snažit o poctivost: ukážeme, co tyto metody umějí, proč fungují, a také kde končí.

37.1 Co znamená 'učit se z dat'

Začněme úplně obyčejně. Máme tabulku bytů: plocha, patro, stáří domu, vzdálenost od metra, a cena. Chceme odhadnout cenu bytu, který v tabulce není. Každý byt je pro nás **bod** $\vec{x} \in \mathbb{R}^n$ (zde $n = 4$) a k němu známe číslo y, cenu. Obrázek s rozlišením 28×28 pixelů je bod v $\mathbb{R}^{784}$ a jeho y je třeba číslice, kterou zobrazuje. Data jsou tedy prostě hromada bodů v (často obrovsky vysokorozměrném) prostoru.

Učení s učitelem: Máme **trénovací data** $(\vec{x}_1, y_1), \dots, (\vec{x}_N, y_N)$. **Model** je funkce $f_{\vec{w}}(\vec{x})$, která závisí na **parametrech** $\vec{w}$ (vahách). **Ztrátová funkce** $\ell(f_{\vec{w}}(\vec{x}), y)$ měří, jak moc se předpověď mýlí, a **učení** je hledání vah, které minimalizují průměrnou ztrátu

$$L(\vec{w}) = \frac{1}{N} \sum_{i=1}^{N} \ell\big(f_{\vec{w}}(\vec{x}_i), y_i\big).$$

V téhle definici je schovaná celá filozofie oboru. 'Učení' je *optimalizace*: hledáme minimum funkce mnoha proměnných, přesně jako v kapitole 30. Jenže skutečný cíl je jiný. Nechceme dobře předpovídat byty, které už známe, ale ty, které jsme ještě neviděli. K tomuto rozporu se vrátíme v sekci o přeučení.

37.2 Lineární regrese

Nejjednodušší model: y závisí na x lineárně, $f(x) = ax + b$. Jak najít 'nejlepší' přímku procházející mrakem bodů? Přímka body většinou přesně neprotne. Rozdílům $r_i = y_i - (ax_i + b)$ říkáme **rezidua**.

Metoda nejmenších čtverců: Za nejlepší přímku považujeme tu, která minimalizuje součet čtverců reziduí

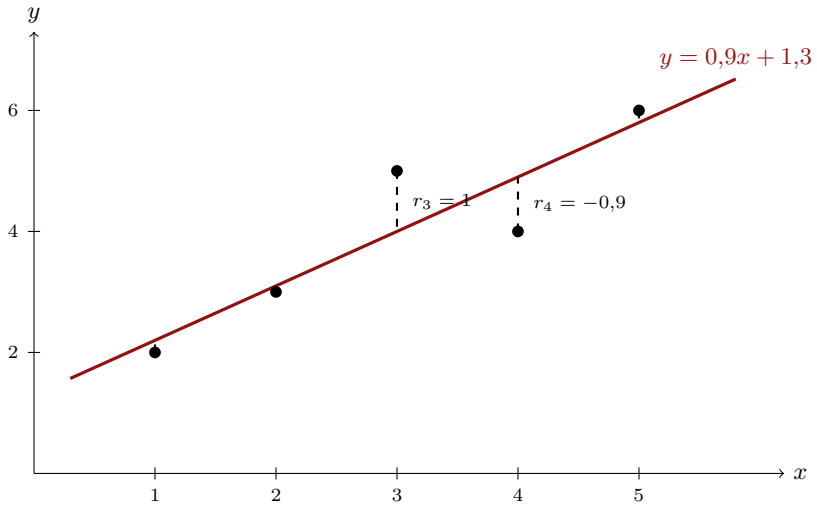
$$S(a, b) = \sum_{i=1}^{N} \big(y_i - ax_i - b\big)^2.$$

Proč čtverce, a ne třeba absolutní hodnoty? Čtverce se dají derivovat, velké chyby trestají víc než malé, a hlavně z nich vyjde krásná geometrie, jak hned uvidíme. (Navíc, pokud jsou chyby měření normálně rozdělené, je to přesně ta nejpravděpodobnější přímka.)

Příklad 37.2.1 Data: $[1,2]$, $[2,3]$, $[3,5]$, $[4,4]$, $[5,6]$. Minimum funkce $S(a,b)$ hledáme jako v kapitole 30: obě parciální derivace položíme rovny nule,

$$\frac{\partial S}{\partial b} = -2\sum(y_i - ax_i - b) = 0 \qquad \Longrightarrow \quad a\sum x_i + bN = \sum y_i,$$
$$\frac{\partial S}{\partial a} = -2\sum x_i(y_i - ax_i - b) = 0 \qquad \Longrightarrow \quad a\sum x_i^2 + b\sum x_i = \sum x_i y_i.$$

Spočítáme $N=5$, $\sum x_i = 15$, $\sum y_i = 20$, $\sum x_i^2 = 55$, $\sum x_i y_i = 2+6+15+16+30 = 69$. Soustava $15a+5b=20$, $55a+15b=69$ má řešení $a=0{,}9$, $b=1{,}3$. Nejlepší přímka je $y=0{,}9x+1{,}3$. Rezidua jsou $-0{,}2$; $-0{,}1$; 1; $-0{,}9$; $0{,}2$ a jejich součet je (jak vyžaduje první rovnice) přesně nula. Minimální součet čtverců je $S=1{,}9$.



Čárkované úsečky jsou rezidua. Minimalizujeme součet čtverců jejich délek. Všimněte si, že měříme svisle, ne kolmo k přímce: chyba je v y, ne v x.

37.2.1 Maticový zápis a projekce

Pro více proměnných se počítání po složkách stane nepřehledným. Zapišme data maticově. Řádky matice X jsou jednotlivé body (s jedničkou navíc kvůli absolutnímu členu), $\vec{y}$ je sloupec výsledků a $\vec{w}$ sloupec vah:

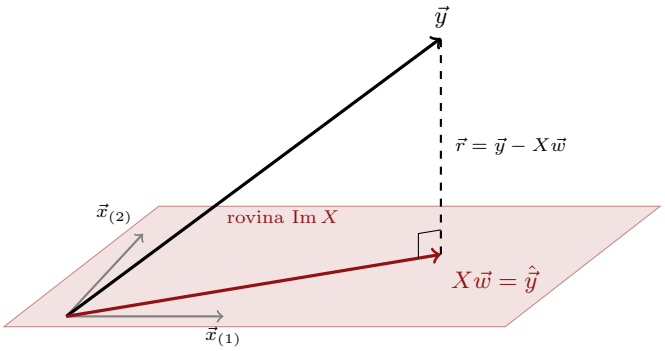
$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \qquad \vec{y} = \begin{pmatrix} 2 \\ 3 \\ 5 \\ 4 \\ 6 \end{pmatrix}, \qquad \vec{w} = \begin{pmatrix} b \\ a \end{pmatrix}, \qquad S(\vec{w}) = \|\vec{y} - X\vec{w}\|^2.$$

Normální rovnice: Vektor vah $\vec{w}$ minimalizuje $\|\vec{y} - X\vec{w}\|^2$, právě když

$$X^T X\vec{w} = X^T\vec{y}.$$

Má-li X lineárně nezávislé sloupce, je X^TX regulární a $\vec{w} = (X^TX)^{-1}X^T\vec{y}$.

V našem příkladu je $X^TX = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$ a $X^T\vec{y} = \begin{pmatrix} 20 \\ 69 \end{pmatrix}$, tedy přesně soustava z příkladu. Důležitější než výpočet je ale geometrie. Vektor $X\vec{w} = b\,\vec{x}_{(1)} + a\,\vec{x}_{(2)}$ je lineární kombinace sloupců matice X, takže leží v rovině (obecně podprostoru) $\operatorname{Im} X$, kterou sloupce generují. Vektor $\vec{y} \in \mathbb{R}^5$ v ní obvykle neleží. Hledáme bod roviny, který je k $\vec{y}$ nejblíž. To je **kolmý průmět**.



Důkaz. (normálních rovnic) Nejbližší bod $\hat{\vec{y}} = X\vec{w}$ roviny k bodu $\vec{y}$ je ten, pro který je spojnice $\vec{r} = \vec{y} - X\vec{w}$ kolmá na celou rovinu (jinak bychom se mohli posunout po rovině blíž, podobně jako u vzdálenosti bodu od přímky v kapitole 14). Kolmost na rovinu znamená kolmost na každý sloupec matice X, tedy $X^T\vec{r} = \vec{o}$. Odtud $X^T(\vec{y} - X\vec{w}) = \vec{o}$, neboli $X^T X\vec{w} = X^T\vec{y}$.

Že jde o minimum, ověříme přímo: pro libovolný vektor $\vec{v}$ je $\vec{y} - X(\vec{w}+\vec{v}) = \vec{r} - X\vec{v}$ a protože $\vec{r} \perp X\vec{v}$, dává Pythagorova věta

$$\|\vec{y} - X(\vec{w}+\vec{v})\|^2 = \|\vec{r}\|^2 + \|X\vec{v}\|^2 \geq \|\vec{r}\|^2.$$

■

Tenhle argument dokázal víc, než jsme chtěli. Funkce $S(\vec{w})$ je **konvexní** miska bez jiných důlků: jediné stacionární místo je globální minimum. (Hessova matice je $2X^T X$ a pro každé $\vec{v}$ je $\vec{v}^T X^T X\vec{v} = \|X\vec{v}\|^2 \geq 0$.) U lineární regrese tedy nemůžeme ‘uvíznout’ ve špatném údolí. U neuronových sítí, jak uvidíme, takové štěstí nemáme.

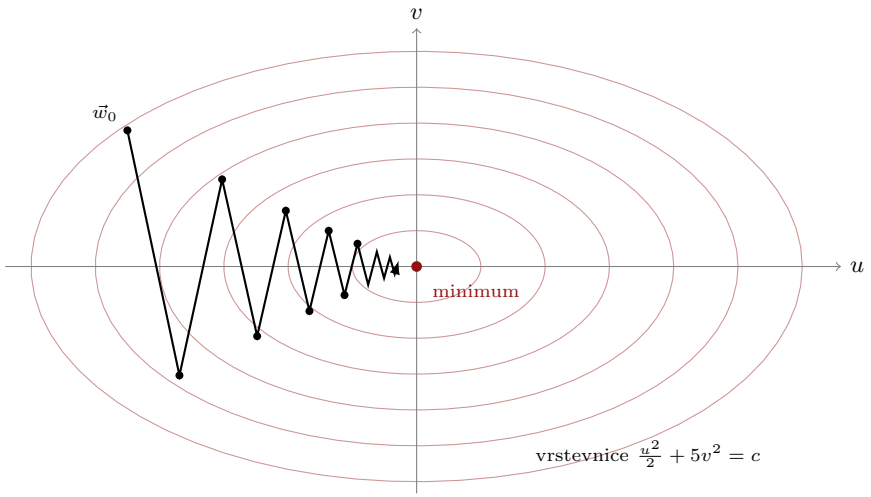
37.3 Gradientní sestup

Normální rovnice jsou krásné, ale pro model s miliardou parametrů bychom museli řešit soustavu s miliardou neznámých. A pro většinu modelů žádný vzorec pro minimum ani neexistuje. Proto se v praxi postupuje jako turista v mlze: nevidí údolí, ale cítí pod nohama sklon. V kapitole 30 jsme dokázali, že nejprudší klesání ukazuje vektor $-\nabla L$.

Gradientní sestup: Zvolíme počáteční váhy $\vec{w}_0$ a **rychlost učení** $\eta > 0$ a opakujeme

$$\vec{w}_{k+1} = \vec{w}_k - \eta\,\nabla L(\vec{w}_k).$$

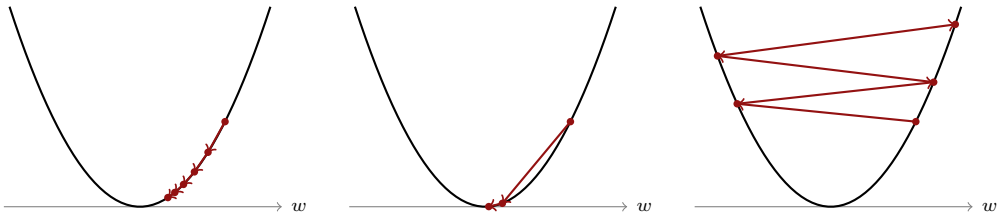
Příklad 37.3.1 Pro $L(u,v) = \frac{u^2}{2} + 5v^2$ je $\nabla L = (u, 10v)$ a krok s $\eta = 0{,}18$ zní $u_{k+1} = 0{,}82\,u_k$, $v_{k+1} = -0{,}8\,v_k$. Začneme v bodě $[-4{,}5;\ 1{,}2]$. Souřadnice v v každém kroku změní znaménko, takže cesta *kličkuje* napříč úzkým údolím, a přitom se po jeho dně jen pomalu sune k minimu.



Na obrázku je skutečných patnáct iterací. Gradient je kolmý na vrstevnice, a v protáhlém údolí proto míří hlavně ‘přes údolí’, ne ‘podél něj’. To je typické chování: když je funkce v jednom směru mnohem strmější než v jiném, gradientní sestup zbytečně kmitá. Moderní metody (s ‘hybností’ nebo s různou rychlostí pro každou souřadnici) se snaží právě tohle kmitání tlumit.

37.3.1 Rychlost učení

Nejdůležitější číslo celého algoritmu je η. Podívejme se na nejjednodušší možný případ $L(w) = w^2$. Krok je $w_{k+1} = w_k - 2\eta w_k = (1-2\eta)w_k$, takže $w_k = (1-2\eta)^k w_0$ je geometrická posloupnost z kapitoly 17. Konverguje k minimu, právě když $|1-2\eta| < 1$, tedy pro $0 < \eta < 1$.



$\eta = 0{,}1$: pomalu $\eta = 0{,}4$: rychle $\eta = 1{,}05$: diverguje

Malá rychlost učení znamená mnoho drobných kroků. Rozumná dojde k minimu za pár kroků. Příliš velká přeskočí údolí na druhou stranu, výš, než začala, a výpočet ‘vybuchne’. V praxi se η ladí zkoušením a často se během učení postupně zmenšuje. Pro obecnou hladkou funkci platí podobné pravidlo: je-li druhá derivace (zakřivení) nejvýš M, stačí volit $\eta < \frac{2}{M}$. V protáhlém údolí z předchozího obrázku určuje bezpečné η ten *nejstrmější* směr, a proto se v plochém směru postupuje tak pomalu.

37.3.2 Stochastický gradientní sestup

Ztráta je průměr přes všechna data, $L = \frac{1}{N}\sum \ell_i$, takže i gradient je průměr $\frac{1}{N}\sum \nabla \ell_i$. Pro N v řádu miliard je jeden přesný krok neúnosně drahý. **Stochastický gradientní sestup** (SGD) proto v každém kroku vybere náhodnou malou dávku (anglicky *minibatch*) třeba 32 příkladů a použije průměr gradientů jen přes ni. Takový odhad je náhodný, ale jeho *střední hodnota* je přesně skutečný gradient, protože každý příklad je vybrán se stejnou pravděpodobností. Cesta pak připomíná opilce, který jde z kopce: klopýtá ze strany na stranu, ale v průměru míří dolů. A jak se ukazuje, trocha šumu dokonce pomáhá vyskočit z mělkých důlků.

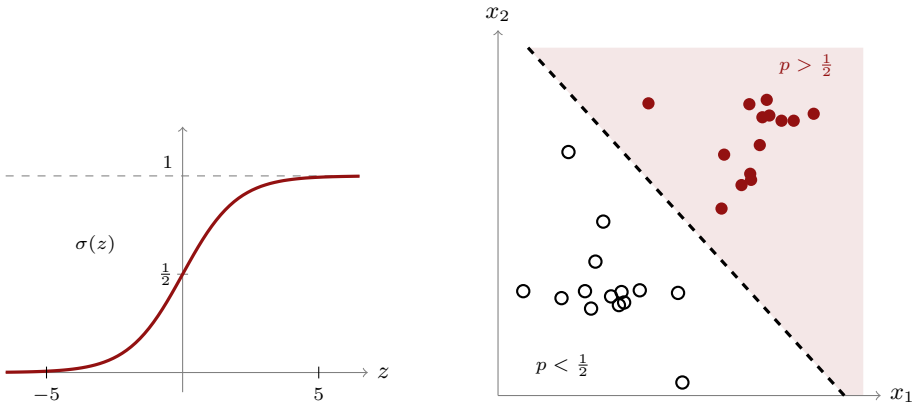
37.4 Klasifikace a logistická regrese

Často nechceme předpovědět číslo, ale *třídu*: je e-mail spam? Je na snímku nádor? Odpovědi budeme kódovat $y \in \{0, 1\}$. Přímka $\vec{w} \cdot \vec{x} + b$ dává libovolné reálné číslo. Chceme z něj udělat pravděpodobnost.

Sigmoida (logistická funkce) je $\sigma(z) = \dfrac{1}{1+\mathrm{e}^{-z}}$. **Logistická regrese** modeluje

$$P(y = 1 \mid \vec{x}) = p = \sigma(\vec{w} \cdot \vec{x} + b).$$

Rozhodovací hranice $p = \frac{1}{2}$ je množina $\vec{w} \cdot \vec{x} + b = 0$, tedy přímka (v rovině), rovina, obecně nadrovina.



Vlevo je sigmoida: hladký ‘schod’, který stlačí celou reálnou osu do intervalu $(0,1)$. Vpravo je skutečný výsledek logistické regrese pro dvě skupiny po čtrnácti bodech. Naučené váhy jsou $w_1 \approx 1{,}47$, $w_2 \approx 1{,}33$, $b \approx -5{,}84$ a čárkovaná přímka $1{,}47x_1 + 1{,}33x_2 = 5{,}84$ odděluje obě skupiny bezchybně. Daleko od hranice je model ‘jistý’ (p blízko 0 nebo 1), u hranice váhá.

37.4.1 Křížová entropie

Jakou ztrátu zvolit? Čtverce se tu nehodí. Přirozenější je zeptat se pravděpodobnosti z kapitoly 20: *Jak pravděpodobná jsou naše data, pokud platí model?* Model dává bodu třídy 1 pravděpodobnost p_i a bodu třídy 0 pravděpodobnost $1 - p_i$. Obojí zapíšeme jedním vzorcem $p_i^{y_i}(1-p_i)^{1-y_i}$. Pro nezávislé příklady se pravděpodobnosti násobí:

$$\mathcal{L}(\vec{w}) = \prod_{i=1}^{N} p_i^{y_i}(1-p_i)^{1-y_i}.$$

Chceme ji co největší (**metoda maximální věrohodnosti**). Součin tisíců čísel menších než jedna je ale tak malý, že by ho počítač zaokrouhlil na nulu. Pomůže logaritmus z kapitoly 9: je rostoucí, takže nemění polohu maxima, a mění součin na součet. Místo maximalizace $\ln \mathcal{L}$ budeme minimalizovat $-\ln \mathcal{L}$.

Křížová entropie (log-loss) jednoho příkladu je

$$\ell(p, y) = -\big(y \ln p + (1-y)\ln(1-p)\big).$$

Pro $y = 1$ je to $-\ln p$, pro $y = 0$ je to $-\ln(1-p)$. V obou případech tedy

$$\ell = -\ln\big(\text{pravděpodobnost, kterou model dal správné odpovědi}\big).$$

Pokud model dá správné odpovědi pravděpodobnost 0,9, zaplatí $-\ln 0{,}9 \approx 0{,}11$. Při 0,5 zaplatí 0,69 a při 0,01 už 4,6. Sebevědomý omyl je tedy trestán velmi tvrdě, a pro $p \to 0$ jde ztráta do nekonečna. Odměna za derivování je překvapivě elegantní.

Příklad 37.4.1 Platí $\sigma'(z) = \sigma(z)\big(1-\sigma(z)\big)$, protože

$$\sigma'(z) = \frac{\mathrm{e}^{-z}}{(1+\mathrm{e}^{-z})^2} = \frac{1}{1+\mathrm{e}^{-z}} \cdot \frac{\mathrm{e}^{-z}}{1+\mathrm{e}^{-z}} = \sigma(z)\big(1-\sigma(z)\big).$$

Pro $p = \sigma(z)$ pak podle derivace složené funkce

$$\frac{\partial \ell}{\partial z} = -\left(\frac{y}{p} - \frac{1-y}{1-p}\right) p(1-p) = -y(1-p) + (1-y)p = p - y.$$

Gradient podle vah je tedy $(p-y)\,\vec{x}$: chyba předpovědi krát vstup. Úplně stejný tvar má gradient čtvercové ztráty u lineární regrese. To není náhoda, obojí je zvláštní případ jedné obecné teorie (tzv. zobecněných lineárních modelů).

37.5 Neuronové sítě

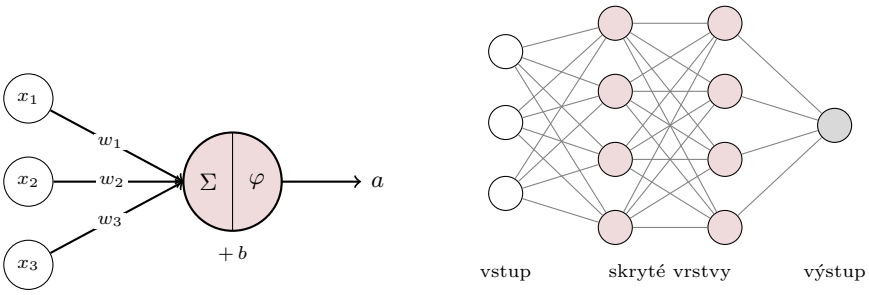
Logistická regrese umí oddělit třídy jen přímkou. Svět je ale křivější. Myšlenka neuronových sítí je jednoduchá: poskládat mnoho jednoduchých jednotek za sebe a vedle sebe.

Umělý neuron se vstupy $x_1, \dots, x_n$ spočítá vážený součet a na něj použije nelineární **aktivační funkci** φ:

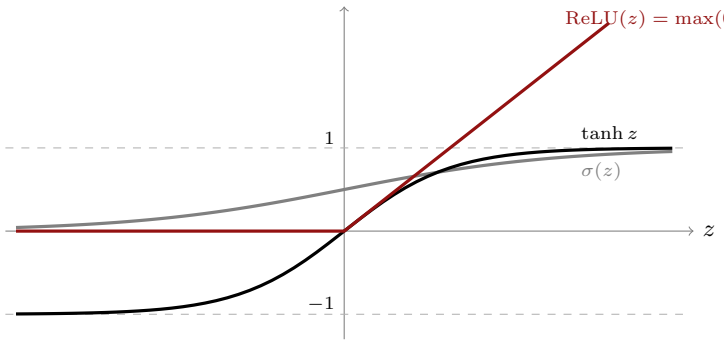
$$a = \varphi(w_1 x_1 + w_2 x_2 + \cdots + w_n x_n + b) = \varphi(\vec{w} \cdot \vec{x} + b).$$

Vrstva je několik neuronů se stejnými vstupy, tedy $\vec{a} = \varphi(W\vec{x} + \vec{b})$, kde W je matice vah a φ se použije na každou složku zvlášť. **Síť** je složení několika vrstev,

$$f(\vec{x}) = W_3\,\varphi\big(W_2\,\varphi(W_1\vec{x} + \vec{b}_1) + \vec{b}_2\big) + \vec{b}_3.$$



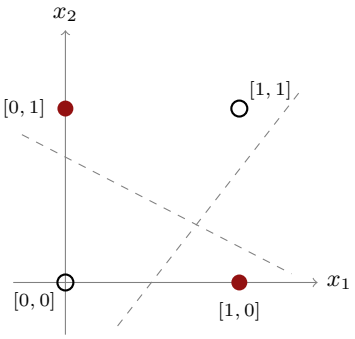
Vlevo jeden neuron, vpravo síť se dvěma skrytými vrstvami. Každá čára je jedna váha. Už tahle malá síť má $3 \cdot 4 + 4 \cdot 4 + 4 \cdot 1 = 32$ vah a 9 absolutních členů. Velké jazykové modely mají vah stovky miliard. Se skutečnými neurony v mozku mají ty umělé společné asi tolik, co letadlo s ptákem: inspiraci, ne mechanismus.



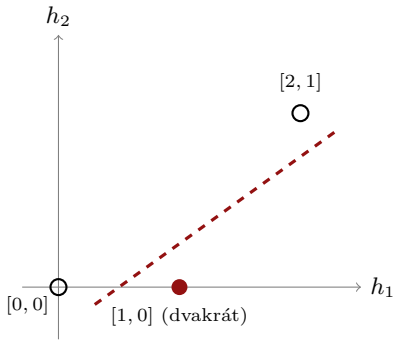
Tři nejznámější aktivační funkce. Sigmoida a hyperbolický tangens $\tanh z = \frac{e^z - e^{-z}}{e^z + e^{-z}}$ jsou hladké schody. Daleko od nuly jsou ale téměř vodorovné, mají tam skoro nulovou derivaci, a gradientní sestup se v nich ‘zasekne’. Proto se dnes nejvíc používá obyčejný **ReLU** (*rectified linear unit*): pro záporná čísla nula, pro kladná identita. Nevypadá to jako nic převratného, a přece právě on hlubokým sítím výrazně usnadnil učení.

37.5.1 Proč je potřeba nelinearita

Kdyby φ byla lineární, byla by celá síť jen $W_3W_2W_1\vec{x}+$konstanta: součin matic je zase matice, takže by sto vrstev nebylo o nic silnějších než jedna. Bez nelinearity je hluboká síť jen drahá lineární regrese. Nejslavnější úloha, kterou lineární model nezvládne, je **XOR** (‘buď, anebo’): výstup je 1, právě když je právě jeden ze vstupů roven 1.



žádná přímka neoddělí barevné body od bílých



po skryté vrstvě to jde

Vlevo: body $[1,0]$ a $[0,1]$ leží na jedné úhlopříčce, body $[0,0]$ a $[1,1]$ na druhé, a každá přímka, která odřízne jednu barevnou, odřízne s ní i bílou. (Formálně: kdyby $w_1x_1 + w_2x_2 + b$ bylo kladné v $[1,0]$ a $[0,1]$ a záporné v $[0,0]$ a $[1,1]$, sečtením prvních dvou nerovností dostaneme $w_1 + w_2 + 2b > 0$ a sečtením druhých dvou $w_1 + w_2 + 2b < 0$.) Jedna skrytá vrstva se dvěma neurony ale stačí. Zvolme

$$h_1 = \mathrm{ReLU}(x_1 + x_2), \qquad h_2 = \mathrm{ReLU}(x_1 + x_2 - 1), \qquad \text{výstup} = h_1 - 2h_2.$$

Body se zobrazí na $[0,0] \mapsto [0,0]$, $[1,0], [0,1] \mapsto [1,0]$, $[1,1] \mapsto [2,1]$ a výstup je postupně $0, 1, 1, 0$. Skrytá vrstva *ohnula prostor* tak, že je úloha najednou lineárně oddělitelná (vpravo). Tohle je podstata hlubokého učení: každá vrstva přetransformuje data do tvaru, ve kterém je pro další vrstvu úloha snazší.

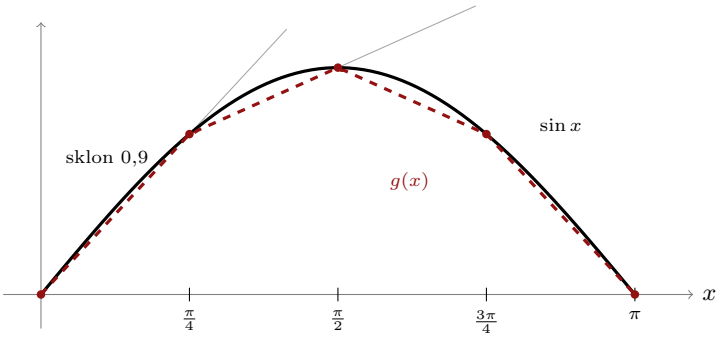
37.5.2 Univerzální aproximace

Kolik toho síť dokáže? Překvapivě mnoho. Uvažujme síť s jednou skrytou vrstvou neuronů ReLU a jedním vstupem: $g(x) = \sum_k c_k \,\mathrm{ReLU}(x - t_k)$. Každý člen je ‘zalomení’ v bodě t_k, za kterým se sklon změní o c_k. Součet je tedy lomená čára, a lomenou čarou se dá libovolně přesně obtáhnout každá spojitá funkce na uzavřeném intervalu.

Příklad 37.5.1 Aproximujme $\sin x$ na $[0,\pi]$ lomenou čárou s vrcholy v bodech $0, \frac{\pi}{4}, \frac{\pi}{2}, \frac{3\pi}{4}, \pi$. Sklony úseků jsou $\pm\frac{2\sqrt{2}}{\pi} \approx \pm 0{,}900$ a $\pm\frac{4-2\sqrt{2}}{\pi} \approx \pm 0{,}373$. Koeficient c_k je změna sklonu v bodě t_k, takže

$$g(x) = 0{,}900\,\mathrm{ReLU}(x) - 0{,}527\,\mathrm{ReLU}\big(x - \tfrac{\pi}{4}\big) - 0{,}746\,\mathrm{ReLU}\big(x - \tfrac{\pi}{2}\big) - 0{,}527\,\mathrm{ReLU}\big(x - \tfrac{3\pi}{4}\big).$$

Čtyři neurony a největší chyba je asi 0,07. S osmi neurony by klesla zhruba na čtvrtinu.



Šedé čáry ukazují, jak by g pokračovala bez dalšího zalomení. Každý neuron graf v jednom místě ‘ohne’. Obecná **věta o univerzální aproximaci** (pro sigmoidy ji v roce 1989 dokázal George Cybenko) říká totéž ve více rozměrech: síť s jednou dostatečně širokou skrytou vrstvou aproximuje libovolnou spojitou funkci na omezené uzavřené množině s libovolnou přesností. Pozor ale, co věta *neříká*: kolik neuronů bude potřeba (může to být astronomické číslo), ani jak správné váhy najít, ani jestli síť bude dobře odhadovat body, které neviděla. Je to věta o existenci, ne návod.

37.6 Zpětné šíření: derivace složené funkce

Učit síť gradientním sestupem znamená spočítat parciální derivace ztráty podle každé z miliard vah. Naivně, po jedné, by to trvalo věčnost. **Zpětné šíření** (*backpropagation*) je jen pečlivě zorganizované pravidlo pro derivaci složené funkce z kapitoly 24: $\frac{\mathrm{d}f}{\mathrm{d}x} = \frac{\mathrm{d}f}{\mathrm{d}g} \cdot \frac{\mathrm{d}g}{\mathrm{d}x}$. Síť je dlouhé složení funkcí, a tak se derivace násobí podél řetězu, odzadu dopředu.

Příklad 37.6.1 Síť s jedním vstupem, jedním skrytým neuronem ReLU a lineárním výstupem:

$$z = w_1 x, \qquad h = \mathrm{ReLU}(z), \qquad \hat{y} = w_2 h, \qquad L = \tfrac{1}{2}(\hat{y} - y)^2.$$

Vezmeme $x = 2$, $y = 1$, $w_1 = 0{,}5$, $w_2 = 1{,}5$. **Dopředný průchod**: $z = 1$, $h = 1$, $\hat{y} = 1{,}5$, $L = 0{,}125$. **Zpětný průchod** jde od konce a každý krok znovu použije výsledek předchozího:

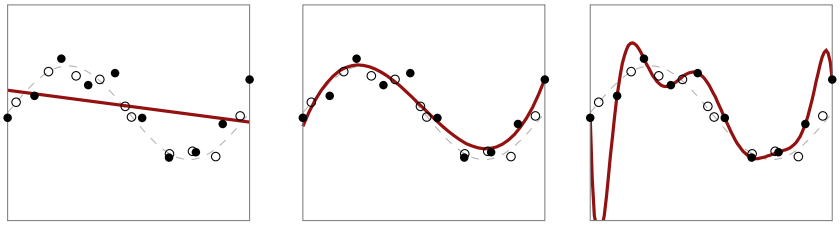
$$\frac{\partial L}{\partial \hat{y}} = \hat{y} - y = 0{,}5, \qquad \frac{\partial L}{\partial w_2} = \frac{\partial L}{\partial \hat{y}} \cdot h = 0{,}5,$$
$$\frac{\partial L}{\partial h} = \frac{\partial L}{\partial \hat{y}} \cdot w_2 = 0{,}75, \qquad \frac{\partial L}{\partial z} = \frac{\partial L}{\partial h} \cdot \mathrm{ReLU}'(z) = 0{,}75 \cdot 1 = 0{,}75,$$
$$\frac{\partial L}{\partial w_1} = \frac{\partial L}{\partial z} \cdot x = 1{,}5.$$

Krok gradientního sestupu s $\eta = 0{,}1$ dá $w_1 = 0{,}35$, $w_2 = 1{,}45$. Nový výstup je $\hat{y} = 1{,}45 \cdot 0{,}7 = 1{,}015$, téměř přesně požadovaná jednička.

Trik je v tom, že mezivýsledky $\frac{\partial L}{\partial h}$, $\frac{\partial L}{\partial z}$ se spočítají jen jednou a sdílí se pro všechny váhy před nimi. Celý gradient tak stojí jen zhruba tolik jako dva až tři dopředné průchody, ať má síť vah kolik chce. Bez tohoto pozorování by moderní umělá inteligence neexistovala.

37.7 Přeučení a zobecnění

Teď k rozporu, který jsme slíbili na začátku. Vezmeme deset bodů, které vznikly z funkce $\sin 2\pi x$ přidáním náhodného šumu, a proložíme jimi metodou nejmenších čtverců mnohočleny stupně 1, 3 a 9. Zvlášť máme deset dalších **testovacích** bodů ze stejného zdroje, které model při učení neviděl.



stupeň 1 stupeň 3 stupeň 9

Plné body jsou trénovací, prázdné testovací, šedá čárkovaná křivka je skutečná funkce, kterou model nezná. Chybu změříme odmocninou z průměrného čtverce reziduí:

	stupeň 1	stupeň 3	stupeň 9
chyba na trénovacích datech	0,64	0,24	0,00
chyba na testovacích datech	0,55	0,19	1,09

Přímka je příliš hloupá: chybuje všude (**nedoučení**). Mnohočlen stupně 9 má deset koeficientů, a tak projde všemi deseti body *přesně*. Trénovací chyba je nulová, a přesto je to nejhorší model ze tří: mezi body divoce kmitá, protože se naučil nazpaměť i šum (**přeučení**). Jeho koeficienty mají velikost až kolem 600 000, které se navzájem jemně vyrušují. Kubika zachytila tvar, ne náhodu. Je to jako student, který se naučí nazpaměť řešení všech příkladů ze sbírky, ale u maturity dostane nový příklad.

Zobecnění: model posuzujeme podle chyby na datech, která při učení neviděl. Proto se data dělí na **trénovací** (na nich se učí váhy) a **testovací** (na nich se jednou, na konci, změří úspěšnost). Často i na třetí, **validační** část, podle které se volí třeba stupeň mnohočlenu.

Regularizace: k ztrátě přičteme trest za velké váhy,

$$L_\lambda(\vec{w}) = \|\vec{y} - X\vec{w}\|^2 + \lambda\|\vec{w}\|^2, \qquad \text{s řešením} \qquad \vec{w} = (X^TX + \lambda I)^{-1}X^T\vec{y}.$$

Regularizace říká modelu: ‘buď jednoduchý, pokud to jde’. Pro mnohočlen stupně 9 s $\lambda = 0{,}001$ klesnou koeficienty z řádu statisíců zhruba na 10, trénovací chyba vzroste na 0,22 a testovací klesne z 1,09 na 0,20. Model se zhoršil na tom, co zná, a výrazně zlepšil na tom, co nezná. Matice $X^TX + \lambda I$ je navíc vždy regulární (proč? nápověda: $\vec{v}^T(X^TX + \lambda I)\vec{v} = \|X\vec{v}\|^2 + \lambda\|\vec{v}\|^2$), takže regularizace vyléčí i soustavy, které by jinak řešení neměly jednoznačné.

37.8 Odbočka — Rozklad chyby na vychýlení a rozptyl

Proč má přímka i mnohočlen stupně 9 velkou testovací chybu, když selhávají úplně jinak? Odpověď dává jedna z nejhezčích rovností statistiky. Předpokládejme, že data vznikají jako $y = f(x) + \varepsilon$, kde f je neznámá skutečná funkce a ε náhodný šum se střední hodnotou 0 a rozptylem σ^2 (viz kapitolu 21). Trénovací data jsou náhodná, takže i naučený model $\hat{f}$ je náhodný: s jinými deseti body bychom dostali jiný mnohočlen. Označme $\bar{f}(x) = \mathrm{E}\,\hat{f}(x)$ ‘průměrný model’ přes všechny možné trénovací sady.

Rozklad na vychýlení a rozptyl: Pro nový bod x s nezávislým šumem platí

$$\mathrm{E}\big[(y - \hat{f}(x))^2\big] = \underbrace{\sigma^2}_{\text{šum}} + \underbrace{\big(f(x) - \bar{f}(x)\big)^2}_{\text{vychýlení}^2} + \underbrace{\mathrm{E}\big[(\hat{f}(x) - \bar{f}(x))^2\big]}_{\text{rozptyl}}.$$

Důkaz. Pišme $y - \hat{f} = \varepsilon + (f - \bar{f}) + (\bar{f} - \hat{f})$ (vše v bodě x). Umocníme na druhou a vezmeme střední hodnotu. Vzniknou tři čtverce a tři smíšené členy. Smíšené členy jsou nulové:

- $\mathrm{E}[\varepsilon(f - \bar{f})] = (f - \bar{f})\,\mathrm{E}\,\varepsilon = 0$, protože $f - \bar{f}$ je pevné číslo;
- $\mathrm{E}[\varepsilon(\bar{f} - \hat{f})] = \mathrm{E}\,\varepsilon \cdot \mathrm{E}[\bar{f} - \hat{f}] = 0$, protože šum v novém bodě nezávisí na trénovacích datech;
- $\mathrm{E}[(f - \bar{f})(\bar{f} - \hat{f})] = (f - \bar{f})\big(\bar{f} - \mathrm{E}\,\hat{f}\big) = 0$ podle definice $\bar{f}$.

Zbudou $\mathrm{E}\,\varepsilon^2 = \sigma^2$, $(f - \bar{f})^2$ a $\mathrm{E}(\bar{f} - \hat{f})^2$. ∎

Šum σ^2 nepřekoná žádný model: je to chyba, kterou má i dokonalé $\hat{f} = f$. **Vychýlení** měří, jak daleko je i *průměrný* model od pravdy. Přímka má vychýlení velké, protože sinusovku nevystihne, ať ji naučíme na čemkoli. **Rozptyl** měří, jak moc model kolísá podle toho, která data zrovna dostal. Mnohočlen stupně 9 má vychýlení malé (v průměru přes mnoho datových sad by se k sinusovce blížil), ale rozptyl obrovský: každá nová desítka bodů dá úplně jinou divokou křivku. Složitější model vychýlení snižuje a rozptyl zvyšuje, a nejlepší je kompromis uprostřed. Regularizace je přesně páka, kterou mezi nimi posouváme. (Moderní obří sítě tento klasický obraz zčásti narušují: při extrémním počtu parametrů se testovací chyba někdy znovu zlepšuje. Proč přesně, je dodnes předmětem výzkumu.)

37.9 Učení bez učitele

Někdy žádné y nemáme, jen body $\vec{x}_i$. Chceme v nich najít strukturu.

37.9.1 Shlukování metodou k-means

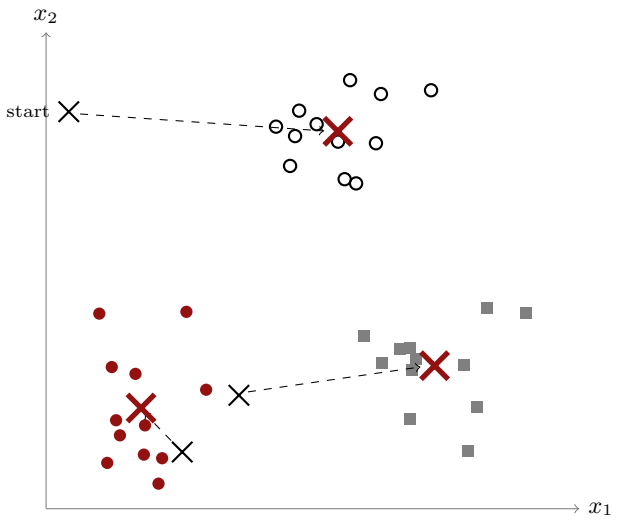
Algoritmus k-means rozdělí body do k shluků. Zvolí k počátečních středů (centroidů) a opakuje dva kroky:

1. každý bod přiřadí k nejbližšímu centroidu;
2. každý centroid přesune do těžiště (průměru) bodů, které k němu patří.

Skončí, když se přiřazení přestane měnit. Minimalizuje tím součet čtverců vzdáleností bodů od

jejich centroidů.

Proč algoritmus skončí? Oba kroky součet čtverců nezvětší: první proto, že bod přejde jen k bližšímu centroidu, a druhý proto, že těžiště je bod, který minimalizuje součet čtverců vzdáleností (to je mimochodem tentýž výpočet jako u $\frac{\partial S}{\partial b} = 0$ v regresi). Přiřazení je jen konečně mnoho, takže se cyklus jednou zastaví. Výsledek ale může záviset na počátečních středech a nemusí být nejlepší možný.



Skutečný běh algoritmu pro 36 bodů a $k = 3$. Tenké křížky jsou počáteční centroidy, zvolené schválně nešikovně. Po dvou kolech se přiřazení přestalo měnit a centroidy (tlusté křížky) skončily v bodech [1,14; 0,89], [3,72; 1,26] a [2,87; 3,33]. Algoritmus nezná žádné ‘správné odpovědi’, a přesto našel tři skupiny, které vidí i lidské oko. Podobně se shlukují zákazníci e-shopů nebo pixely obrázku (tím se zmenšuje počet barev).

37.9.2 Analýza hlavních komponent

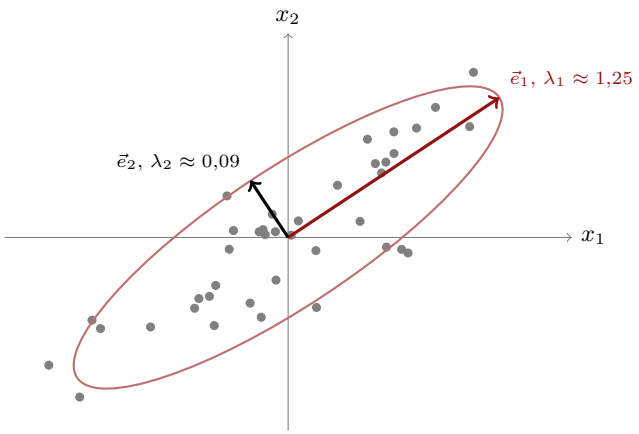
Data o stovkách proměnných nelze nakreslit. Často ale leží blízko nějakého podprostoru menší dimenze: výška a hmotnost lidí spolu silně souvisí, takže dvourozměrný mrak bodů je ve skutečnosti ‘skoro přímka’. Jak ten nejdůležitější směr najít?

Nechť jsou data **vycentrovaná** (průměr každé souřadnice je 0). Jejich **kovarianční matice** je $C = \frac{1}{N-1}\sum_i \vec{x}_i \vec{x}_i^T$, neboli c_{jk} je kovariance j-té a k-té souřadnice. **Hlavní komponenty** jsou vlastní vektory matice C, seřazené podle velikosti vlastních čísel. Vlastní číslo je rozptyl dat ve směru příslušného vlastního vektoru.

Proč zrovna vlastní vektory? Rozptyl průmětů dat na jednotkový vektor $\vec{u}$ je

$$\frac{1}{N-1}\sum_i (\vec{u}\cdot\vec{x}_i)^2 = \vec{u}^T\Big(\frac{1}{N-1}\sum_i \vec{x}_i\vec{x}_i^T\Big)\vec{u} = \vec{u}^T C\vec{u}.$$

Matice C je symetrická, takže podle spektrální věty z kapitoly 27 má ortonormální bázi vlastních vektorů $\vec{e}_1, \vec{e}_2, \ldots$ s vlastními čísly $\lambda_1 \geq \lambda_2 \geq \cdots \geq 0$. Zapíšeme-li $\vec{u} = \sum u_j \vec{e}_j$ se $\sum u_j^2 = 1$, vyjde $\vec{u}^T C\vec{u} = \sum \lambda_j u_j^2 \leq \lambda_1 \sum u_j^2 = \lambda_1$, s rovností pro $\vec{u} = \vec{e}_1$. Směr největšího rozptylu je tedy první vlastní vektor. Druhý nejlepší směr kolmý na první je $\vec{e}_2$, a tak dál.



Pro těchto 40 bodů vyšla kovarianční matice $C \approx \begin{pmatrix} 0{,}89 & 0{,}53 \\ 0{,}53 & 0{,}44 \end{pmatrix}$ s vlastními vektory $\vec{e}_1 \approx (0{,}83;\ 0{,}55)$ a $\vec{e}_2 \approx (-0{,}55;\ 0{,}83)$. Šipky mají délku dvojnásobku směrodatné odchylky $2\sqrt{\lambda}$. První komponenta nese $\frac{1{,}25}{1{,}34} \approx 93\,\%$ celkového rozptylu, takže když každý bod nahradíme jediným číslem, jeho průmětem na $\vec{e}_1$, ztratíme jen 7 % informace (měřeno rozptylem). Stejně se zmenšují data o tisících proměnných: ponechají se jen první desítky komponent.

37.10 Jazykové modely

Jak může počítač, který umí jen násobit čísla, pracovat s textem? Nejdřív musí slova převést na čísla.

37.10.1 Slova jako vektory

Každé slovo (přesněji *token*, kousek slova) dostane vektor v $\mathbb{R}^d$, kde d bývá stovky až tisíce. Tyto vektory, **embeddingy**, nejsou zvolené ručně. Jsou to parametry modelu, naučené gradientním sestupem tak, aby slova vyskytující se v podobných kontextech měla podobné vektory. ‘Podobné’ měříme úhlem, přesně jako v kapitole 14:

Kosinová podobnost vektorů $\vec{u}$, $\vec{v}$ je

$$\cos\theta = \frac{\vec{u}\cdot\vec{v}}{\|\vec{u}\|\,\|\vec{v}\|} \in [-1, 1].$$

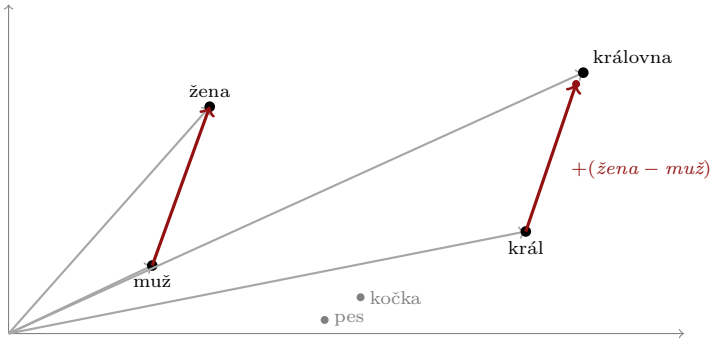
Pro jednotkové vektory je to prostě skalární součin.

Příklad 37.10.1 Hračkové trojrozměrné embeddingy: *kočka* $= (4, 3, 0)$, *pes* $= (3, 4, 1)$, *rovnice* $= (0, 1, 5)$. Pak

$$\cos(\textit{kočka}, \textit{pes}) = \frac{24}{5\sqrt{26}} \approx 0{,}94, \qquad \cos(\textit{kočka}, \textit{rovnice}) = \frac{3}{5\sqrt{26}} \approx 0{,}12.$$

Kočka a pes jsou si ‘blízko’, kočka a rovnice ne.

Nejslavnější pozorování (Tomáš Mikolov a kolegové, 2013, model *word2vec*): rozdíly vektorů někdy zachycují vztahy. Vektor *král* $-$ *muž* $+$ *žena* leží nejblíž vektoru *královna*. Směr ‘muž → žena’ je zhruba stejný jako směr ‘král → královna’.



Tenhle obrázek je ale *ilustrace*, ne skutečná data. Skutečné vektory mají stovky rozměrů a do roviny se nevejdou bez zkreslení. Rovnost platí jen přibližně (a při hledání ‘nejbližšího slova’ se obvykle vylučují slova samotného dotazu, jinak by často vyhrál sám *král*). Pro mnoho jiných dvojic analogie nefunguje vůbec. Je to krásná intuice, ne zákon přírody.

37.10.2 Softmax a pravděpodobnost dalšího slova

Jazykový model dělá v jádru jedinou věc: na základě dosavadního textu přiřadí každému tokenu ze slovníku (bývá jich desítky tisíc) skóre z_i a převede skóre na pravděpodobnosti, že tento token bude následovat.

Softmax s teplotou $T > 0$:

$$p_i = \frac{\mathrm{e}^{z_i/T}}{\sum_j \mathrm{e}^{z_j/T}}.$$

Všechna p_i jsou kladná a jejich součet je 1. Větší skóre znamená větší pravděpodobnost.

Exponenciála dělá z libovolných čísel kladná a zesiluje rozdíly. Pro dvě třídy (a $T = 1$) je

$$p_1 = \frac{\mathrm{e}^{z_1}}{\mathrm{e}^{z_1} + \mathrm{e}^{z_2}} = \frac{1}{1 + \mathrm{e}^{-(z_1 - z_2)}} = \sigma(z_1 - z_2),$$

takže softmax je přímé zobecnění sigmoidy. Model se učí křížovou entropií $-\ln p_{\text{skutečné další slovo}}$, tedy úplně stejně jako logistická regrese, jen na obrovském množství textu.

Příklad 37.10.2 Za textem ‘Kočka spí na …’ dá model skóre *gauči* 3, *stole* 2, *střeše* 1,5, *rovnici* −1. Pravděpodobnosti:

	gauči	*stole*	*střeše*	*rovnici*
$T = 0{,}5$	0,844	0,114	0,042	0,000 3
$T = 1$	0,621	0,229	0,139	0,011
$T = 2$	0,452	0,274	0,213	0,061

Text se generuje tak, že se z tohoto rozdělení *náhodně vylosuje* další token, připojí se k textu a celé se to opakuje. Teplota řídí odvahu. Pro $T \to 0$ se veškerá pravděpodobnost soustředí na nejlepší token a model píše předvídatelně (a často nudně a dokola). Velké T rozdělení zplošťuje, text je ‘kreativnější’, ale i častěji nesmyslný. Proto stejná otázka může dostat pokaždé jinou odpověď.

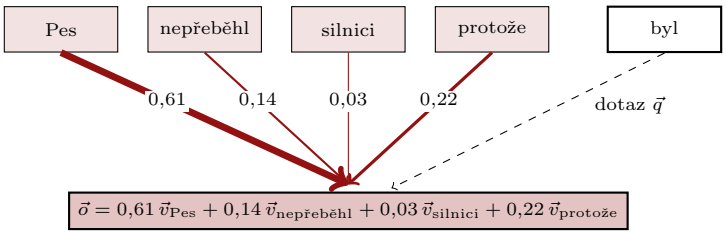
37.10.3 Pozornost: vážený průměr

Význam slova závisí na kontextu. Ve větě ‘Pes nepřeběhl silnici, protože byl unavený’ se ‘byl’ týká psa, ne silnice. Moderní jazykové modely (architektura *transformer*, 2017) k tomu používají mechanismus **pozornosti** (*attention*). Každý token j má kromě embeddingu ještě tři naučené vektory: *dotaz* $\vec{q}_j$, *klíč* $\vec{k}_j$ a *hodnotu* $\vec{v}_j$ (vzniknou vynásobením embeddingu třemi maticemi vah).

Pozornost: nová reprezentace tokenu s dotazem $\vec{q}$ je vážený průměr hodnot

$$\vec{o} = \sum_j \alpha_j \vec{v}_j, \qquad \text{kde} \qquad \alpha_j = \operatorname{softmax}_j\left(\frac{\vec{q}\cdot\vec{k}_j}{\sqrt{d}}\right).$$

Skalární součin $\vec{q}\cdot\vec{k}_j$ měří, jak moc se klíč tokenu j ‘hodí’ k dotazu. Softmax z toho udělá váhy se součtem 1 a výstup je těžiště hodnot s těmito vahami. (Dělení $\sqrt{d}$ jen brání tomu, aby skalární součiny v mnoha rozměrech byly tak velké, že by softmax dal skoro všechnu váhu jedinému tokenu.)



V příkladu vyšla skóre $\frac{\vec{q}\cdot\vec{k}_j}{\sqrt{d}}$ postupně 2; 0,5; -1; 1 a softmax z nich udělal váhy 0,61; 0,14; 0,03; 0,22. Token ‘byl’ si tedy vezme nejvíc informace od ‘Pes’. (Čísla jsou zde vymyšlená pro ilustraci. Ve skutečném modelu běží desítky takových ‘hlav pozornosti’ vedle sebe a desítky vrstev za sebou.) Celý transformer je jen střídání pozornosti, malých neuronových sítí a normalizací, učené zpětným šířením na předpovídání dalšího tokenu.

37.10.4 Co jazykové modely umějí a co ne

Je dobré mít střízlivý pohled. Jazykový model je naučen na jedinou úlohu: odhadovat pravděpodobné pokračování textu. Že se z toho vynoří schopnost překládat, shrnovat nebo psát programy, je pozoruhodné a ne zcela pochopené. Plynou z toho ale i omezení:

- *Pravděpodobné* není totéž co *pravdivé*. Model může sebejistě napsat neexistující citaci nebo chybný výpočet (tomu se říká **halucinace**). Výstup je třeba ověřovat, zvlášť čísla, fakta a zdroje.
- Model zdědí vzorce, a tedy i předsudky a chyby, ze svých trénovacích dat.
- Nemá zaručeno, že na nové typy úloh zobecní. Platí pro něj totéž co pro mnohočlen stupně 9: úspěch na známých datech nic nedokazuje.
- Je to obrovská, přesně definovaná matematická funkce. Otázky, zda ‘rozumí’ nebo ‘myslí’, jsou zajímavé, ale matematika sama na ně neodpoví.

Cvičení 37.10.3

(a) Metodou nejmenších čtverců proložte přímku body $[0,1]$, $[1,3]$, $[2,4]$.

(b) Gradientní sestup s η pro $L(w) = 3w^2$. Pro která η konverguje?

(c) Ukažte, že softmax se nezmění, když ke všem skóre z_i přičteme stejné číslo c. (Počítače to využívají: odečtou $\max z_i$, aby exponenciála nepřetekla.)

(d) Model dá správnému dalšímu slovu pravděpodobnost $\frac{1}{1000}$. Jaká je ztráta? Jaká by byla, kdyby hádal rovnoměrně z 50 000 tokenů?

Řešení 37.10.3

(a) $N = 3$, $\sum x = 3$, $\sum y = 8$, $\sum x^2 = 5$, $\sum xy = 11$. Soustava $3a + 3b = 8$, $5a + 3b = 11$ dává $a = \frac{3}{2}$, $b = \frac{7}{6}$. Přímka $y = 1{,}5x + \frac{7}{6}$.

(b) $w_{k+1} = w_k - 6\eta w_k = (1-6\eta)w_k$, konverguje pro $|1-6\eta| < 1$, tedy $0 < \eta < \frac{1}{3}$. Souhlasí s pravidlem $\eta < \frac{2}{M}$ pro $M = L'' = 6$.

(c) Exponenciála převede sčítání na násobení a e^c se vykrátí:

$$\frac{\mathrm{e}^{z_i+c}}{\sum_j \mathrm{e}^{z_j+c}} = \frac{\mathrm{e}^c\,\mathrm{e}^{z_i}}{\mathrm{e}^c \sum_j \mathrm{e}^{z_j}} = \frac{\mathrm{e}^{z_i}}{\sum_j \mathrm{e}^{z_j}}.$$

(d) $-\ln \frac{1}{1000} = \ln 1000 \approx 6{,}91$. Rovnoměrné hádání: $\ln 50\,000 \approx 10{,}82$. I 'špatný' odhad je tedy mnohem lepší než náhoda.

37.11 Příběh — Stroj, který měl být vědomý

V červenci 1958 předvedl mladý psycholog Frank Rosenblatt z Cornellovy letecké laboratoře novinářům ve Washingtonu svůj **perceptron**. Šlo o program na sálovém počítači IBM 704 financovaný americkým námořnictvem: jeden umělý neuron, jehož váhy se upravovaly podle jednoduchého pravidla. Když se spletl, přičetl ke své váze vstup (nebo ho odečetl). Počítač dostával karty se značkou buď vlevo, nebo vpravo, a po padesáti pokusech je prý začal rozlišovat. Druhý den, 8. července 1958, napsal *New York Times*, že námořnictvo očekává, že stroj bude jednou 'chodit, mluvit, vidět, psát, rozmnožovat se a být si vědom své existence'.

Rosenblatt pak postavil i hardwarovou verzi, Mark I Perceptron, s 'sítnicí' z 400 fotočlánků a s vahami v podobě potenciometrů, které otáčely elektromotorky. Byl charismatický, sliboval hodně a vzbudil stejně tolik nadšení jako odporu. Jeho nejvýznamnějším kritikem byl Marvin Minsky z MIT, mimochodem absolvent téže newyorské střední školy, Bronx High School of Science.

V roce 1969 vydali Minsky a Seymour Papert knihu *Perceptrons*. Matematicky přesně v ní ukázali, co jedna vrstva perceptronů nedokáže: například rozpoznat, zda je obrazec souvislý, nebo spočítat paritu, tedy obecnou verzi našeho XOR. O vícevrstvých sítích byli skeptičtí, a nikdo tehdy neuměl takové sítě rozumně učit. Kniha se stala symbolem konce optimismu. Peníze na výzkum neuronových sítí v sedmdesátých letech do značné míry vyschly a nastala první 'zima umělé inteligence'. Jak velký podíl na tom kniha opravdu měla, se historici přou dodnes.

Rosenblatt se nástupu té zimy plně nedožil. 11. července 1971, v den svých třiačtyřicátých narozenin, zahynul při nehodě na lodi v zálivu Chesapeake. Vícevrstvé sítě učené zpětným šířením se proslavily až v roce 1986 díky článku Davida Rumelharta, Geoffreyho Hintona a Ronalda Williamse. A když v roce 2012 hluboká síť drtivě vyhrála soutěž v rozpoznávání obrázků ImageNet, ukázalo se, že Rosenblattova základní myšlenka, vážený součet, nelinearita a úprava vah podle chyb, byla správná. Chyběla jen data, výpočetní výkon a derivace složené funkce použitá v pořádném měřítku.

37.12 Shrnutí a otázky

Cvičení 37.12.1 Odpovězte vlastními slovy:

1. Co je model, parametry a ztrátová funkce? Proč je 'učení' vlastně optimalizace?
2. Odvoďte normální rovnice pro proložení přímky. Proč je řešení kolmým průmětem a proč je minimum jediné?
3. Jak funguje gradientní sestup? Co se stane při příliš malé a příliš velké rychlosti učení? Proč kličkuje v úzkém údolí?
4. Co je logistická regrese a sigmoida? Jak souvisí křížová entropie s pravděpodobností a proč v ní je logaritmus?
5. Co je umělý neuron a neuronová síť? Proč je nutná nelineární aktivační funkce? Vysvětlete na úloze XOR.
6. Co říká věta o univerzální aproximaci a co neříká?
7. Vysvětlete zpětné šíření pomocí derivace složené funkce. Proč je tak efektivní?
8. Co je přeučení? Proč dělíme data na trénovací a testovací a k čemu je regularizace? Co je vychýlení a rozptyl?

9. Jak funguje k-means a proč skončí? Proč jsou hlavní komponenty vlastními vektory kovarianční matice?
10. Jak jazykový model volí další slovo? Co je kosinová podobnost, softmax, teplota a pozornost? Jaká jsou jeho omezení?

Kapitola 38

Matematika v přírodě

Mraky nejsou koule, hory nejsou kužely, pobřeží nejsou kružnice, kůra není hladká a blesk se nešíří po přímce.

Benoît Mandelbrot, Fraktální geometrie přírody, 1982

Příroda matematiku nestudovala, a přesto se jí řídí. Epidemie se šíří podle diferenciálních rovnic z kapitoly 31. Počty zvířat mohou kolísat chaoticky, přestože se řídí jednoduchým vzorcem. Semínka slunečnice se rovnají podle čísla, které jsme potkali u Fibonacciho posloupnosti v kapitole 17. Harmonie v hudbě je otázkou zlomků a mocnin dvojky z kapitoly 9. A k tomu dvě věci, které přírodní nejsou, ale bez matematiky by nefungovaly: GPS v telefonu, které musí počítat s Einsteinovou relativitou, a vyhledávač, který řadí stránky pomocí vlastního vektoru matice z kapitoly 27.

38.1 Epidemie: model SIR

Rozdělme populaci na tři skupiny: **náchylní** (S, *susceptible*), **nakažení** (I, *infected*) a **zotavení** (R, *recovered*, sem patří i zemřelí). Počítáme podíly, takže $S + I + R = 1$.

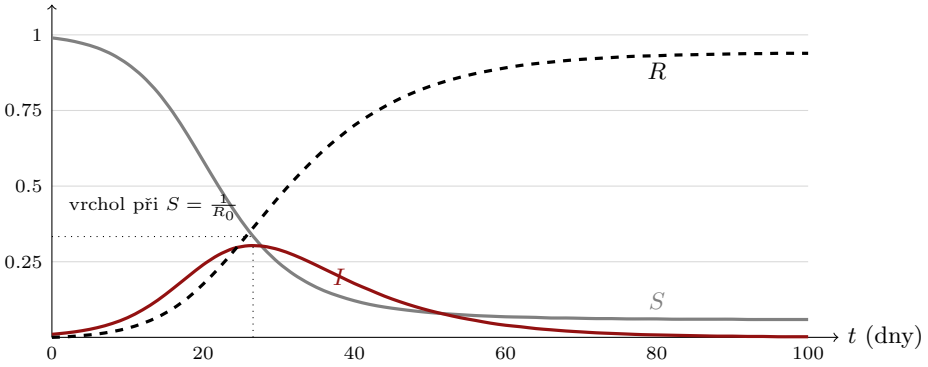
Model SIR (Kermack a McKendrick, 1927):

$$\frac{\mathrm{d}S}{\mathrm{d}t} = -\beta SI, \qquad \frac{\mathrm{d}I}{\mathrm{d}t} = \beta SI - \gamma I, \qquad \frac{\mathrm{d}R}{\mathrm{d}t} = \gamma I.$$

Číslo β je rychlost nakažlivých kontaktů, γ rychlost uzdravování ($\frac{1}{\gamma}$ je průměrná doba nemoci). **Základní reprodukční číslo** je

$$R_0 = \frac{\beta}{\gamma}.$$

Odkud se rovnice berou? Nakažení se setkávají s náchylnými. Počet takových setkání za jednotku času je úměrný $S \cdot I$ (jako u chemické reakce dvou látek), a část z nich vede k nákaze. Tak vzniká člen βSI, který ubírá z S a přidává do I. Nakažení se zároveň uzdravují rychlostí γI. A R_0 je počet lidí, které jeden nakažený nakazí v plně náchylné populaci: za den nakazí β lidí a nemocný je průměrně $\frac{1}{\gamma}$ dní.



Obrázek je numerické řešení pro $\beta = 0{,}3$, $\gamma = 0{,}1$ (nemoc trvá průměrně 10 dní, $R_0 = 3$), na začátku je nakaženo 1 % populace. Epidemie nejdřív roste téměř exponenciálně, kolem 27. dne vrcholí s asi 30 % současně nakažených a pak odezní. Nakonec projde nemocí asi 94 % lidí.

38.1.1 Kolektivní imunita

Počet nakažených roste, právě když $\frac{\mathrm{d}I}{\mathrm{d}t} = I(\beta S - \gamma) > 0$, tedy když

$$S > \frac{\gamma}{\beta} = \frac{1}{R_0}.$$

Epidemie tedy nemůže propuknout, pokud je náchylných méně než $\frac{1}{R_0}$. Jinými slovy, imunní musí být aspoň podíl

$$p_c = 1 - \frac{1}{R_0}$$

populace. To je **práh kolektivní imunity**. Pro $R_0 = 3$ je to $\frac{2}{3}$. Spalničky mají R_0 zhruba 12 až 18, a proto je potřeba proočkovanost přes 92 %. Na obrázku je vidět i druhá stránka věci: vrchol nastane přesně ve chvíli, kdy S klesne na $\frac{1}{R_0}$. Po vrcholu ale epidemie ještě dlouho ‘dobíhá’ a nakazí mnohem víc lidí, než je práh.

Příklad 38.1.1 Výška vrcholu. Vydělíme rovnice pro I a S:

$$\frac{\mathrm{d}I}{\mathrm{d}S} = \frac{\beta SI - \gamma I}{-\beta SI} = -1 + \frac{1}{R_0 S} \qquad \Longrightarrow \qquad I + S - \frac{1}{R_0}\ln S = \text{konst.}$$

Ve vrcholu je $S = \frac{1}{R_0}$, takže

$$I_{\max} = I_0 + S_0 - \frac{1}{R_0} - \frac{1}{R_0}\ln(R_0 S_0) = 1 - \frac{1}{3} - \frac{1}{3}\ln 2{,}97 \approx 0{,}304.$$

Podobně z $\frac{\mathrm{d}S}{\mathrm{d}R} = -R_0 S$ plyne $S = S_0 \mathrm{e}^{-R_0 R}$. Na konci je $I = 0$, $R_\infty = 1 - S_\infty$, a dostaneme rovnici $S_\infty = S_0 \mathrm{e}^{-R_0(1-S_\infty)}$ s řešením $S_\infty \approx 0{,}06$.

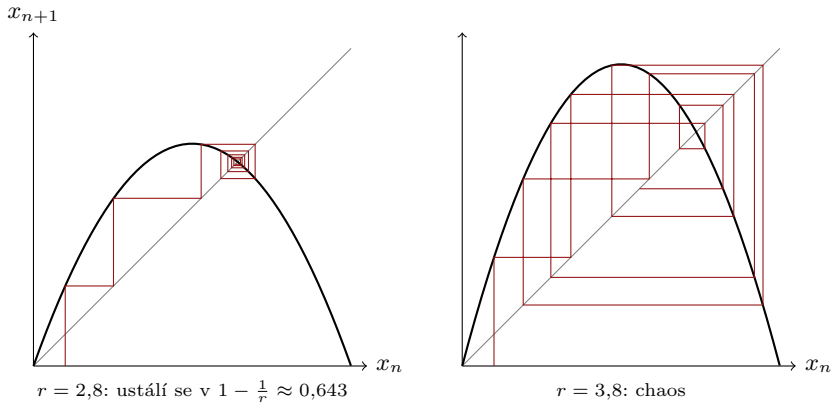
38.2 Populace a chaos: logistické zobrazení

Populace hmyzu v jednom roce určuje populaci v roce příštím. Je-li $x_n \in [0, 1]$ velikost populace jako podíl maximální kapacity prostředí, jednoduchý model je

$$x_{n+1} = r x_n (1 - x_n).$$

Člen rx_n je rozmnožování, člen $(1 - x_n)$ brzdí růst, když je jedinců moc (nedostatek potravy). Parametr $r \in [0, 4]$ udává plodnost. Robert May v roce 1976 v časopise Nature upozornil, že tento nevinně vypadající vzorec skrývá neuvěřitelně složité chování.

Iterace se dobře kreslí **pavučinovým diagramem**: z bodu x_n jdeme svisle ke grafu paraboly (to je x_{n+1}) a vodorovně k přímce $y = x$ (tím se x_{n+1} stane novým vstupem).

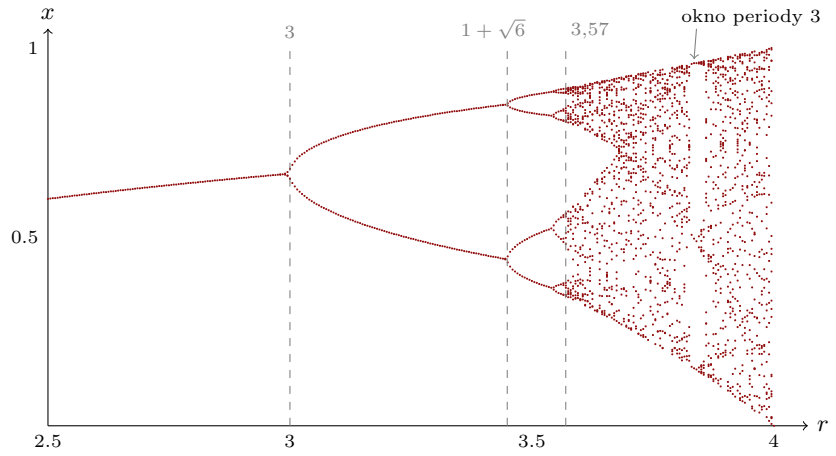


Příklad 38.2.1 Pevný bod a jeho stabilita. Pevný bod splňuje $x = rx(1-x)$, tedy $x = 0$ nebo $x^* = 1 - \frac{1}{r}$. Pevný bod iterace $x_{n+1} = f(x_n)$ je stabilní (blízké body se k němu přibližují), pokud $|f'(x^*)| < 1$. Odchylka ε se totiž podle Taylorova rozvoje změní na $f(x^* + \varepsilon) \approx x^* + f'(x^*)\varepsilon$, tedy se každý krok vynásobí číslem $f'(x^*)$. Zde $f'(x) = r(1-2x)$ a

$$f'(x^*) = r\left(1 - 2 + \frac{2}{r}\right) = 2 - r.$$

Podmínka $|2 - r| < 1$ dává $1 < r < 3$. Pro $r = 2{,}8$ je $f'(x^*) = -0{,}8$: odchylka se zmenšuje a střídá znaménko, proto pavučina obíhá kolem pevného bodu dovnitř.

Co se děje pro $r > 3$? Pevný bod ztratí stabilitu a populace začne střídat dvě hodnoty: rok hojnosti, rok bídy. Při $r = 1 + \sqrt{6} \approx 3{,}449$ se i tento cyklus rozdvojí na cyklus délky 4, pak 8, 16, … Zdvojení přicházejí stále rychleji a kolem $r \approx 3{,}5699$ je jich nekonečně mnoho. Za touto hranicí začíná **chaos**.



Na **bifurkačním diagramu** je pro každé r vyneseno, kterými hodnotami populace prochází po odeznění počátečního přechodu. Vlevo jediná hodnota, pak vidlička na dvě, na čtyři… a pak ‘šum’. V chaosu jsou ale vidět i bílá **okna**, například kolem $r \approx 3{,}83$ se populace náhle zase pravidelně opakuje s periodou 3. Poměry délek po sobě jdoucích intervalů mezi zdvojeními konvergují k číslu $\delta \approx 4{,}669$, které objevil Mitchell Feigenbaum. Totéž číslo se objeví u každého podobného ‘hrbolatého’ zobrazení, je to univerzální konstanta jako π.

Příklad 38.2.2 Chaos pro $r = 4$ je přesně spočitatelný. Zapišme $x_n = \sin^2 \theta_n$. Pak

$$x_{n+1} = 4\sin^2\theta_n(1 - \sin^2\theta_n) = 4\sin^2\theta_n\cos^2\theta_n = \sin^2(2\theta_n).$$

Tedy $\theta_n = 2^n\theta_0$: úhel se každý krok zdvojnásobí. Malá nejistota v θ_0, třeba v desáté desetinné cifře, se za 34 kroků zvětší $2^{34} \approx 1{,}7 \cdot 10^{10}$krát a předpověď je bezcenná. To je **citlivost na počáteční podmínky**, podstata chaosu. Systém je přitom zcela deterministický, žádná náhoda v něm není.

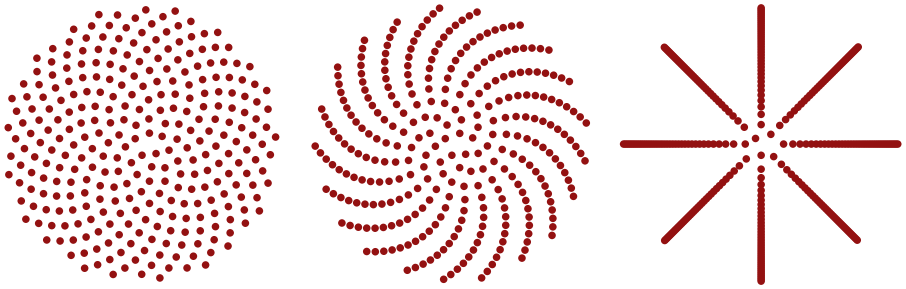
38.3 Slunečnice a zlatý úhel

Semínka v květu slunečnice vyrůstají jedno po druhém ze středu a každé nové se pootočí o stejný úhel vůči předchozímu. Starší semínka se odsouvají ven. Model (Vogel, 1979): n-té semínko leží v polárních souřadnicích

$$r_n = c\sqrt{n}, \qquad \theta_n = n \cdot \alpha.$$

Odmocnina zajistí, že plocha kruhu s n semínky, $\pi r_n^2 = \pi c^2 n$, roste úměrně n, takže hustota je všude stejná. Zbývá zvolit úhel α. Příroda volí **zlatý úhel**

$$\alpha = 360^\circ \left(1 - \frac{1}{\varphi}\right) = \frac{360^\circ}{\varphi^2} \approx 137{,}508^\circ, \qquad \varphi = \frac{1+\sqrt{5}}{2}.$$



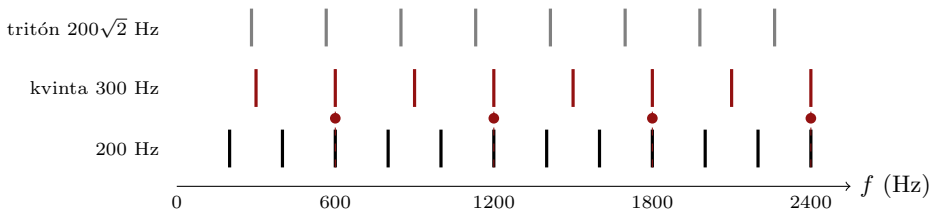
137,508° (zlatý úhel) 137° 135° = $\frac{3}{8}$ otáčky

Se zlatým úhlem (vlevo) vyplní semínka plochu rovnoměrně a bez mezer. Oko v nich vidí spirály, a když je spočítáte, vyjdou sousední Fibonacciho čísla, u skutečných slunečnic typicky 34 a 55 nebo 55 a 89. Už při 137° (uprostřed) se objeví výrazná ramena s mezerami mezi nimi. A při racionálním úhlu $\frac{3}{8}$ otáčky (vpravo) leží každé osmé semínko na stejném paprsku, takže vznikne osm paprsků a obrovské prázdné výseče.

Proč? Pokud je úhel α blízko zlomku $\frac{p}{q}$ otáčky, semínka n a $n+q$ leží skoro na stejném paprsku a vznikne q ramen. Čím lépe lze $\frac{\alpha}{360^\circ}$ aproximovat zlomkem s malým jmenovatelem, tím dřív se ramena objeví a tím víc místa se plýtvá. Ideální úhel je tedy ten, jehož podíl otáčky je *nejhůře aproximovatelný zlomky*, ‘nejiracionálnější’ číslo. Že je to právě $\frac{1}{\varphi^2}$ (a φ), uvidíme v odbočce.

38.4 Hudba: zlomky, které zní dobře

Tón je kmitání vzduchu, jeho výška je **frekvence** f v hertzích. Komorní a^1 má 440 Hz. Struna ale nekmitá jen základní frekvencí: zní v ní i **vyšší harmonické** $2f$, $3f$, $4f$, … (jejich poměr určuje barvu zvuku, jak jsme viděli u Fourierových řad v kapitole 29). Dva tóny zní **souzvučně**, když se mnoho jejich harmonických shoduje, a **nelibě**, když se harmonické míjejí těsně vedle sebe a ‘drhnou’.



Tón 200 Hz a tón o **kvintu** výš, 300 Hz, s poměrem 3 : 2 mají společnou každou třetí, respektive každou druhou harmonickou: 600, 1200, 1800, … Hz. Ucho slyší shodu a interval zní ‘čistě’. Ještě čistší je **oktáva** 2 : 1, při ní jsou všechny harmonické horního tónu harmonickými dolního. Tón v poměru $\sqrt{2}$ (tritón, kdysi přezdívaný ‘ďábel v hudbě’) nemá s dolním tónem společnou žádnou harmonickou, protože $\sqrt{2}$ je iracionální. Harmonické se jen míjejí, třeba 1414 Hz vedle 1400 Hz, a interval zní napjatě.

38.4.1 Rovnoměrné ladění a Pythagorejské koma

Pythagorejci stavěli stupnici z čistých kvint. Vystoupáme-li ale o 12 kvint, měli bychom se dostat na stejný tón jako po 7 oktávách. Nedostaneme:

$$\left(\frac{3}{2}\right)^{12} = \frac{531\,441}{4\,096} \approx 129{,}75, \qquad 2^7 = 128, \qquad \frac{3^{12}}{2^{19}} = \frac{531\,441}{524\,288} \approx 1{,}0136.$$

Rozdílu se říká **Pythagorejské koma**. Nemůže být nula, protože 3^{12} je liché a 2^{19} sudé. Žádná mocnina čísla $\frac{3}{2}$ není mocninou dvojky, čistými kvintami se kruh nikdy neuzavře.

Rovnoměrně temperované ladění dělí oktávu na 12 stejných půltónů s poměrem $2^{1/12} \approx 1{,}059\,46$. Tón o k půltónů nad a^1 má frekvenci $440 \cdot 2^{k/12}$ Hz.

interval	půltóny	čistý poměr	$2^{k/12}$
oktáva	12	2	2
kvinta	7	1,5	1,4983
kvarta	5	1,3333	1,3348
velká tercie	4	1,25	1,2599

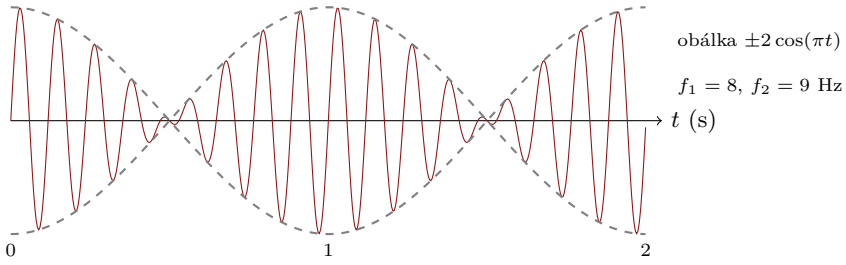
Rovnoměrné ladění je kompromis: všechny intervaly kromě oktávy jsou trochu ‘falešně’, ale ve všech tóninách stejně, takže lze volně modulovat. Kvinta je pokřivená jen o 0,1 %, velká tercie ale o 0,8 %, což cvičené ucho slyší. Přesný výpočet $2^{1/12}$ publikoval čínský princ Zhu Zaiyu v roce 1584. Proč zrovna 12? Protože $2^{7/12}$ je nečekaně dobrá aproximace čísla $\frac{3}{2}$. Ekvivalentně je $\frac{7}{12}$ dobrá aproximace čísla $\log_2 \frac{3}{2} \approx 0{,}585$, a to je jeden z řetězových zlomků, o nichž bude řeč v odbočce.

38.4.2 Zázněje

Dva tóny s blízkými frekvencemi f_1 a f_2 se skládají podle vzorce pro součet sinů z kapitoly 10:

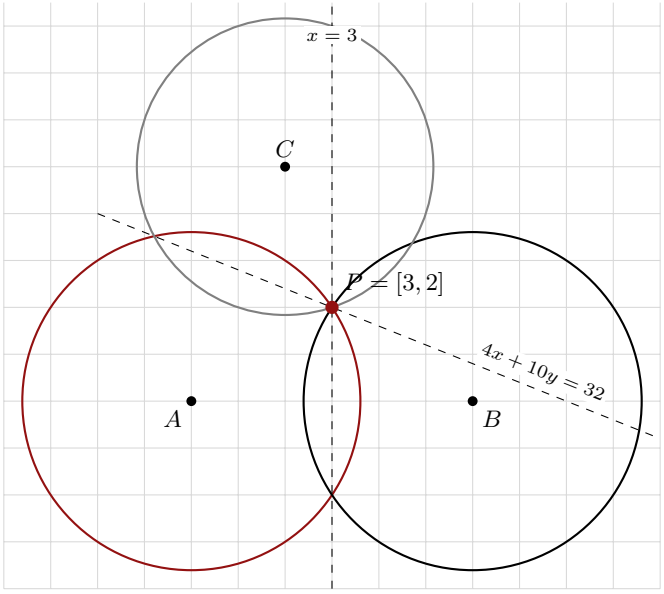
$$\sin(2\pi f_1 t) + \sin(2\pi f_2 t) = 2\cos\big(\pi(f_1 - f_2)t\big)\sin\big(\pi(f_1 + f_2)t\big).$$

Slyšíme průměrnou frekvenci $\frac{f_1+f_2}{2}$, jejíž hlasitost pomalu pulzuje. Obálka $2|\cos(\pi(f_1-f_2)t)|$ má periodu $\frac{1}{|f_1-f_2|}$, takže hlasitost kolísá $|f_1 - f_2|$krát za sekundu. Tomu se říká **zázněje**. Ladiči klavírů je využívají: dokud zázněje slyší, struny nejsou naladěné stejně.



38.5 GPS: kružnice, hodiny a relativita

Každá družice GPS vysílá svou polohu a přesný čas vyslání. Přijímač změří, kdy signál dorazil, a rozdíl časů vynásobený rychlostí světla c je vzdálenost k družici. Bod ve známé vzdálenosti od družice leží na kouli kolem ní, a průsečík několika koulí je naše poloha. Princip se jmenuje **trilaterace**. Ve 2D jsou to kružnice:



Příklad 38.5.1 Družice (majáky) jsou v bodech $A = [0, 0]$, $B = [6, 0]$, $C = [2, 5]$ a změřené vzdálenosti jsou $\sqrt{13}$, $\sqrt{13}$, $\sqrt{10}$. Rovnice kružnic

$$x^2 + y^2 = 13, \qquad (x-6)^2 + y^2 = 13, \qquad (x-2)^2 + (y-5)^2 = 10$$

jsou kvadratické, ale jejich rozdíly jsou lineární, protože členy $x^2 + y^2$ se odečtou. První minus druhá: $12x - 36 = 0$, tedy $x = 3$. První minus třetí: $4x - 4 + 10y - 25 = 3$, tedy $4x + 10y = 32$ a $y = 2$. Odečtené rovnice jsou přímky z kapitoly 14 (na obrázku čárkovaně), na nichž leží společné tětivy dvojic kružnic.

Ve 3D potřebujeme tři koule. Proč tedy GPS potřebuje *čtyři* družice? Kvůli hodinám. Družice nesou atomové hodiny, ale přijímač v telefonu má obyčejné křemenné hodiny, které se mohou rozcházet o neznámou odchylku b. Chyba hodin o jedinou mikrosekundu je chyba vzdálenosti $c \cdot 10^{-6}\,\mathrm{s} \approx 300$ m. Změřená 'pseudovzdálenost' k družici i je proto

$$\rho_i = \sqrt{(x - x_i)^2 + (y - y_i)^2 + (z - z_i)^2} + c \cdot b,$$

a neznámé jsou čtyři: x, y, z a b. Na čtyři neznámé potřebujeme čtyři rovnice. Přijímač tak mimochodem zjistí i velmi přesný čas.

38.5.1 Relativita v kapse

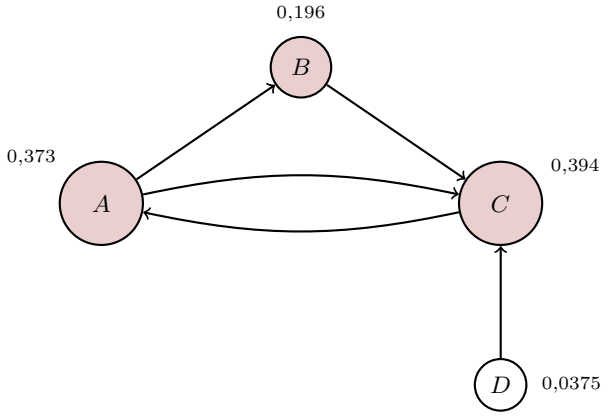
Družice GPS obíhají ve výšce asi 20 200 km rychlostí asi 3,9 km/s. Na jejich hodinách se projeví oba efekty Einsteinovy relativity:

- **Speciální relativita**: pohybující se hodiny jdou pomaleji, relativně o $\frac{v^2}{2c^2} = \frac{(3\,874)^2}{2\cdot(3\cdot 10^8)^2} \approx 8{,}3 \cdot 10^{-11}$. Za den (86 400 s) to dělá asi -7 µs.
- **Obecná relativita**: hodiny v slabším gravitačním poli jdou rychleji, relativně o $\frac{GM}{c^2}\left(\frac{1}{R_Z} - \frac{1}{r}\right) \approx 5{,}3 \cdot 10^{-10}$, kde $R_Z = 6\,371$ km je poloměr Země a $r \approx 26\,570$ km poloměr dráhy. Za den asi $+45$ µs.

Celkem jdou hodiny na družici o zhruba 38 µs denně rychleji. Vynásobeno rychlostí světla to je asi 11 km za den. Bez relativistické korekce by se GPS každý den rozladilo zhruba o deset kilometrů. Inženýři proto hodiny na družicích ještě před startem nastavili tak, aby na Zemi tikaly o tento rozdíl pomaleji: místo frekvence 10,23 MHz mají 10,229 999 995 43 MHz. Na oběžné dráze pak jdou správně.

38.6 PageRank: náhodný surfař

Jak poznat, která webová stránka je důležitá? Larry Page a Sergey Brin v roce 1998 navrhli: stránka je důležitá, pokud na ni odkazují důležité stránky. Zní to jako kruh v definici, ale je to přesně rovnice pro vlastní vektor.



Náhodný surfař klikne na stránce na náhodný odkaz (každý se stejnou pravděpodobností). Pravděpodobnosti, že je na stránkách $1, \dots, N$, tvoří vektor $\vec{x}$, který se jedním kliknutím změní na $M\vec{x}$, kde $M_{ij} = \frac{1}{\text{počet odkazů ze stránky } j}$, pokud j odkazuje na i, jinak $M_{ij} = 0$. Je to **Markovův řetězec**. **PageRank** je jeho **stacionární rozdělení**, vektor s

$$M\vec{x} = \vec{x}, \qquad x_1 + \cdots + x_N = 1,$$

tedy vlastní vektor matice M s vlastním číslem 1.

Příklad 38.6.1 Pro graf na obrázku ($A \to B$, $A \to C$, $B \to C$, $C \to A$, $D \to C$) označme složky vektoru $\vec{x}$ jako x_A, x_B, x_C, x_D. Stránka A má dva odkazy, takže každý dostane polovinu její váhy. Stacionární rovnice jsou

$$x_A = x_C, \qquad x_B = \tfrac{1}{2}x_A, \qquad x_C = \tfrac{1}{2}x_A + x_B + x_D, \qquad x_D = 0.$$

Na D nic neodkazuje, takže tam surfař nikdy nezůstane. Z normalizace $x_A + \frac{1}{2}x_A + x_A = 1$ dostaneme $\vec{x} = (0{,}4;\ 0{,}2;\ 0{,}4;\ 0)$.

Čistý model má dvě vady. Stránka bez odkazů je past, ze které surfař neuteče, a stránka, na kterou nic neodkazuje, má PageRank nula. Page a Brin proto přidali **tlumení**: s pravděpodobností $d = 0{,}85$ surfař klikne na odkaz, s pravděpodobností $1 - d = 0{,}15$ se znudí a skočí na úplně náhodnou stránku. Nová matice je

$$G = dM + \frac{1-d}{N}\mathbf{1},$$

kde $\mathbf{1}$ je matice ze samých jedniček. Pro náš graf vyjde $x_D = \frac{0{,}15}{4} = 0{,}0375$ (na D se dá dostat jen skokem) a

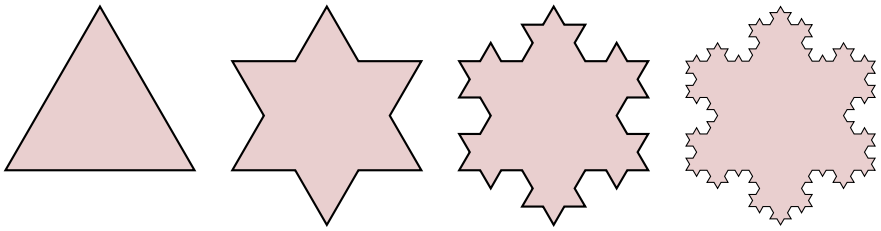
$$x_A = 0{,}0375 + 0{,}85x_C, \qquad x_B = 0{,}0375 + 0{,}425x_A, \qquad x_C = 0{,}0375 + 0{,}85\left(\tfrac{1}{2}x_A + x_B + 0{,}0375\right).$$

Dosazením dostaneme $x_A = \frac{659}{1769} \approx 0{,}373$, $x_B \approx 0{,}196$, $x_C \approx 0{,}394$ a $x_D = 0{,}0375$ (součet je 1). Nejdůležitější je C, na kterou odkazují tři stránky. Ale A s jediným příchozím odkazem je skoro stejně důležitá, protože ten odkaz přichází od C.

Poznámka 38.6.2 Proč stacionární vektor existuje a je jediný? Matice G má všechny prvky kladné a součet každého sloupce je 1. **Perronova–Frobeniova věta** pak zaručuje, že vlastní číslo 1 je největší, má jediný kladný vlastní vektor a všechna ostatní vlastní čísla mají absolutní hodnotu nejvýš d. Proto **mocninná metoda** $\vec{x}_{k+1} = G\vec{x}_k$ z libovolného startu konverguje, s chybou klesající zhruba jako $0{,}85^k$. Na celém webu stačí několik desítek iterací. Pro náš graf: $(0{,}25;\ 0{,}25;\ 0{,}25;\ 0{,}25) \to (0{,}25;\ 0{,}144;\ 0{,}569;\ 0{,}038) \to (0{,}521;\ 0{,}144;\ 0{,}298;\ 0{,}038) \to \cdots$

38.7 Fraktály: Kochova vločka a délka pobřeží

Kochova vločka (Helge von Koch, 1904): začneme rovnostranným trojúhelníkem. V každém kroku každou úsečku rozdělíme na třetiny a nad prostřední třetinou postavíme rovnostranný trojúhelník (a jeho základnu odstraníme). Vločka je limita tohoto procesu.



Příklad 38.7.1 Obvod. Každý krok nahradí každou úsečku čtyřmi úsečkami třetinové délky, takže obvod se vynásobí $\frac{4}{3}$. Při počáteční straně 1 je obvod po n krocích $3 \cdot \left(\frac{4}{3}\right)^n \to \infty$.

Obsah. Nechť T je obsah počátečního trojúhelníku. V n-tém kroku přidáme jeden nový trojúhelník na každou z $3 \cdot 4^{n-1}$ úseček, a každý má stranu 3^{-n}, tedy obsah $\frac{T}{9^n}$. Celkem

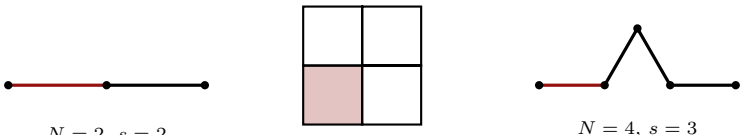
$$T + \sum_{n=1}^{\infty} 3 \cdot 4^{n-1} \cdot \frac{T}{9^n} = T + \frac{T}{3} \sum_{n=1}^{\infty} \left(\frac{4}{9}\right)^{n-1} = T + \frac{T}{3} \cdot \frac{1}{1 - \frac{4}{9}} = T + \frac{3}{5}T = \frac{8}{5}T.$$

Vločka má tedy **nekonečný obvod a konečný obsah**. Vejde se do kruhu opsaného počátečnímu trojúhelníku, a přesto je její hranice nekonečně dlouhá. Je to přesně situace, na kterou narazil anglický matematik Lewis Fry Richardson, když zjistil, že délky hranice mezi Španělskem a Portugalskem uváděné v různých zdrojích se výrazně liší. Čím kratší měřítko použijete, tím víc zálivů a výběžků změříte a tím je pobřeží delší. Mandelbrot o tom v roce 1967 napsal slavný článek *Jak dlouhé je pobřeží Británie?* a odpověď zní: záleží na délce pravítka, a bez omezení roste nade všechny meze. **Paradox pobřeží.**

38.7.1 Fraktální dimenze

Úsečka se skládá z 2 kopií sebe sama zmenšených na polovinu, čtverec ze $4 = 2^2$ kopií, krychle z $8 = 2^3$ kopií. Obecně: útvar dimenze D se skládá z $N = s^D$ kopií zmenšených $s$krát. Odtud

$$D = \frac{\log N}{\log s}.$$



Kochova křivka se skládá ze 4 kopií zmenšených 3krát, takže její dimenze je $\frac{\log 4}{\log 3} \approx 1{,}2619$. Je 'víc než čára' (proto má nekonečnou délku), ale 'míň než plocha' (proto má nulový obsah). Richardsonova měření dávají pro západní pobřeží Británie dimenzi zhruba 1,25, pro hladké pobřeží Jižní Afriky skoro přesně 1. Fraktály se objevují všude, kde příroda opakuje stejný proces v různých měřítkách: v rozvětvení plic a cév, v kapradinách, v blescích, v mracích, v říčních sítích.

38.8 Včely a šestiúhelníky

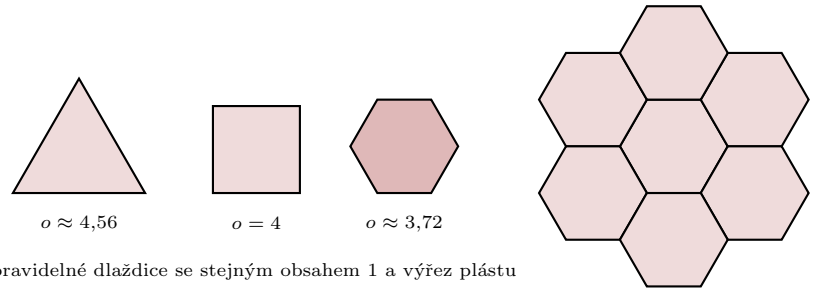
Včela potřebuje rozdělit plochu plástu na buňky stejného obsahu a spotřebovat přitom co nejméně vosku na stěny. Kterým pravidelným mnohoúhelníkem to jde?

Nejdřív: pravidelným n-úhelníkem lze rovinu vydláždit jen tehdy, když jeho vnitřní úhel $\frac{(n-2)\cdot 180^\circ}{n}$ dělí 360°, tedy když $\frac{2n}{n-2} = 2 + \frac{4}{n-2}$ je celé číslo. To nastane, jen když $n-2$ dělí 4, tedy pro $n = 3, 4, 6$. Jsou jen tři možnosti.

Příklad 38.8.1 Porovnáme obvody pro obsah 1. Rovnostranný trojúhelník se stranou a má obsah $\frac{\sqrt{3}}{4}a^2$, čtverec a^2, pravidelný šestiúhelník (šest rovnostranných trojúhelníků) $\frac{3\sqrt{3}}{2}a^2$. Pro obsah 1:

$$\begin{aligned} \text{trojúhelník:} \quad & a = \sqrt{4/\sqrt{3}} \approx 1{,}520, && o = 3a \approx 4{,}559, \\ \text{čtverec:} \quad & a = 1, && o = 4, \\ \text{šestiúhelník:} \quad & a = \sqrt{2/(3\sqrt{3})} \approx 0{,}620, && o = 6a \approx 3{,}722. \end{aligned}$$

Šestiúhelník vyhrává, o 7 % proti čtverci a o 18 % proti trojúhelníku. Kruh by měl obvod $2\sqrt{\pi} \approx 3{,}545$, ale kruhy rovinu nevydláždí.



tři pravidelné dlaždice se stejným obsahem 1 a výřez plástu

Navíc každá stěna v plástu patří dvěma buňkám, takže na buňku připadá polovina obvodu. Že šestiúhelníky jsou nejlepší i mezi *všemi* rozděleními roviny na stejně velké oblasti, ne jen mezi pravidelnými mnohoúhelníky, tušil už Pappos z Alexandrie ve 4. století. Dokázal to až Thomas Hales v roce 1999.

38.9 Odbočka — Řetězové zlomky a nejiracionálnější číslo

Řetězový zlomek čísla x vznikne opakováním: odděl celou část, zbytek převrať.

$$x = a_0 + \cfrac{1}{a_1 + \cfrac{1}{a_2 + \cfrac{1}{a_3 + \cdots}}} = [a_0; a_1, a_2, a_3, \dots].$$

Useknutím po k krocích dostaneme **sblížený zlomek** $\frac{p_k}{q_k}$.

Příklad 38.9.1 $\pi = 3{,}14159\ldots$: celá část 3, zbytek 0,14159, převrácená hodnota 7,0625. Celá část 7, zbytek převrácený 15,996, a tak dál: $\pi = [3; 7, 15, 1, 292, \dots]$. Sblížené zlomky jsou 3, $\frac{22}{7}$, $\frac{333}{106}$, $\frac{355}{113}$, … Protože další člen 292 je velký, je $\frac{355}{113} = 3{,}141\,592\,9\ldots$ neobyčejně přesné (chyba $3 \cdot 10^{-7}$). Velký člen řetězového zlomku znamená ‘skvělá aproximace přišla brzo’.

Platí obecná věta: sblížené zlomky splňují $\left|x - \frac{p_k}{q_k}\right| < \frac{1}{q_k q_{k+1}} \le \frac{1}{a_{k+1} q_k^2}$. Čím větší jsou členy a_k, tím lépe se číslo dá aproximovat. Nejhůř aproximovatelné je tedy číslo, jehož členy jsou všechny co nejmenší, tedy rovny 1:

$$x = 1 + \cfrac{1}{1 + \cfrac{1}{1 + \cdots}} \quad \Longrightarrow \quad x = 1 + \frac{1}{x} \quad \Longrightarrow \quad x^2 - x - 1 = 0 \quad \Longrightarrow \quad x = \frac{1+\sqrt{5}}{2} = \varphi.$$

Zlatý řez je $[1; 1, 1, 1, \dots]$. Jeho sblížené zlomky jsou podíly sousedních Fibonacciho čísel:

$$\frac{1}{1}, \frac{2}{1}, \frac{3}{2}, \frac{5}{3}, \frac{8}{5}, \frac{13}{8}, \frac{21}{13}, \dots, \frac{F_{k+1}}{F_k}.$$

Opravdu: je-li $\frac{p}{q}$ sblížený zlomek, další je $1 + \frac{1}{p/q} = \frac{p+q}{p}$, což je přesně Fibonacciho pravidlo.

Hurwitzova věta (1891): Pro každé iracionální x existuje nekonečně mnoho zlomků $\frac{p}{q}$ s

$$\left| x - \frac{p}{q} \right| < \frac{1}{\sqrt{5}\, q^2}.$$

Konstantu $\sqrt{5}$ nelze zvětšit. Pro $x = \varphi$ by pro větší konstantu existovalo jen konečně mnoho takových zlomků.

Proč je φ hraniční, je vidět z Fibonacciho čísel. Platí Cassiniho identita $F_{k+1}F_{k-1} - F_k^2 = (-1)^k$, odkud $\left|\varphi - \frac{F_{k+1}}{F_k}\right|$ je přibližně $\frac{1}{\sqrt{5}F_k^2}$ a konstantu zlepšit nelze. Zpět ke slunečnici: zlatý úhel je $\frac{1}{\varphi^2} = 2 - \varphi$ otáčky, a i jeho řetězový zlomek $[0; 2, 1, 1, 1, \dots]$ má samé malé členy. Jeho nejlepší aproximace jsou $\frac{1}{3}$, $\frac{2}{5}$, $\frac{3}{8}$, $\frac{5}{13}$, $\frac{8}{21}$, $\frac{13}{34}$, $\frac{21}{55}$, … Jmenovatele aproximací jsou Fibonacciho čísla, a protože ramena se objevují podle jmenovatelů, spirály v květu jsou počítány Fibonacciho čísly. Žádná aproximace není ‘příliš dobrá’, a tak žádná soustava ramen nezačne dominovat a nenechá mezery.

38.10 Příběh — Pumpa na Broad Street

V srpnu 1854 udeřila v londýnské čtvrti Soho cholera. Během deseti dnů zemřelo přes pět set lidí v okruhu několika ulic, celkem jich bylo přes šest set. Lékařská věda té doby věřila, že cholera se šíří ‘miasmatem’, zkaženým vzduchem z hnijících odpadků. Lékař John Snow, známý mimo jiné tím, že při porodu prince Leopolda podal královně Viktorii chloroform, si myslel něco jiného: že nemoc se přenáší vodou.

Snow obcházel domy, zapisoval adresy zemřelých a zanášel je jako čárky do mapy čtvrti. Mapa ukázala zřetelné shluky kolem jediné veřejné pumpy na Broad Street. Výjimky jeho teorii jen potvrzovaly. Chudobinec s více než pěti sty obyvateli, jen kousek od pumpy, měl vlastní studnu a téměř žádné oběti. Dělníci z místního pivovaru pili pivo, které dostávali jako součást mzdy, a nezemřel ani jeden. A naopak vdova z Hampsteadu, kilometry daleko, zemřela na choleru, i když v jejím okolí nikdo jiný neonemocněl. Vodu z Broad Street měla tak ráda, že si ji nechávala vozit v lahvích.

Sedmého září předložil Snow svá data místní radě. Rada mu příliš nevěřila, ale druhý den nechala z pumpy odmontovat rukojeť. Epidemie v tu dobu už sama slábla, protože mnoho obyvatel uprchlo. Až později místní farář Henry Whitehead, který chtěl Snowovu teorii původně vyvrátit, dohledal pravděpodobný počátek: pětiměsíční holčičku z domu číslo 40, jejíž matka prala plenky a vylévala vodu do žumpy jen pár stop od studny. Holčička zemřela.

Úřední zpráva Snowovo vysvětlení odmítla a rukojeť byla po čase vrácena. Snow zemřel v roce 1858, ve čtyřiceti pěti letech, aniž by se dočkal uznání. Teprve po letech se jeho mapa stala jedním z nejslavnějších obrázků v dějinách vědy a Snow zakladatelem epidemiologie. Byla to statistika a geometrie, ne mikroskop, co poprvé ukázalo, jak se nemoc šíří.

38.11 Shrnutí a otázky

Cvičení 38.11.1 Vypočítejte:

(a) Nemoc má $R_0 = 5$. Jaká část populace musí být imunní, aby epidemie nepropukla?

(b) Pro která r je pevný bod logistického zobrazení kladný a stabilní? Jaký je pro $r = 2{,}5$?

(c) Kolikrát se zvětší obvod Kochovy vločky po 10 krocích? Jaká je fraktální dimenze útvaru, který se skládá z 8 kopií zmenšených 3krát?

(d) Kolik hertzů má tón o kvintu (7 půltónů) nad $a^1 = 440$ Hz v rovnoměrném ladění a kolik v čistém ladění? Kolik záznějů za sekundu spolu vydají?

Řešení 38.11.1

(a) $1 - \frac{1}{5} = 80\,\%$.

(b) Pro $1 < r < 3$, kdy $|2 - r| < 1$. Pro $r = 2{,}5$ je $x^* = 1 - \frac{1}{2{,}5} = 0{,}6$.

(c) $\left(\frac{4}{3}\right)^{10} \approx 17{,}8$krát. $D = \frac{\log 8}{\log 3} \approx 1{,}89$ (to je Sierpińského koberec).

(d) $440 \cdot 2^{7/12} \approx 659{,}26$ Hz a $440 \cdot \frac{3}{2} = 660$ Hz. Zázněje: asi 0,74 za sekundu (u třetí harmonické tónu a^1 a druhé harmonické kvinty, 1320 proti 1318,5 Hz, je to 1,5 záznějů za sekundu).

Cvičení 38.11.2 Odpovězte vlastními slovy:

1. Odkud se v modelu SIR bere člen βSI a co znamená R_0?
2. Odvoďte práh kolektivní imunity $1 - \frac{1}{R_0}$. Proč epidemie nakazí víc lidí, než je tento práh?
3. Proč je pevný bod logistického zobrazení stabilní jen pro $1 < r < 3$? Co se stane pak?
4. Co je citlivost na počáteční podmínky a jak ji ukazuje substituce $x = \sin^2 \theta$ pro $r = 4$?
5. Proč slunečnice používá zlatý úhel a proč se v ní objevují Fibonacciho čísla?
6. Proč zní kvinta souzvučně a proč se kruh čistých kvint nikdy neuzavře?
7. Proč potřebuje GPS čtyři družice a proč musí počítat s relativitou?
8. Jak souvisí PageRank s vlastním vektorem matice? K čemu je tlumení $d = 0{,}85$?
9. Jak může mít Kochova vločka nekonečný obvod a konečný obsah? Co je fraktální dimenze?
10. Proč včely stavějí šestiúhelníkové buňky?

Kapitola 39

Matematika v hudbě

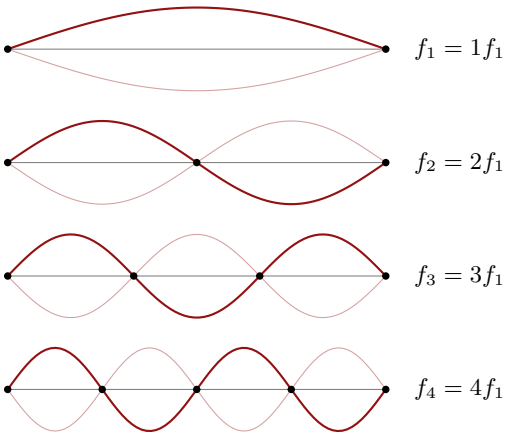
Hudba je skryté cvičení v aritmetice, při kterém duše neví, že počítá.

Gottfried Wilhelm Leibniz

V kapitole 38 jsme viděli, že tón je kmitání vzduchu, že kvinta je poměr frekvencí $3:2$ a že dvanáct kvint se nikdy úplně nepotká se sedmi oktávami. V této kapitole půjdeme hlouběji. Proč zní některé dvojice tónů dobře a jiné ne? Proč má oktáva právě dvanáct půltónů a ne deset? Proč je mollový akord zrcadlovým obrazem durového? A jak souvisí Eukleidův algoritmus s africkými a kubánskými rytmy? Hudební teorie je z velké části matematika, jen se o tom v hudebce moc nemluví.

39.1 Struna a řada alikvotních tónů

Napnutá struna délky L, upevněná na obou koncích, může kmitat jen tak, aby na koncích zůstala v klidu. Vejde se na ni půl vlny, celá vlna, jeden a půl vlny, a tak dál. Jde o stojaté vlnění z kapitoly 31.



Vlnová délka n-tého módu je $\frac{2L}{n}$, a tedy jeho frekvence je n-násobkem základní frekvence f_1. Struna přitom kmitá všemi módy najednou. Slyšíme tón o frekvenci f_1, ale ‘obarvený’ vyššími **alikvotními tóny** (harmonickými) $2f_1$, $3f_1$, $4f_1$, … Totéž platí pro vzduchový sloupec ve flétně nebo trubce. Na strunu ale můžeme ‘zahrát’ i jednotlivé alikvóty: když se struny kytary v polovině jen lehce dotknete, utlumíte módy s lichým n a zazní flažolet o oktávu výš.

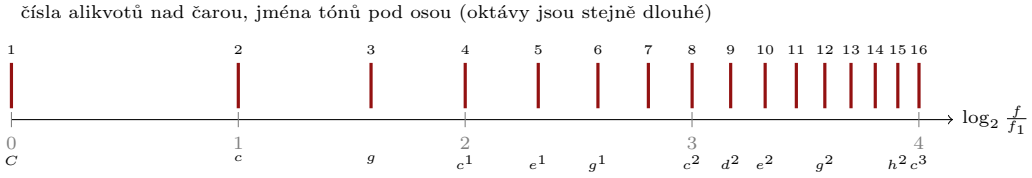
Základní frekvenci struny popisují **Mersennovy zákony** (1636):

$$f_1 = \frac{1}{2L}\sqrt{\frac{T}{\mu}},$$

kde T je napětí a μ hmotnost jednoho metru struny. Poloviční délka dává dvojnásobnou frekvenci (to je pražec v polovině hmatníku). Čtyřnásobné napětí také dvojnásobnou. A proto jsou basové struny tlusté a ovinuté drátem: velké μ snižuje tón, aniž by struna musela být metry dlouhá.

Alikvoty jako stupnice

Vynesme si alikvotní tóny tónu C na osu, na které stejná vzdálenost znamená stejný *poměr* frekvencí (tedy na logaritmickou osu z kapitoly 9). Přesně takhle totiž výšku tónu vnímá ucho.



V první oktávě je jen jeden alikvot, ve druhé přibude kvinta, ve třetí tercie a kvinta, a čím výš, tím hustěji. Uprostřed se objevují přesně ty intervaly, na kterých stojí evropská hudba. Oktáva $2:1$, kvinta $3:2$, kvarta $4:3$, velká tercie $5:4$, malá tercie $6:5$. Durový akord c^1, e^1, g^1 je doslova poskládaný z alikvotů číslo 4, 5 a 6. Proto se mu říká ‘přirozený’. Alikvoty 7, 11, 13 a 14 jsme nepojmenovali. Do běžné stupnice nepasují, a právě z nich mají svůj typický zvuk třeba alpské rohy.

39.2 Intervaly: násobení, ne sčítání

Interval je *poměr* frekvencí. Zahrát kvintu a pak ještě kvartu znamená vynásobit frekvenci $\frac{3}{2} \cdot \frac{4}{3} = 2$, tedy dohromady oktávu. Ucho ale intervaly vnímá, jako by se *sčítaly*. Mezi násobením a sčítáním je most, který už známe: logaritmus.

Velikost intervalu s poměrem frekvencí $r = \frac{f_2}{f_1}$ v **centech** je

$$c(r) = 1200 \log_2 r.$$

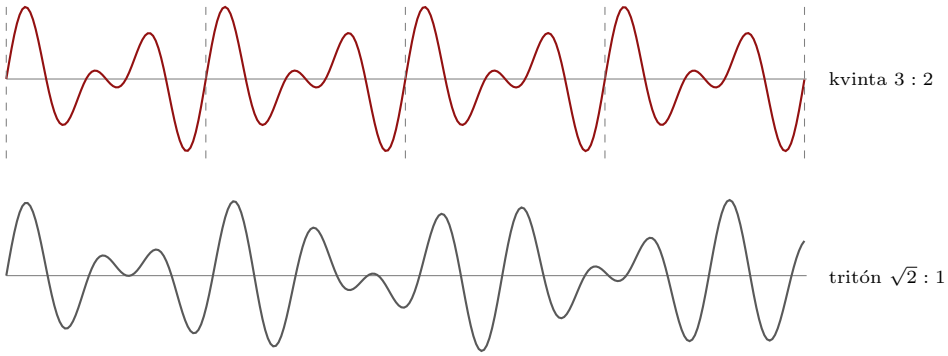
Oktáva má 1200 centů a rovnoměrně temperovaný půltón přesně 100. Platí $c(r_1 r_2) = c(r_1) + c(r_2)$, takže skládání intervalů je obyčejné sčítání centů.

interval	čistý poměr	centy (čistě)	centy (temperovaně)	rozdíl
malá tercie	6 : 5	315,6	300	−15,6
velká tercie	5 : 4	386,3	400	+13,7
kvarta	4 : 3	498,0	500	+2,0
kvinta	3 : 2	702,0	700	−2,0
malá sexta	8 : 5	813,7	800	−13,7
velká sexta	5 : 3	884,4	900	+15,6
oktáva	2 : 1	1200	1200	0

Rozdíl jednoho centu je na hranici toho, co trénované ucho rozezná. Kvinty a kvarty klavíru jsou tedy skoro čisté. Tercie jsou o celou sedminu půltónu vedle. Pěvecké sbory a smyčcová kvarteta, které nemají pevné ladění, proto tercie intuitivně ‘opravují’ k čistým poměrům.

39.3 Proč zní konsonance dobře

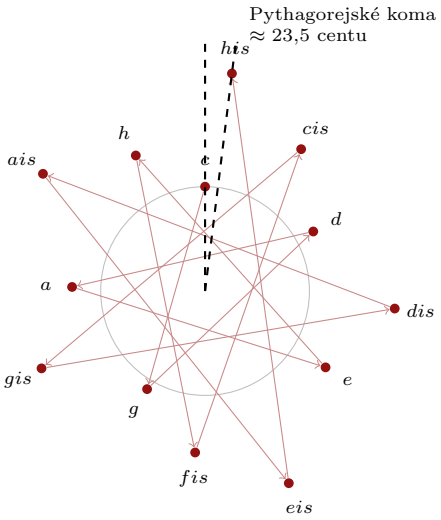
Proč zrovna jednoduché poměry? Jedna odpověď je vidět přímo na průběhu vlny. Sečtěme dvě sinusovky s poměrem frekvencí $3:2$ a dvě s poměrem $\sqrt{2}$ (rovnoměrně temperovaný tritón, ‘ďábel v hudbě’):



Kvinta dává periodický průběh, který se opakuje po každé druhé periodě nižšího tónu (čárkované čáry), protože nsn(2, 3) je malé číslo. U poměru $\sqrt{2}$ se vzor nikdy přesně neopakuje, protože $\sqrt{2}$ je iracionální. Druhá odpověď je v alikvotech (kapitola 38): u jednoduchého poměru mají oba tóny mnoho společných alikvotů a zbylé jsou od sebe daleko. U složitého poměru leží alikvoty obou tónů těsně vedle sebe a vytvářejí rychlé zázněje, které ucho vnímá jako drsnost. Moderní psychoakustika (Plomp a Levelt, 1965) tuto drsnost měří a z alikvotů dokáže předpovědět, které intervaly budou znít libě.

39.4 Spirála kvint a dvanáct tónů

Pythagorejci stavěli stupnici z kvint. Začneme na c, jdeme o kvintu výš na g, pak na d, a, e, …, a kdykoli vyletíme z oktávy, vydělíme frekvenci dvěma. Na kružnici, na které jeden oběh je jedna oktáva, je kvinta otočení o $360° \cdot \log_2 \frac{3}{2} \approx 210{,}6°$. Kdyby se dvanáct kvint potkalo se sedmi oktávami, dvanáctý krok by nás vrátil přesně na start. Nevrátí, a tak místo kruhu kreslíme spirálu:



Tón his po dvanácti kvintách je o 23,46 centu (asi čtvrtinu půltónu) výš než c. Na obrázku je to malý úhel mezi dvěma čárkovanými přímkami. Tomu se říká **Pythagorejské koma** a celé dějiny ladění jsou dějinami toho, kam ho schovat.

Poznámka 39.4.1 Proč se spirála nikdy neuzavře, ať uděláme kvint kolik chceme? Kdyby $\left(\frac{3}{2}\right)^a = 2^b$ pro přirozená a, b, pak $3^a = 2^{a+b}$. Vlevo je ale liché číslo a vpravo sudé, což podle základní věty aritmetiky z kapitoly 28 nejde. Ekvivalentně: číslo $\log_2 \frac{3}{2}$ je iracionální.

39.5 Odbočka — Proč má oktáva právě dvanáct tónů

Když se kruh čistých kvint přesně uzavřít nedá, můžeme se ptát, na kolik stejných dílů rozdělit oktávu, aby se v nich čistá kvinta schovala co nejlépe. Při rozdělení na n dílů hledáme celé číslo k, pro které je $\frac{k}{n}$ co nejblíž

$$\log_2 \frac{3}{2} = 0{,}584\,962\,5\ldots$$

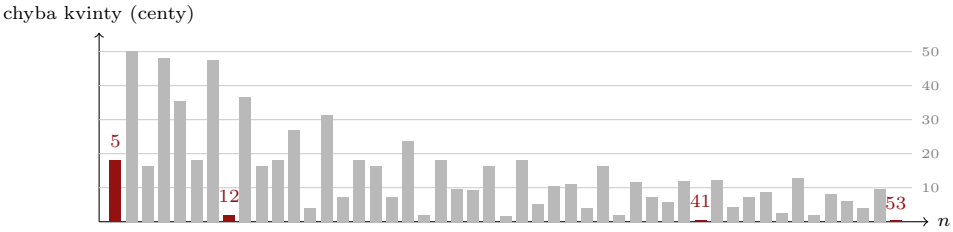
Jde o úlohu přiblížit iracionální číslo zlomkem se jmenovatelem co nejmenším. Přesně tu řeší **řetězové zlomky** z odbočky v kapitole 38:

$$\log_2 \frac{3}{2} = \cfrac{1}{1+\cfrac{1}{1+\cfrac{1}{2+\cfrac{1}{2+\cfrac{1}{3+\cdots}}}}}$$

Useknutím dostaneme nejlepší přiblížení (sblížené zlomky)

$$\frac{1}{2},\quad \frac{3}{5},\quad \frac{7}{12},\quad \frac{24}{41},\quad \frac{31}{53},\quad \ldots$$

Zlomek $\frac{7}{12}$ znamená: kvinta je 7 půltónů z 12. Zlomek $\frac{3}{5}$ odpovídá pětitónové (pentatonické) stupnici, kterou najdeme v lidové hudbě po celém světě. Graf ukazuje, jak daleko je nejlepší kvinta při rozdělení oktávy na n dílů od čisté kvinty:



Dvanáctka je nejmenší počet dílů, při kterém je chyba kvinty menší než dva centy, tedy pod hranicí slyšitelnosti. Menší počty buď kvintu minou o hodně, nebo (jako $n = 7$) vedou ke stupnici, ve které jsou intervaly příliš hrubé. Dalšími ‘rekordmany’ jsou 41 a 53. Rozdělení na 53 dílů navrhl už v 1. století př. n. l. čínský teoretik Ťing Fang a kolem 53 dílů oktávy je postavena i teorie tradiční turecké hudby. Dvanáct tónů tedy není výmysl skladatelů ani kulturní náhoda. Je to nejlepší kompromis mezi počtem kláves a čistotou kvint.

Syntonické koma

Kvinty nejsou jediný problém. Čtyři čisté kvinty nahoru a dvě oktávy dolů by měly dát velkou tercii. Dají ale

$$\left(\frac{3}{2}\right)^4 \cdot \frac{1}{4} = \frac{81}{64} \qquad \text{místo} \qquad \frac{5}{4} = \frac{80}{64}.$$

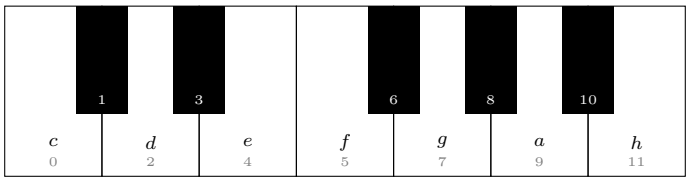
Poměr $\frac{81}{80}$ (asi 21,5 centu) je **syntonické koma**. Čisté kvinty a čisté tercie tedy nejdou mít zároveň. Renesanční *středotónové ladění* proto kvinty trochu zúžilo, aby vycházely čisté tercie. V oblíbených tóninách to znělo krásně, ve vzdálených tóninách ale vznikla tzv. vlčí kvinta, tak falešná, že ‘vyla’. Rovnoměrné ladění, které se prosadilo v 18. a 19. století, rozpustilo všechna komata rovnoměrně do všech intervalů. Žádná tónina není dokonalá, ale všechny jsou stejně použitelné.

39.6 Hudba v modulární aritmetice

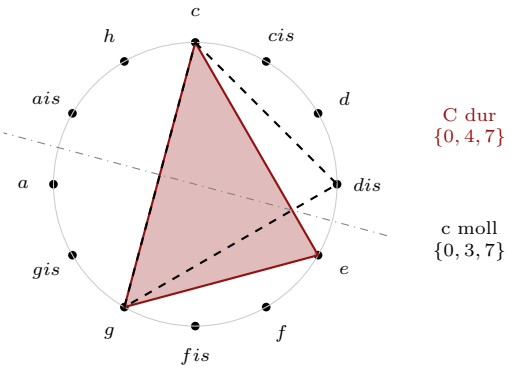
V hudbě se tóny lišící se o oktávu považují za ‘stejné’ (c, c^1 i c^2 jsou všechny c). Pojmenujeme-li půltóny čísly

$$c = 0,\ cis = 1,\ d = 2,\ \ldots,\ h = 11,$$

počítáme s nimi **modulo 12**, přesně jako s hodinami v kapitole 28. Tóny tvoří grupu $\mathbb{Z}_{12}$.



Transpozice o n půltónů je zobrazení $T_n(x) = x + n \bmod 12$. **Inverze** (zrcadlení) je $I(x) = -x \bmod 12$. Na hodinovém ciferníku tónů je transpozice otočení a inverze překlopení. Dohromady generují grupu symetrií pravidelného dvanáctiúhelníku se 24 prvky.

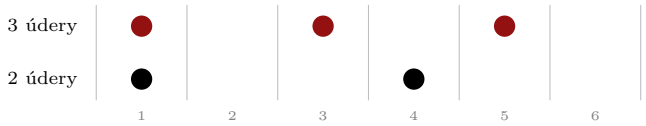


Durový akord $\{0, 4, 7\}$ se skládá z velké tercie (4 půltóny) a malé tercie (3). Mollový akord $\{0, 3, 7\}$ má tytéž intervaly v obráceném pořadí. Na ciferníku je to vidět okamžitě: c moll je zrcadlový obraz C dur podle osy, která leží mezi *dis* a *e* (čerchovaně). Zrcadlení $x \mapsto 7 - x$ totiž posílá $0 \mapsto 7$, $4 \mapsto 3$, $7 \mapsto 0$. Všech 12 durových a 12 mollových akordů je tedy jediný trojúhelník v 24 polohách, otočený a překlopený všemi symetriemi dvanáctiúhelníku.

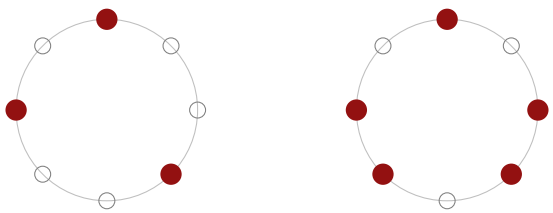
Některé akordy jsou souměrnější než jiné. Zvětšený kvintakord $\{0, 4, 8\}$ je rovnostranný trojúhelník: transpozice o 4 ho nezmění, a proto existují jen 4 různé zvětšené akordy. Zmenšený septakord $\{0, 3, 6, 9\}$ je čtverec a existují jen 3. Právě kvůli této souměrnosti zní tyto akordy ‘nejistě’ a skladatelé je rádi používají k nečekaným modulacím: akord se dá rozvést mnoha směry, protože patří do mnoha tónin zároveň.

39.7 Rytmus a Eukleidův algoritmus

Matematika není jen ve výšce tónů, ale i v čase. Hrají-li dva hudebníci zároveň tři a dva stejně dlouhé údery na takt, potkají se jejich údery jen na začátku taktu a takt se přirozeně dělí na $\mathrm{nsn}(3, 2) = 6$ dílků. Tomu se říká **polyrytmus** 3 : 2.



Zajímavější úloha: jak rozmístit k úderů mezi n pulzů co nejrovnoměrněji? Matematik Godfried Toussaint si v roce 2005 všiml, že algoritmus, který tuto úlohu řeší (a který byl původně vymyšlen pro časování neutronových zdrojů v urychlovačích částic), je ve skutečnosti Eukleidův algoritmus z kapitoly 28. A že rytmy, které vytváří, se objevují v tradiční hudbě po celém světě. Říká se jim **eukleidovské rytmy** $E(k, n)$.



$E(3, 8)$: tresillo $\qquad$ $E(5, 8)$: cinquillo

Tři údery mezi osm pulzů, $x\,.\,.\,x\,.\,.\,x\,.$, je **tresillo**, rytmický základ kubánské hudby, reggaetonu i spousty současného popu. Pět úderů mezi osm, $x\,.\,x\,x\,.\,x\,x\,.$, je kubánské **cinquillo**. Eukleidův algoritmus pro $\mathrm{NSD}(8, 3)$ dělí ‘$8 = 2 \cdot 3 + 2$’ a přesně tato dělení určují, jak velké mezery mezi údery vzniknou: dvě mezery délky 3 a jedna délky 2.

39.8 Barva zvuku a Fourier

Proč zní a^1 na flétně jinak než na houslích, když mají stejnou frekvenci 440 Hz? Protože mají jiné **spektrum**, tedy jiné zastoupení alikvotů. Každý periodický tón lze podle kapitoly 29 rozložit na Fourierovu řadu

$$p(t) = \sum_{n=1}^{\infty} a_n \sin(2\pi n f_1 t + \varphi_n),$$

a právě čísla a_n slyšíme jako barvu zvuku. Flétna má skoro čistý sinusový tón s několika slabými alikvoty. Klarinet má díky válcové trubici zesílené liché alikvoty a jeho tón připomíná obdélníkovou vlnu. Housle mají bohaté spektrum, protože smyčec strunu opakovaně chytá a pouští a struna kmitá jako pilovitá vlna, ve které jsou zastoupeny všechny alikvoty s amplitudou zhruba $\frac{1}{n}$.

Syntezátory to dělají obráceně. **Aditivní syntéza** skládá zvuk ze sinusovek. **Subtraktivní syntéza** začne u pilovité nebo obdélníkové vlny s bohatým spektrem a filtrem z ní ubírá vysoké alikvoty. Autotune a rozpoznávání skladeb v mobilu zase zvuk nejprve rozloží na frekvence pomocí *rychlé Fourierovy transformace*, algoritmu, který spočítá spektrum n vzorků přibližně za $n \log n$ kroků místo n^2.

Cvičení 39.8.1

(a) Kolik centů má interval s poměrem $\frac{9}{8}$ (Pythagorejský celý tón)? Porovnejte s temperovaným celým tónem.

(b) Struna dlouhá 65 cm zní tónem 110 Hz. Kde musí být pražec, aby zněla kvinta výš?

(c) Ukažte, že dvanáct temperovaných kvint dá přesně sedm oktáv.

(d) Najděte v $\mathbb{Z}_{12}$ obraz durového akordu $\{0, 4, 7\}$ při inverzi $I(x) = -x$. O jaký akord jde?

(e) Kolik různých zmenšených septakordů $\{x, x+3, x+6, x+9\}$ existuje?

Řešení 39.8.1

(a) $1200 \log_2 \frac{9}{8} \approx 203{,}9$ centu, temperovaný celý tón má 200.

(b) Frekvence je nepřímo úměrná délce, takže znějící část musí mít délku $\frac{2}{3} \cdot 65 \approx 43{,}3$ cm. Pražec je tedy asi 21,7 cm od nultého pražce u hlavy kytary, ve třetině struny.

(c) $\left(2^{7/12}\right)^{12} = 2^7$. Temperovaná kvinta je tím pádem o přesně $\frac{1}{12}$ Pythagorejského komatu užší než čistá.

(d) $\{0, 8, 5\} = \{f, gis, c\}$, tedy f moll ($gis = as$).

(e) Tři. Akord se nezmění transpozicí o 3, takže z 12 transpozic jsou různé jen $\frac{12}{4} = 3$.

39.9 Příběh — Kníže, který vraždil a skládal

Carlo Gesualdo, kníže z Venosy, byl synovcem kardinála a jedním z nejbohatších šlechticů neapolského království. V říjnu 1590 v Neapoli přistihl svou ženu Marii d'Avalos s jejím milencem, vévodou z Andrie, a oba i s pomocí sluhů zavraždil. Těla nechal vystavit před palácem. Potrestán nebyl: podle tehdejších představ šlechtic hájil svou čest.

Gesualdo se pak stáhl na svůj hrad, znovu se oženil a skládal. Jeho pozdní madrigaly, třeba *Moro, lasso, al mio duolo* ('Umírám, běda, ve své bolesti'), jsou plné chromatických postupů a akordů ze vzdálených tónin, které po sobě jdou tak nečekaně, že jim hudební teoretici dodnes zkoumají logiku. Zněly o tři staletí moderněji, než bylo v jeho době zvykem, a takové harmonie se naplno prosadily až s rovnoměrným laděním, kde mají všechny tóniny stejnou cenu. Igor Stravinskij Gesualda obdivoval a k 400. výročí jeho narození napsal skladbu *Monumentum pro Gesualdo*.

Podle dobových zpráv trpěl Gesualdo na konci života těžkými depresemi a nechával se denně bičovat svými sluhy. Zemřel v roce 1613 na svém hradě v Gesualdu, jen několik týdnů po svém jediném synovi z prvního manželství.

39.10 Shrnutí a otázky

Cvičení 39.10.1 Odpovězte vlastními slovy:

1. Proč struna nekmitá jen jednou frekvencí? Co jsou alikvotní tóny?
2. Co říkají Mersennovy zákony? Proč jsou basové struny tlusté?
3. Proč se intervaly měří v centech a proč je to logaritmus?
4. Proč zní jednoduché poměry frekvencí libě? Uveďte dvě vysvětlení.
5. Co je Pythagorejské a syntonické koma? Proč se spirála kvint nikdy neuzavře?
6. Proč má oktáva dvanáct půltónů? Jak s tím souvisí řetězové zlomky?
7. Jak lze tóny popsat jako $\mathbb{Z}_{12}$? Proč je mollový akord zrcadlovým obrazem durového?
8. Co jsou eukleidovské rytmy?
9. Co určuje barvu zvuku a jak s ní souvisí Fourierova řada?

Poznámka o použití umělé inteligence

Na této knize se podílela umělá inteligence Claude od společnosti Anthropic. Kapitoly 1 a 2 jsem napsala sama. U ostatních kapitol mi Claude pod mým vedením a dohledem pomáhal se strukturou, s obrázky a s prvními verzemi textu, příkladů a řešení. Já jsem určovala, o čem a jak se bude psát, rozhodovala jsem o stylu, humoru a vzhledu knihy a všechno jsem procházela, připomínkovala a opravovala.

Pokud v textu najdete chybu, budu moc ráda, když mi ji napíšete na email **evelyn.vybiral@gmail.com**.